



An MCP-Enabled Interactive Network Protocol Teaching System with Large Language Models

研究生：張育維

Master Student : Yu-Wei Chang

指導教授：林家瑜教授

Advisor: Prof. Chia-Yu Lin

共同指導：郭志義教授

Co-Advisor: Prof. Ted Kuo

Outline



- Introduction
 - Background
 - Motivation
 - Problem Description
 - Goal
 - Contribution
- Related Works
- Proposed Framework
- Experiments
- Conclusion

Background




- 在目前資訊工程與資訊安全中，網路協定已成為不可或缺的知識，能夠理解網路行為與診斷問題的關鍵
- 對於學習者而言，傳統網路教育主要以靜態教材為主，缺乏互動與即時回饋，並難以立即與現存的封包做連結
- 對於教育者而言，目前缺乏一套系統化框架來協助設計課程、規劃教學內容，或即時掌握學生的理解情形
- 隨著大型語言模型（ Large Language Models, LLM ）於語意理解與知識推理上的表現日益成熟，結合其與具備程式化操作能力的技術，如模型上下文協定（ Model Context Protocol, MCP ）等，為教育場域帶來全新的可能性，透過LLM與MCP的結合，網路教育從被動查詢教材轉向透過對話來獲得知識，並能夠縮短理論與操作間的距離，提升學習成效。



Motivation

- 主要挑戰：
 - 學生難以將教科書概念與實際封包內容建立連結
 - 教師難以即時掌握學生理解狀況與學習軌跡
 - 現有的網路協定工具如wireshark，雖然擁有多樣的功能來分析封包，但對於初學者而已，難以理解各個功能與封包資訊背後的涵義





Problem Description

- 學習端：語意理解困難
 - 過於側重底層封包欄位 (Packet-oriented) 。
 - 缺乏協定語意與運作邏輯的直觀連結。
 - 認知負荷過高，學生需自行推導對應關係。
- 教學端：反饋與開發機制匱乏觀察缺失：
 - 難以掌握學生操作歷程與理解誤區。
 - 缺乏系統化框架，教材開發成本過高。
 - 教學策略缺乏數據支撐，難以因材施教。

Goal



- 設計一個結合 LLM 語意推理 與 MCP 程式化工具操控的教學架構
- 實現封包資料到協定語意的自動化層次解釋機制
- 建立自然語言驅動的封包分析與視覺化互動流程
- 發展學習歷程分析機制，支援個別化學習與教學決策

Contribution



- 整合式智慧教學平台
 - 結合 LLM + MCP + WebShark，彌補網路協定教學中「封包數據 ↔ 協定語意理解」的落差
- 自然語言 與視覺化學習的結合
 - LLM 提供層次化封包語意解釋
 - MCP 自動操控分析工具，降低工具操作門檻
- 學習歷程導向的教學支援
 - 分析學生操作行為與學習軌跡
 - 提供教師即時回饋，支援適性化教學
- 可擴展的教材與課程框架
 - 提供教材模板與案例設計機制
 - 提升教材開發效率與教學彈性



Related Works



Network Protocol Teaching

- Title : Methods in Teaching Computer Networks: A Literature Review[1] & What is good teaching of computer networks? [2]& Enhancing Practical Skills in Computer Networking[3]
- Challenge :
 - 協議的抽象性 (狀態轉換、時序關係、多層次互動)
 - 初學者難以建立協議運作的心智模型
 - 在資源受限環境下提供有效教學
- Approach :
 - Prvan & Ožegović [1]:歸納四大教學法 (視覺化、模擬器、虛擬化、主動實驗) ，確立了實作工具在網路教學中的支柱地位。
 - Berglund [2]: 採用現象圖譜學方法揭示學生對 TCP 協議的不同理解方式，強調需考慮學習者的不同程度的認知
 - Mwansa et al. [3]: 評估 Cisco Packet Tracer，發現模擬工具顯著改善實作技能和理論理解
- Limitation :
 - 各方法獨立運作，缺乏智慧化整合：
 - 模擬工具：提供安全環境但缺乏真實性
 - 封包分析工具：提供真實資料但缺乏指導
 - 傳統教學：提供理論知識但缺乏互動
 - 如何整合提供既能觀察真實網路行為，又能獲得即時智慧指導的學習環境仍是有待解決的問題

[1] M. Prvan and J. Ožegović, "Methods in teaching computer networks: A literature review," ACM Transactions on Computing Education, vol. 20, no. 3, pp. 1–35, 2020.

[2] A. Berglund, "What is good teaching of computer networks?," in 33rd Annual Frontiers in Education (FIE 2003), vol. 3, pp. S2D–13, IEEE, 2003

[3] G. Mwansa, M. R. Ngandu, and Z. S. Dasi, "Enhancing practical skills in computer networking: Evaluating the unique impact of simulation tools, particularly Cisco Packet Tracer, in resource-constrained higher education settings," Education Sciences, vol. 14, no. 10, p. 1099, 2024.

Intelligent Tutoring Systems & Conversational Learning(1/2)



- Title: A Comprehensive Review of AI-based Intelligent Tutoring Systems: Applications and Challenges[4] & Artificial intelligence in intelligent tutoring systems toward sustainable education: a systematic review[5]
- Challenge:
 - 針對不同學習者提供個人化、即時的教學指導
 - 試圖透過 AI 技術模擬「一對一」人類導師的個人化引導效果
- Approach:
 - 傳統ITS由四大核心組件：
 - 知識庫:結構化的相關知識
 - 學生模型:追蹤學生的認知狀態、誤解與心理狀態。
 - 教學模組:決定何時提供提示、修正或鷹架支持
 - 使用者介面:提供互動介面
- Limitation:
 - 傳統 ITS 多為封閉式系統僅針對特定的題目，並且缺乏自然對話能力
 - 對於封包教育需要大量專家，來知識工程建構知識庫

[4] M. Zerkouk, M. Mihoubi, and B. Chikhaoui, "A comprehensive review of ai-based intelligent tu-toring systems: Applications and challenges," 2025.

[5] C.-C. Lin, A. Y. Q. Huang, and O. H. T. Lu, "Artificial intelligence in intelligent tutoring systemstoward sustainable education: a systematic review," Smart Learning Environments, vol. 10, no. 1,p. 41, 2023.

Intelligent Tutoring Systems & Conversational Learning(2/2)



- Title: Role of {AI} chatbots in education: systematic literature review [6]& The impact of chatbots based on large language models on second language vocabulary acquisition[7] & Conversational and generative artificial intelligence and human–chatbot interaction in education and research[8]
- Challenge:
 - 利用 LLM 的自然語言能力提供教學對話
 - 從預定義腳本走向開放式互動
- Approach:
 - 多樣化教學支援：系統性回顧顯示[6]，LLM 主要應用於作業輔助、個人化自學路徑規劃及複雜技能的分解發展。
 - 即時語言與認知回饋：尤其在語言習得領域（如詞彙獲取）[7]，生成式 AI 能提供無窮盡的上下文範例，顯著提升學習動機與成效。
- Limitation:
 - 主要應用於語言/數學/通識教育，對於技術教育(網路協議)研究稀少
 - 缺乏實際操作環境整合

[6] L. Labadze, M. Grigolia, and L. Machaidze, "Role of AI chatbots in education: systematic literature review," *International Journal of Educational Technology in Higher Education*, vol. 20, no. 1, p. 56, 2023.

[7] Z. Zhang and X. Huang, "The impact of chatbots based on large language models on second language vocabulary acquisition," *Heliyon*, vol. 10, no. 3, p. e25370, 2024.

[8] I. J. Akpan, Y. M. Kobara, J. Owolabi, A. A. Akpan, and O. F. Offodile, "Conversational and generative artificial intelligence and human–chatbot interaction in education and research," *International Transactions in Operational Research*, vol. 32, no. 3, pp. 1251–1281, 2025.

LLM Applications in Networking



- Title : llmcap: large language model for unsupervised pcap failure detection[9] & Understanding Misunderstandings: Evaluating LLMs on Networking Questions [10]
- Challenge :
 - 驗證 LLM 分析網路封包的可行性
 - 確保網路技術知識的準確性
- Approach :
 - LLMcap [9]: 將封包轉為結構化文字,用 LLM 進行無監督異常檢測
 - Understanding Misunderstandings [10]:系統性評估 LLM 對網路問題的理解程度
- Limitation :
 - LLMcap僅作為分析工具，每有給進一步的解釋
 - Understanding Misunderstandings則顯示了，不同的LLM對於網路問題容易產生看似合理但實際錯誤的回答

[9] L. Tulczyjew, K. Jarrah, C. Abondo, D. Bennett, and N. Weill, "Llmcap: Large language model for unsupervised pcap failure detection," 2024.

[10] M. Anwar and M. Caesar, "Understanding misunderstandings: Evaluating LLMs on networking questions," SIGCOMM Computer Communication Review, vol. 54, no. 4, pp. 14–24, 2025.

Tool-Augmented LLM & Agent Systems



- Title : ReAct: Synergizing Reasoning and Acting in Language Models [11] & Toolformer: Language Models Can Teach Themselves to Use Tools [12]
- Challenge :
 - LLM 知識受限於訓練資料時效性
 - 難以執行需要外部工具協助的任務
- Approach :
 - ReAct [11]: 交替生成推理軌跡與行動,克服幻覺問題
 - Toolformer[12]: 自監督學習工具使用,整合計算器/搜尋引擎等
- Limitation :
 - 主要聚焦於通用任務(問答、程式碼生成)
 - 尚未探討應用於技術教育場景
 - 特別缺乏針對即時分析+互動回饋的教學應用
 - Toolformer需要對於特定model經過微調才能使用

[11] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, "React: Synergizing reasoning and acting in language models," in International Conference on Learning Representations (ICLR), 2023.

[12] T. Schick, J. Dwivedi-Yu, R. Dessi, R. Raileanu, M. Lomeli, E. Hambro, L. Zettlemoyer, N. Can-chedda, and T. Scialom, "Toolformer: Language models can teach themselves to use tools," in Thirty-seventh Conference on Neural Information Processing Systems, 2023.



LLM Evaluation Methods

- Title : G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment [13]
- Challenge :
 - 傳統自動評估指標 (BLEU、ROUGE) 主要依賴文字相似度
 - 難以捕捉語意品質、事實準確性和任務相關性等複雜面向
 - 開放式生成任務難以評估
- Approach :
 - G-Eval [13]: 利用具有思維鏈 (Chain-of-Thought) 的 GPT-4 評估自然語言品質
 - 首先提示 LLM 生成評估步驟
 - 使用這些步驟和表單對生成文字進行評分
 - 在摘要和對話生成任務中，與人類判斷的 Spearman 相關性達 0.514 (BLEU: 0.360)
 - LLM-as-Judge:
 - 評估多個維度的品質 (相關性、連貫性、創造性)
 - 提供可解釋的評估理由
 - 可客製化評估標準適應特定領域
- Limitation :
 - 需針對特定領域客製化評估維度
 - LLM會對於特定答案的偏頗

[13] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu, and C. Zhu, "G-eval: NLG evaluation using GPT-4 with better human alignment," in Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 2511–2522, Association for Computational Linguistics, 2023


Work Comparison

	研究缺口	本研究貢獻
網路教學工具	各工具（模擬、分析、理論）功能碎片化，缺乏具備智能解釋的統合環境	智慧整合真實封包分析與理論指導
智慧教學系統	傳統架構難以處理非結構化、動態的實作數據（如 PCAP 封包）	建構專注於網路協議分析的 ITS 系統，實現底層實作數據的自動化教學建模
LLM 網路應用	現有研究多側重於自動化維運分析，缺乏針對學習者的教學對話設計	將封包數據轉化為具備教學意義的互動內容
工具增強 LLM	鮮少應用於即時性與適應性的互動教學場景	透過 MCP 協定實現教學工具與模型間的即時數據對齊與動態引導



An MCP-Enabled Interactive Network Protocol Teaching System with Large Language Models

An MCP-Enabled Interactive Network Protocol Teaching System with Large Language Models





Stage 1 : Large Language Models

- LLM是基於深度學習技術，在海量文本數據上進行訓練的人工智慧模型。
- LLM模型我們選擇使用Claude Sonnet 4 因為它具備：
 - 技術文件理解: RFC 解釋、協議轉換
 - 支援長上下文:多輪對話、大量封包
 - 能夠對多模態處理 :封包截圖、拓撲圖
 - 支援MCP



System Prompt

- 角色設定："專業網路封包分析助理"
- 環境嵌入：WebShark 網址 + PCAP 檔案的預設目錄+互動方式
- 操作規則：涉及封包 → 先呼叫mcp tool get_state() 確認當前狀況
- 情境回應：封包內容 → 在webshark上進行實際演示
通用知識 → 直接回答
- 錯誤避免：
 - 避免螢幕截圖，為了減少token的消耗
 - 強調使用真實的封包狀況來避免他產生幻覺，誤導學習
 - 在上傳封包前先確認目前封包狀況來避免重複上傳

Stage 2 : Model Context Protocol Tool



- MCP 是一個開放標準，讓 LLM 能以統一的方式安全地存取外部數據與工具
- 我們主要使用三個mcp tool來完成課程架構， Microsoft的mcp playwright[14]、pyshark mcp與自製的mcp 狀態擷取工具
- mcp playwright操控網頁，引導學生使用webshark，讓學生能夠用口語的方式了解每一個步驟
- pyshark mcp為了彌補webshark所缺少的即時捕獲封包功能
- 狀態擷取主要由兩個工具組成，分別記錄了webshark的狀態與學生在教育框架上的行動，webshark狀態可以使使用者不須告訴LLM詳細封包資訊，就能夠詢問相關問題，而記錄學生行動則是能夠讓LLM為每位學生產生客製化的建議。

[14] Microsoft, Playwright MCP: Playwright MCP server, GitHub repository, 2025. [Online]. Available: <https://github.com/microsoft/playwright-mcp>



MCP 狀態擷取工具


- `Get_state()` 會將封包資訊轉換成json格式儲存包含
 - 基本統計：封包總數、平均封包大小、時間範圍。
 - 協定分析：各傳輸層協定與應用層協定的分布數量。
 - IP 分析：來源與目的 IP 的出現頻率排行、主要通訊對話關係。
 - 當前焦點: Webshark pcap 點擊狀況、協議樹的展開與否、當前過濾狀況
- `Get_learn_state()` 會將學生在教育平台的學習軌跡記錄下來，幫助教師分析學生學習狀況

Stage 3: Application & Implementation Layer




- WebShark為網頁版的wireshark，能夠顯示封包資訊與統計資料，選擇webshrk是為了能夠使用playwright來操控，讓學生在不同的情況下有實際的引導
- 自製 Web 介面的教育平台，主要是建立一個架構，主要功能包含上傳課程，學生狀況監督，並能夠與LLM進行對話

Workflow



Practical demonstration





Practical demonstration

test / Network packet capture file

Share

There's traffic from Fedora Linux host 10.6.15.101. Is it malicious?

Let me analyze the traffic from the Fedora Linux host 10.6.15.101 to determine if it's malicious. I'll examine the connections, protocols, and behavior patterns.

Get state

Now let me examine the DNS queries and the connections more closely. Let me start by looking at the DNS traffic to see what domains are being queried:

Click

Good! Packet 1 is selected. Now let me check the current state and look for information about the IP 143.244.34.1 which has the most traffic. Let me examine packet 19 which showed a TLS alert, as this might be significant:

Click

Perfect! Now let me get the current state to analyze packet 19 details:

Get state

Excellent! Now I can see packet 19's raw data shows TLS alert code 0x15 0x03 0x01 0x00 0x02 0x02 0x46. Let me look at the unknown IP 143.244.34.1 which has the most traffic. Let me search for information about this IP online:

143.244.34.1 IP address malicious 10 results

Let me search specifi

Reply to Claude...

Sonnet 4.5

Web Shark NG

localhost:8085/webshark/#261e71de1d71cdf19bf81de530fda672

WebShark workshop-part-04-11.pcap 已選擇 1 個封包

Endpoints Response Time Statistics Export Objects Misc

Apply a display filter

11	0.101147	10.6.15.101	108.179.232.93	TLSv1.2	227	Client Hello (SNI=icechat.net)
12	0.101177	10.6.15.101	108.179.232.93	TLSv1	173	Client Hello (SNI=www.icechat.net)
13	0.147022	108.179.232.93	10.6.15.101	TCP	54	443 → 49683 [ACK] Seq=1 Ack=174 Win=64128 Len=0
14	0.147030	108.179.232.93	10.6.15.101	TLSv1.2	1436	Server Hello
15	0.150845	108.179.232.93	10.6.15.101	TCP	1436	443 → 49683 [PSH, ACK] Seq=1383 Ack=174 Win=64128 Len=1382 [TCP PC
16	0.150851	108.179.232.93	10.6.15.101	TCP	1386	443 → 49683 [PSH, ACK] Seq=2765 Ack=174 Win=64128 Len=1332 [TCP PC
17	0.151015	10.6.15.101	108.179.232.93	TCP	54	49683 → 443 [ACK] Seq=174 Ack=4097 Win=263168 Len=0
18	0.156611	108.179.232.93	10.6.15.101	TCP	54	443 → 49684 [ACK] Seq=1 Ack=120 Win=64128 Len=0
19	0.156616	108.179.232.93	10.6.15.101	TLSv1	61	
20	0.156921	108.179.232.93	10.6.15.101	TCP	54	443 → 49684 [FIN, ACK] Seq=8 Ack=120 Win=64128 Len=0
21	0.157806	10.6.15.101	108.179.232.93	TCP	54	49684 → 443 [ACK] Seq=120 Ack=9 Win=263168 Len=0
22	0.173315	108.179.232.93	10.6.15.101	TLSv1.2	588	Certificate, Server Key Exchange, Server Hello Done
23	0.173501	10.6.15.101	108.179.232.93	TCP	54	49683 → 443 [ACK] Seq=174 Ack=4631 Win=262656 Len=0
24	0.176426	10.6.15.101	108.179.232.93	TLSv1.2	147	Client Key Exchange, Change Cipher Spec, Encrypted Handshake Message

Apply a field filter

> Frame 19: 61 bytes on wire (488 bits), 61 bytes captured...

> Ethernet II, Src: Netgear_b6:93:f1 (20:e5:2a:b6:93:f1), ...

> Internet Protocol Version 4, Src: 108.179.232.93, Dst: 1...

> Transmission Control Protocol, Src Port: 443, Dst Port: ...

> Transport Layer Security

HEX

BINARY

TEXT

0000

00 08 02 1c 47 ae 20 e5 2a b6 93 f1 08 00 45 00 ...G...

0010

00 2f e9 69 00 00 2e 06 34 e4 6c b3 e8 5d 0a 06 .../.i....

0020

0f 65 01 bb c2 14 3e 0b 1d ee a0 9f 64 14 50 18 ...e.....

0030

01 f5 bc d2 00 00 15 03 01 00 02 02 46F



Practical demonstration

test / Network packet capture file

Let me try a more direct search for that specific IP and IRC or malware:

143.244.34.1 IRC botnet malware 10 results

Based on my comprehensive analysis of the traffic from Fedora Linux host 10.6.15.101, here is my assessment:

Analysis Summary: NOT MALICIOUS - LEGITIMATE HTTPS TRAFFIC

Benign Traffic Indicators:

1. DNS Queries (Packets 1-4):

- The host queries for icechat.net and www.icechat.net
- DNS responses resolve to 108.179.232.93 (legitimate IP)
- This is normal DNS behavior for visiting a website

2. TLS/HTTPS Connections:

- Multiple TLS 1.2 handshakes to 108.179.232.93 (icechat.net)
- Proper TLS handshake sequence:** Client Hello → Server Hello → Certificate Exchange → Encrypted Data
- Uses standard port 443 (HTTPS)
- SNI (Server Name Indication) correctly shows icechat.net and www.icechat.net

3. Protocol Version Issue (Packet 19):

- TLS Alert: "Protocol Version" error
- This is NOT malicious - it indicates:
 - Client tried TLSv1.0 (older protocol)
 - Server rejected it and required TLS 1.2+
 - This is actually good security - the server enforces modern encryption
 - Connection was properly terminated and retried with TLS 1.2

Reply to Claude...

Sonnet 4.5

Web Shark NG

localhost:8085/webshark/#261e71de1d71cdf19bf81de530fda672

WebShark workshop-part-04-11.pcap 已選擇 1 個封包

Endpoints Response Time Statistics Export Objects Misc

Apply a display filter

11	0.101147	10.6.15.101	108.179.232.93	TLSv1.2	227	Client Hello (SNI=icechat.net)
12	0.101177	10.6.15.101	108.179.232.93	TLSv1	173	Client Hello (SNI=www.icechat.net)
13	0.147022	108.179.232.93	10.6.15.101	TCP	54	443 → 49683 [ACK] Seq=1 Ack=174 Win=64128 Len=0
14	0.147030	108.179.232.93	10.6.15.101	TLSv1.2	1436	Server Hello
15	0.150845	108.179.232.93	10.6.15.101	TCP	1436	443 → 49683 [PSH, ACK] Seq=1383 Ack=174 Win=64128 Len=1382 [TCP PD
16	0.150851	108.179.232.93	10.6.15.101	TCP	1386	443 → 49683 [PSH, ACK] Seq=2765 Ack=174 Win=64128 Len=1332 [TCP PD
17	0.151015	10.6.15.101	108.179.232.93	TCP	54	49683 → 443 [ACK] Seq=174 Ack=4097 Win=263168 Len=0
18	0.156611	108.179.232.93	10.6.15.101	TCP	54	443 → 49684 [ACK] Seq=1 Ack=120 Win=64128 Len=0
19	0.156616	108.179.232.93	10.6.15.101	TLSv1	61	
20	0.156921	108.179.232.93	10.6.15.101	TCP	54	443 → 49684 [FIN, ACK] Seq=8 Ack=120 Win=64128 Len=0
21	0.157806	10.6.15.101	108.179.232.93	TCP	54	49684 → 443 [ACK] Seq=120 Ack=9 Win=263168 Len=0
22	0.173315	108.179.232.93	10.6.15.101	TLSv1.2	588	Certificate, Server Key Exchange, Server Hello Done
23	0.173501	10.6.15.101	108.179.232.93	TCP	54	49683 → 443 [ACK] Seq=174 Ack=4631 Win=262656 Len=0
24	0.176426	10.6.15.101	108.179.232.93	TLSv1.2	147	Client Key Exchange, Change Cipher Spec, Encrypted Handshake Message

Apply a field filter

> Frame 19: 61 bytes on wire (488 bits), 61 bytes captured...

> Ethernet II, Src: Netgear_b6:93:f1 (20:e5:2a:b6:93:f1), ...

> Internet Protocol Version 4, Src: 108.179.232.93, Dst: 1...

> Transmission Control Protocol, Src Port: 443, Dst Port: ...

> Transport Layer Security

HEX

BINARY

TEXT

0000

00 08 02 1c 47 ae 20 e5

2a b6 93 f1 08 00 45 00

....G...

0010

00 2f e9 69 00 00 2e 06

34 e4 6c b3 e8 5d 0a 06

./i....

0020

0f 65 01 bb c2 14 3e 0b

1d ee a0 9f 64 14 50 18

.....>

0030

01 f5 bc d2 00 00 15 03

01 00 02 02 46

.....F



Experiment



G-Eval Evaluation Framework

- 傳統指標的侷限性：
 - 如 BLEU、ROUGE 僅能比對「文字重疊率」。
 - 無法評估教學系統需要的語意準確性、互動品質與角色定位。
- G-Eval[13] 核心概念：
 - LLM-as-a-Judge：利用具備強大推理能力的 LLM 作為評審，根據設定的準則進行評分。
 - 實作工具：採用 DeepEval 框架，實現標準化的評估介面。
- 三大核心優勢：
 - 語意理解：能辨識回答是否符合教學邏輯，而非僅是關鍵字匹配。
 - 高度靈活性：可針對「網路協定」與「MCP 工具使用」自訂評分標準。
 - 高人類相關性：評分結果與人類專家判斷具備高度一致性。

[13] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu, and C. Zhu, "G-eval: NLG evaluation using GPT-4 with better human alignment," in Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 2511–2522, Association for Computational Linguistics, 2023



Evaluation Metrics

評估維度	核心目的 (設計理由)
Answer Relevancy	確保回應精準理解需求並與問題高度相關。
Hallucination	嚴防錯誤或臆測資訊，確保網路協定技術的正確性。
Misuse	確保互動不偏離教學目的，過濾不當用途。
MCP-use & Completion	驗證 MCP 工具整合效能與指定任務達成率
Role Adherence	維持「教學助理」定位，著重於引導而非直接給答案。
Knowledge Retention	跨多輪對話保留上下文，確保教學連貫性
Conversation Completeness	確認整體教學流程完整達成使用者目標

G-Eval Scoring Mechanism and Workflow

- 步驟一：評估提示詞構建 (Prompt Construction)
 - 定義每個維度的評分標準 (0 - 1 分) 。
 - 提供輸入資訊 (學生問題、系統回應、對話歷史) 。
 - 設定輸出格式：「理由 (Reasoning) + 分數 (Score)」 。
- 步驟二：LLM 評審評分 (LLM Judging)
 - 評審模型根據準則分析回應，給出具體的評分理由，確保評估過程透明可解釋。
- 步驟三：分數聚合 (Score Aggregation)
 - 對多個測試案例進行算術平均，計算最終得分：

$$Final\ Score = \frac{1}{N} \sum_{i=1}^N score_i$$



Experimental Setup – Compared Systems

- Baseline System (LLM-only)
 - 接收相同的學生問題
 - 無法存取 即時的PCAP 資料，僅有在system prompt給予封包資訊
 - 僅能基於訓練知識回答
 - 只產生文字回應
- Proposed Method(Claude + MCP + WebShark)
 - 整合多個 MCP 工具
 - 可查詢當前 PCAP 狀態
 - 可套用過濾器、選擇封包、標記欄位
 - 進行多輪互動式教學

系統名稱	描述	LLM	模型工具	能力特點
Baseline System	純LLM，無工具整合	Claude 4 Sonnet	無	單輪回答，教科書式講解
Proposed Method	LLM + MCP 工具整合	Claude 4 Sonnet	操控網頁、統計資料、抓取封包	多輪互動，具情境感知能力



Experimental Workflow

- step 1 :
 - 環境準備初始化系統狀態。
 - 紀錄基礎數據：初始封包總數、協定分布情況。
- Step 2：系統回應生成 (對照組設計)
 - LLM 統計資料 (Baseline)：單輪對話，不調用工具。
 - Claude MCP WebShark (本研究)：多輪對話，動態調用 MCP 工具分析 PCAP 狀態。
- Step 3：雙評審評分機制輸入：
 - 學生問題、系統回應、PCAP 情境。
 - 評審模型：GPT-4o 與 Gemini (gemini-2.5-flash-lite)進行獨立八維度評分。
- Step 4：數據記錄
 - 完整保存對話紀錄、評分理由、MCP 工具調用軌跡及對話輪數。



Data Description

- 本研究使用 Palo Alto Networks Unit 42 威脅情報團隊開發的 Wireshark Workshop 系列作為實驗資料集，具有以下特性
 - 真實性：包含實際捕獲的網路流量，非人工構造
 - 教學導向：每個 PCAP 檔案配有教學影片和分析文檔
 - 協定多樣性：涵蓋 HTTP、HTTPS、DNS、FTP、SMB 等多種協定
 - 情境豐富：包含正常流量、異常行為、惡意軟體通訊等不同場景
 - 權威性：由業界知名威脅情報團隊維護，品質有保證

Data Description



場景名稱	問題類型	涉及技術	關鍵教學點	學生初始問題
作業系統指紋識別	操作引導型	OS fingerprinting,TTL, TCP window,User-Agent	TTL 值 判 斷、HTTP標頭 分 析、多 特 徵 綜 合 判	我是初學者，請教我如何從封包中識別出主機的作业系統？
IDS 警報分析	診斷分析型	IDS alerts, HTTPanalysis, threat intelli-gence	IDS 警 報 解 讀、流 量 模 式 分 析、威 脅 判 定 邏 輯	這個來自 10.6.15.101的 Fedora Linux 流量被 IDS 標記為可疑。請分析這是真的惡意行為還是誤報？
行動裝置資訊提取	結構化任務型	DHCP, HTTP head-ers, User-Agent pars-ing	DHCP 主 機 名 查 詢、User-Agent 解 析、多 步 驟 任 務 管 理	請幫我完成以下任務： 1) 找出 Android 設備的主機名 2) 確認製造商 3) 找出使用的瀏覽器
FTP 檔案傳輸分析	探索與提取型	FTP protocol, streamfollowing, file extrac-tion	FTP 指令識別、資料流追蹤、檔案重組技術	這個 PCAP 中有 FTP 流量嗎？如果有，請告訴我傳輸了什麼檔案。



GPT-4o Evaluation Results

System Type	Experiment	AR	Hallu.	Mis.	MCP	MCP Task	Role	Know.	Conv.
Proposed Method	場景一	0.70	0	0	0	0.75	0.78	1	1
	場景二	0.70	0	0	0	0.75	0.78	1	1
	場景三	0.71	0	0	0	1.00	0.00	1	1
	場景四	0.71	0	0	0	0.75	0.78	1	1
Baseline System	場景一	0.36	0	0	—	—	0.00	1	0
	場景二	0.65	0	0	—	—	0.00	1	1
	場景三	0.65	0	0	—	—	0.00	1	1
	場景四	0.70	0	0	—	—	0.00	1	1

註：AR=Answer Relevancy, Hallu.=Hallucination, Mis.=Misuse, MCPTask=MCP Task Completion, Role=Role Adherence, Know.=Knowledge Retention, Conv.=Conversation Completeness

GPT-4o Evaluation Results



- Claude MCP WebShark 的穩定優勢：
 - 高相關性 (Answer Relevancy)：始終保持在 0.70 以上，能提供具體封包證據。
 - 完美的一致性：Knowledge Retention 與 Conv. Completeness 皆為 1.0。
 - 工具執行力：MCP Task Completion 穩定維持在 0.75 - 1.0。
- 純 LLM 系統的侷限：
 - 缺乏證據：實驗一相關性僅 0.36，難以處理需要 PCAP 證據的任務。
 - 角色失能：Role Adherence 全數為 0，完全無法維持教學助理設定。



Gemini Evaluation Results

System Type	Experiment	AR	Hallu.	Mis.	MCP	MCP Task	Role	Know.	Conv.
Proposed Method	場景一	0.79	0	0	0	1	1	0.86	1
	場景二	1.00	0	0	0	1	1	0.85	1
	場景三	1.00	0	0	0	1	1	0.85	1
	場景四	1.00	0	0	0	1	1	0.85	1
Baseline System	場景一	0.55	0	0	—	—	0	0.86	1
	場景二	1.00	0	0	—	—	0	0.85	1
	場景三	1.00	0	1	—	—	0	0.85	1
	場景四	0.88	0	1	—	—	0	0.85	1

Gemini Evaluation Results



- Claude MCP WebShark 的穩定優勢：
 - 回答相關性 (AR)：場景二至四達滿分 1.0，展現極高精準度。
 - 角色維持 (Role)：全場景滿分 1.0，穩定維持教學助理定位。
 - 任務達成 (MCPTask)：工具呼叫成功率 100%，無誤用 (Misuse)。
- 純 LLM 系統的侷限：
 - 教學角色失能：Role Adherence 全數為 0，無法執行引導式教學。
 - 安全性風險：於場景三、四偵測到 Misuse (誤用) 現象。
 - 品質不穩定：AR 指標於 0.55 至 1.0 間劇烈波動。

Cross-Model Comparison




- 雙模型一致性發現 (Consensus)
 - 核心優勢確認：兩者皆認可 MCP 系統在「封包佐證」與「對話完整性」上遠優於純 LLM。
 - 純 LLM 的致命傷：雙模型均判定其 Role Adherence 為 0，證實其不適合作為長期教學助理。
 - 系統可靠性：兩者對於 Hallucination (幻覺) 的評分皆為 0，顯示系統生成的內容具備事實基礎。
- 判定尺度不同：
 - 知識保留：GPT-4o 傾向給滿分，Gemini 則較嚴格 (0.85)。
 - 敏感度差異：Gemini 對於「工具誤用 (Misuse)」的偵測較 GPT-4o 敏感。

Statistical Significance Testing



統計顯著性檢驗：MCP系統 vs 純LLM (配對樣本 t 檢定)





Conclusion

- 研究核心：解決「有資料、無指導」痛點核心問題：
 - 學生難以將抽象協議概念與實際封包內容連結。
 - 系統架構：結合 Claude Sonnet 4 與 MCP 協議，建構互動式教育。
 - 教學模式：透過自然語言實現情境感知的互動式引導。
- 採用 G-Eval 框架與雙評審機制（ GPT-4o, Gemini ）驗證：
 - 回答相關性 (AR)：提升 20.3%。
 - 知識保留 (Know.)：提升 33.3%。
 - 任務完成度 (MCPTask)：穩定達 75 - 100%。
 - 技術準確性：幻覺率 (Hallu.) 為 0。
- 創新價值與應用潛力教學模式創新：
 - 將 MCP 標準引入技術教育，解決 Wireshark 學習門檻高的痛點。
 - 領域貢獻：證明 LLM+MCP 混合架構為網路協議教學提供有效解決方案。

Reference



- [1] M. Prvan and J. Ožegović, “Methods in teaching computer networks: A literature review,” *ACM Transactions on Computing Education*, vol. 20, no. 3, pp. 1–35, 2020.
- [2] A. Berglund, “What is good teaching of computer networks?,” in *33rd Annual Frontiers in Education (FIE 2003)*, vol. 3, pp. S2D–13, IEEE, 2003.
- [3] G. Mwansa, M. R. Ngandu, and Z. S. Dasi, “Enhancing practical skills in computer networking: Evaluating the unique impact of simulation tools, particularly Cisco Packet Tracer, in resource-constrained higher education settings,” *Education Sciences*, vol. 14, no. 10, p. 1099, 2024.
- [4] M. Zerkouk, M. Mihoubi, and B. Chikhaoui, “A comprehensive review of ai-based intelligent tutoring systems: Applications and challenges,” 2025.
- [5] C.-C. Lin, A. Y. Q. Huang, and O. H. T. Lu, “Artificial intelligence in intelligent tutoring system toward sustainable education: a systematic review,” *Smart Learning Environments*, vol. 10, no. 1, p. 41, 2023.
- [6] L. Labadze, M. Grigolia, and L. Machaidze, “Role of AI chatbots in education: systematic literature review,” *International Journal of Educational Technology in Higher Education*, vol. 20, no. 1, p. 56, 2023.
- [7] Z. Zhang and X. Huang, “The impact of chatbots based on large language models on second language vocabulary acquisition,” *Heliyon*, vol. 10, no. 3, p. e25370, 2024.
- [8] I. J. Akpan, Y. M. Kobara, J. Owolabi, A. A. Akpan, and O. F. Offodile, “Conversational and generative artificial intelligence and human–chatbot interaction in education and research,” *International Transactions in Operational Research*, vol. 32, no. 3, pp. 1251–1281, 2025.
- [9] L. Tulczyjew, K. Jarrah, C. Abondo, D. Bennett, and N. Weill, “Llmcap: Large language model for unsupervised pcap failure detection,” 2024.
- [10] M. Anwar and M. Caesar, “Understanding misunderstandings: Evaluating LLMs on networking questions,” *SIGCOMM Computer Communication Review*, vol. 54, no. 4, pp. 14–24, 2025.

Reference



- [11] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, “React: Synergizing reasoning and acting in language models,” in International Conference on Learning Representations (ICLR), 2023.
- [12] T. Schick, J. Dwivedi-Yu, R. Dessi, R. Raileanu, M. Lomeli, E. Hambro, L. Zettlemoyer, N. Can-chedda, and T. Scialom, “Toolformer: Language models can teach themselves to use tools,” in Thirty-seventh Conference on Neural Information Processing Systems, 2023.
- [13] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu, and C. Zhu, “G-eval: NLG evaluation using GPT-4 with better human alignment,” in Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 2511–2522, Association for Computational Linguistics, 2023.
- [14] Microsoft, Playwright MCP: Playwright MCP server, GitHub repository, 2025. [Online]. Available: <https://github.com/microsoft/playwright-mcp>

Reference



- [1] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, “React: Synergizing reasoning and acting in language models,” in International Conference on Learning Representations (ICLR), 2023.
- [2] T. Schick, J. Dwivedi-Yu, R. Dessi, R. Raileanu, M. Lomeli, E. Hambro, L. Zettlemoyer, N. Can-chedda, and T. Scialom, “Toolformer: Language models can teach themselves to use tools,” in Thirty-seventh Conference on Neural Information Processing Systems, 2023.
- [3] L. Tulczyjew, K. Jarrah, C. Abondo, D. Bennett, and N. Weill, “Llmcap: Large language model for unsupervised pcap failure detection,” 2024.
- [4] M. Anwar and M. Caesar, “Understanding misunderstandings: Evaluating LLMs on networking questions,” SIGCOMM Computer Communication Review, vol. 54, no. 4, pp. 14–24, 2025.
- [5] M. Zerkouk, M. Mihoubi, and B. Chikhaoui, “A comprehensive review of ai-based intelligent tutoring systems: Applications and challenges,” 2025.
- [6] C.-C. Lin, A. Y. Q. Huang, and O. H. T. Lu, “Artificial intelligence in intelligent tutoring systems toward sustainable education: a systematic review,” Smart Learning Environments, vol. 10, no. 1, p. 41, 2023.
- [7] L. Labadze, M. Grigolia, and L. Machaidze, “Role of AI chatbots in education: systematic literature review,” International Journal of Educational Technology in Higher Education, vol. 20, no. 1, p. 56, 2023.
- [8] Z. Zhang and X. Huang, “The impact of chatbots based on large language models on second language vocabulary acquisition,” Heliyon, vol. 10, no. 3, p. e25370, 2024.
- [9] I. J. Akpan, Y. M. Kobara, J. Owolabi, A. A. Akpan, and O. F. Offodile, “Conversational and generative artificial intelligence and human–chatbot interaction in education and research,” International Transactions in Operational Research, vol. 32, no. 3, pp. 1251–1281, 2025.
- [10] M. Prvan and J. Ožegović, “Methods in teaching computer networks: A literature review,” ACM Transactions on Computing Education, vol. 20, no. 3, pp. 1–35, 2020.
- [11] A. Berglund, “What is good teaching of computer networks?,” in 33rd Annual Frontiers in Education (FIE 2003), vol. 3, pp. S2D–13, IEEE, 2003.

Reference



- [12] C. Sanders, Practical Packet Analysis: Using Wireshark to Solve Real-World Network Problems.No Starch Press, 3rd ed., 2017
- [13] G. Mwansa, M. R. Ngandu, and Z. S. Dasi, “Enhancing practical skills in computer networking:Evaluating the unique impact of simulation tools, particularly Cisco Packet Tracer, in resource-constrained higher education settings,” Education Sciences, vol. 14, no. 10, p. 1099, 2024.
- [14] P. Yang and X. Zhang, “Teaching reform and practice with computer network courses in the contextof new engineering education,” Advances in Vocational and Technical Education, vol. 7, no. 3,pp. 1–6, 2025.
- [15] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu, and C. Zhu, “G-eval: NLG evaluation using GPT-4 withbetter human alignment,” in Proceedings of the 2023 Conference on Empirical Methods in NaturalLanguage Processing (EMNLP), pp. 2511–2522, Association for Computational Linguistics, 2023