

國立陽明交通大學
電機工程學系碩士班
碩士論文

Department of Electronics and Electrical Engineering
National Yang Ming Chiao Tung University
Master Thesis

基於圖像辨識的入侵偵測系統: 已知分類結合未知攻擊偵測

An Image-Based Approach for Unknown Attack Detection in Network Intrusion Detection Systems

研究生: 康學民 (Xue-Min Kang)
指導教授: 王蒞君 (Li-Chun Wang)

中華民國 一一五年三月
March 2026

基於圖像辨識的入侵偵測系統: 已知分類結合未知攻擊偵測

An Image-Based Approach for Unknown Attack Detection in
Network Intrusion Detection Systems

研 究 生：康學民
指導教授：王蒞君

Student: Xue-Min Kang
Advisor: Dr. Li-Chun Wang

國立陽明交通大學
電機工程學系碩士班
碩士論文

A Thesis
Submitted to Department of Electronics and Electrical Engineering
College of Electronics and Computer Engineering
National Yang Ming Chiao Tung University
in partial Fulfilment of the Requirements
for the Degree of
Master of Science
in
Electrical and Computer Engineering

March 2026

Hsinchu, Taiwan

中華民國 一一五年三月

誌 謝

本論文得以順利完成，首先要衷心感謝我的指導老師王蒞君教授，非常感謝老師在研究過程中給予的細心指導與關心，從研究方向的探討到論文撰寫與修改，皆提供了寶貴的建議與關心，使我能夠順利完成本研究。另一部分也要特別感謝國立中央大學的林家瑜教授，在研究過程中與學生討論並且提供許多意見與實驗想法，對本研究的方向與方法帶來重要啟發，謹致上誠摯的感謝。

同時感謝口試委員們撥冗審閱本論文，並提供詳細的建議使本論文內容改進並且更加完善。此外也要謝謝實驗室一起努力的同學、學長姐和各位夥伴們，在我讀碩士期間的彼此互相激勵與討論，使我在面對困難時更加有動力去解決，也讓研究過程順利完成。

最後謝謝我的家人在求學期間給予的支持與鼓勵，使我能夠無後顧之憂地投入研究並最終完成學業。謹以此文，向身旁所有關心與幫助過我的人致上最誠摯的謝意。

基於圖像辨識的入侵偵測系統：已知分類結合未知攻擊偵測

學生：康學民

指導教授：王蒞君 博士

國立陽明交通大學 電機工程學系碩士班

摘 要

隨著網路環境的快速發展，相關的物聯網應用不斷推陳出新，與之而來的是新型態的網路攻擊日益多樣且複雜，企業和基礎設施等因為遭受相關惡意行為而造成的損失等也跟著日益增加，其中最主要的威脅便是來自於防禦系統先前未知的漏洞或是新型態未見的攻擊方法導致無法有效偵測。而過往的網路入侵偵測系統研究多半著重於已知異常類型的偵測，至今雖然對已知的類型已經能達到優秀的偵測結果，但缺少有效的未知攻擊偵測能力是一大痛點，因此發展具備高效辨識並且具有有效偵測未知能力的入侵偵測系統已成為相關網路與資安領域的一大趨勢。為了實現一個完整且有效的網路偵測系統，本研究提出一套基於流量轉影像的網路入侵偵測架構，旨在同時達成已知攻擊的多分類任務以及未知攻擊的偵測。首先，本研究與傳統主流的入侵偵測做法不同，而是同時將多筆的網路流量資料轉換為固定大小的影像形式，用意是相較於原始資料集提供的單筆流量輸入，這樣的作法能夠考量到流量彼此之間的上下關係，並且透過強大的 Transformer-based 模型捕捉其中潛在的結構與語意特徵，並且基於迫切需要有效偵測未知攻擊的需求，本研究設計的方法和架構會先做包含已知攻擊和正常類別的多分類模型，接著對正常類別進一步處理以檢測出可能混雜其中的未知類別，未知偵測的做法實際上透過分群搭配本研究獨特的取樣方法並在正常樣本的主子空間的投影以建構出潛在的低維度表示，若是非正常的未知類別則投影到低維度空間容易產生較大的誤差。最後實驗結果證明了本研究所提出方法的有效性，除了能夠有效分辨已知攻擊的類型之外，即使模型只學過部分類別也能夠從正常的部分推斷出可能不屬於其中的未知攻擊，而且相比其他的分佈外檢測 (Out-of-Distribution, OOD) 或未知偵測方法而言，本方法的結果呈現上具有優勢。

關鍵詞：入侵偵測系統、未知偵測。



An Image-Based Approach for Unknown Attack Detection in Network Intrusion Detection Systems

Student: Xue-Min Kang

Advisor: Dr. Li-Chun Wang

Department of Electronics and Electrical Engineering
National Yang Ming Chiao Tung University

Abstract

With the rapid development of the network environment, related applications and services continue to evolve, and network attacks have become increasingly diverse and sophisticated. As a result, enterprises and critical infrastructures are facing growing losses caused by malicious activities. One of the main reasons is that defense systems often fail to effectively detect previously unknown vulnerabilities or newly emerging attack techniques.

Traditional research on Network-based Intrusion Detection Systems (NIDS) has primarily focused on detecting known attack types. Although these systems have achieved high accuracy in identifying known threats, their limited capability in detecting unknown or novel attacks remains a significant challenge. Therefore, developing an intrusion detection system that not only performs accurate classification of known attacks but also possesses effective unknown attack detection capability has become an important research direction in the field of cybersecurity.


To build a comprehensive and effective network intrusion detection system, this study proposes an image-based framework that transforms network traffic into images. The goal is to simultaneously accomplish multi-class classification of known attacks and detection of unknown attacks. Unlike conventional approaches that process individual flow records as input, this study converts multiple consecutive network traffic flows into fixed-size images. Compared to using single-flow inputs, this design enables the model to capture contextual relationships among flows. By leveraging powerful deep learning models, the proposed approach effectively learns spatial and semantic features embedded within the transformed representations.

To address the urgent need for unknown attack detection, the proposed framework first trains a multi-class classifier covering known attack types and normal traffic. Subsequently, the normal class is further analyzed to identify potential unknown samples mixed within it. The un-

known detection mechanism combines clustering with a novel sampling strategy proposed in this work. Specifically, a principal subspace is constructed based on normal samples to learn a compact low-dimensional representation. Unknown or abnormal samples tend to produce larger reconstruction or projection errors when mapped into this subspace, enabling effective separation from normal traffic.

Experimental results demonstrate the effectiveness of the proposed method. In addition to accurately classifying known attack types, the model is capable of inferring potential unknown attacks from normal traffic even when trained on only a subset of attack categories. Furthermore, compared to other out-of-distribution (OOD) and unknown detection approaches, the proposed method achieves superior performance.

Keywords: Intrusion Detection System, Unknown Attack Detection.



目 錄

摘要	i
Abstract	iii
目錄	v
圖目錄	vii
表目錄	viii
一、 緒論	1
1.1 研究背景	1
1.2 研究動機	6
1.3 本文貢獻	8
1.4 論文架構	8
二、 文獻探討	9
2.1 研究背景	9
2.2 傳統機器學習的入侵偵測方法	10
2.3 深度學習在入侵偵測的應用	11
2.4 圖像化在入侵偵測中的應用	12
2.5 開放集識別的相關研究	13
2.6 網路入侵偵測的未知攻擊研究	14
三、 解決方法架構	16
3.1 整體流程概述	18
3.2 資料處理與圖像轉換	20
3.3 訓練 ViT 多分類模型	21
3.4 建構 OOD 分類器	22
3.5 結合已知分類與未知檢測	24
四、 實驗結果	26
4.1 資料集介紹	26

4.2	實驗環境與設置	28
4.2.1	硬體與軟體環境	28
4.2.2	資料集與前處理	28
4.2.3	第一階段:ViT 模型訓練設置	29
4.2.4	第二階段：未知攻擊檢測實驗設置	30
4.2.5	評估指標	31
4.3	實驗與其他方法比較	32
4.3.1	模型結果	32
4.3.2	方法比較	32
4.4	消融實驗 (Ablation Study)	39
4.4.1	影像化策略	39
4.4.2	正常樣本分群策略	41
4.4.3	取樣選擇策略	41
4.5	本章小結	46
五、	結論與未來工作	47
5.1	研究挑戰與對應解決策略	47
5.2	研究貢獻	47
5.3	研究限制	48
5.4	未來研究方向	49
	參考文獻	50

圖目錄

1.1	2018–2025 全球資料外洩平均成本（單位：百萬美元），資料來源：IBM 《Cost of a Data Breach Report》 [1]	2
1.2	各產業平均的資料外洩成本（單位：百萬美元），資料來源：IBM 《Cost of a Data Breach Report》 [1]	3
1.3	外洩事件的平均識別與控制時間（單位：天），資料來源：IBM 《Cost of a Data Breach Report》 [1]	4
3.1	本研究之 Proposed Method	19
3.2	不同類別流量轉換後之 RGB 影像示例。	21
3.3	Vision Transformer (ViT) 架構示意圖，取自 Dosovitskiy et al. [2]	22
4.1	本圖為根據 Verkerken et al. (2023) [3] 所提出之三階段入侵偵測流程重新 繪製。	33
4.2	本圖為根據 Chen et al. 提出的兩階段偵測重新繪製的流程圖 [4]	34
4.3	CICIDS2017 上連續流量構成的 DDoS 攻擊圖片	39
4.4	CICIDS2017 上隨機流量構成的 DDoS 攻擊圖片	40
4.5	CICIDS2017 高到低取樣時在各比例下的偵測率折線圖	42
4.6	CICIDS2018 高到低取樣時在各比例下的偵測率折線圖	43
4.7	CICIDS2017 低到高取樣時在各比例下的偵測率折線圖	44
4.8	CICIDS2018 低到高取樣時在各比例下的偵測率折線圖	45

表 目 錄

4.1	實驗環境系統配置	28
4.2	CICIDS2017 轉圖像後樣本數	29
4.3	CICIDS2018 轉圖像後樣本數	29
4.4	模型訓練設置參數	30
4.5	第二階段未知攻擊檢測實驗設置	31
4.6	CICIDS2017 七種攻擊類別輪流作為 Unknown 時的分類結果：主對角線為 Unknown Recall(異常偵測模組 @5%FPR (%) 設定下)，非對角線為各已知類別的分類準確率 (%), Normal 固定為已知類別。	32
4.7	CICIDS2018：攻擊類別輪流作為 Unknown 的分類結果。主對角線為 Unknown Recall(異常偵測模組 @5%FPR (%) 設定下) 其餘為各已知類別的分類準確率 (%)。Normal 永遠作為已知類別。	32
4.8	不同比較對象在異常偵測模組設定 5% FPR 下，各攻擊類別之未知攻擊整體 Recall 比較 (CICIDS2017)	35
4.9	Chen et al. 方法於各未知攻擊類別的未知攻擊準確率與 FPR 比較 (CICIDS2017)	35
4.10	不同比較對象在異常偵測模組設定 5% FPR 下，各攻擊類別之未知攻擊整體 Recall 比較 (CICIDS2018)	35
4.11	Chen et al. 方法於各未知攻擊類別的未知攻擊準確率與 FPR 比較 (CICIDS2018)	36
4.12	本研究在不同 FPR 門檻 (於異常偵測模組設定) 下之未知攻擊整體偵測表現 (CICIDS2017)。	37
4.13	本研究在不同 FPR 門檻 (於異常偵測模組設定) 下之未知攻擊整體偵測表現 (CICIDS2018)。	37
4.14	影像化策略對已知攻擊分類準確率 (%) 之影響 (CICIDS2017, ViT-B/16)	40

4.15 正常樣本分群與取樣策略對未知攻擊整體偵測表現之影響（於異常偵測模組設定 5% FPR）。	41
4.16 CICIDS2017 不同取樣比例下（High-to-Low 相似度策略）未知攻擊偵測效果（TPR@5%FPR, %）。列為攻擊類別，欄為 golden sample 取樣比例。	42
4.17 CICIDS2018 不同取樣比例下（High-to-Low 相似度策略）未知攻擊偵測效果（TPR@5%FPR, %）。列為攻擊類別，欄為 golden sample 取樣比例。	43
4.18 CICIDS2017 不同取樣比例下（Low-to-High 相似度策略）未知攻擊整體偵測表現之影響（於異常偵測模組設定 5% FPR）。列為攻擊類別，欄為取樣比例。	44
4.19 CICIDS2018 不同取樣比例下（Low-to-High 相似度策略）未知攻擊整體偵測表現之影響（於異常偵測模組設定 5% FPR）。列為攻擊類別，欄為取樣比例。	45
5.1 研究挑戰與本研究之對應解決策略	47

一、緒論

1.1 研究背景

隨著數位化浪潮的推進，網際網路已經成為了生活中不可缺少的基礎設施之一，推動了經濟、科技與生活便利。然而，其快速發展與開放性也帶來了日漸嚴重的資訊安全挑戰。各類網路與異常行為層出不窮，常見的如分散式的阻斷攻擊（DDoS）、惡意掃描、漏洞利用、惡意軟體及滲透攻擊等，已對資訊系統的穩定與安全形成重大威脅。由於攻擊手法與組織化程度持續提升，單純依靠邊界防禦或固定規則的安全機制，往往難以在實際場景中長期維持有效防護。

根據 IBM 在 2025 年發布的《Cost of a Data Breach Report》[1]，全球資料外洩的平均成本在過去數年間持續攀升，從 2018 年的 386 萬美元成長至 2024 年的 488 萬美元，在 2025 年略微下降至 444 萬美元，但整體仍維持高水準。此結果顯示即使投入更多資安相關的人員與技術，外洩事件仍難以完全避免，且攻擊者不斷的透過新型態手法試圖突破防禦與偵測機制。此外不同產業亦呈現顯著差異，例如涉及敏感個資或關鍵基礎設施之領域的外洩成本往往更高，能否及早偵測與控制在實務上具有關鍵影響。

此外，報告亦指出資料外洩的成本組成中，偵測與事件處置仍佔一定比例，顯示及早偵測並縮短處置時間在降低整體損失上具有實務重要性。除了成本面向之外，外洩事件的規模與頻率也持續升高。2020 年國家技術安全聯盟安全報告指出，重大資訊安全問題每月都在加劇，且有大量帳戶資訊被駭客洩漏並在暗網上出售 [5]。在此背景下，僅依賴傳統防火牆、存取控制或簽章式阻擋往往不足以應對多變攻擊，因此入侵偵測系統（Intrusion Detection Systems, IDS）成為重要防禦機制之一，能夠透過監控與分析網路流量，在攻擊尚未擴大之前及早發現並阻止潛在惡意行為。

早期 IDS 研究多依賴簽章式偵測（Signature-based detection），其優點為對已知攻擊具有較高準確率，但對於零日攻擊（Zero-day attack）或未知威脅的偵測能力有限。為提升對未知攻擊的防禦能力，後續研究者提出基於異常的偵測方法（Anomaly-based detection），利用統計模型或機器學習演算法建構正常行為分布，並以偏離程度作為異




圖 1.1: 2018–2025 全球資料外洩平均成本 (單位：百萬美元)，資料來源：IBM 《Cost of a Data Breach Report》 [1]

常判斷依據 [6, 7, 8]。然而在實務環境中，正常流量本身具有高度多樣性，使得異常偵測常面臨「偵測率不足」或「誤報率過高」的兩難，進一步限制其部署效益。

近年研究指出，將每一筆網路流量 (Flow) 視為獨立樣本的研究方式，與真實攻擊行為並不相符。實際入侵活動通常呈現多階段步驟的特性，例如偵查、橫向移動與資料外洩，其證據往往分散於多筆流量、不同時間區段甚至多個主機之間，而非存在於單一流量中。因此僅依賴單筆流量進行分類，可能難以捕捉攻擊整體行為特徵。近期文獻亦指出許多以單一流量為單位的偵測方法，在符合時間因果關係 (例如依時間切割或跨日/跨場域評估) 的情形下效能會明顯下降。此現象反映入侵偵測問題本質更接近於行為序列上的分析，而非獨立樣本分類問題；因此如何建模出流量之間的上下文關係，成為近年 IDS 的重要研究方向之一 [9]。

隨著神經網路的快速進展，IDS 研究亦逐漸轉向深度學習模型如卷積神經網路 (Convolutional Neural Networks, CNN)、循環神經網路 (Recurrent Neural Networks, RNN) 及長短期記憶模型 (Long Short-Term Memory, LSTM) 等，以期透過特徵表徵學習提升偵測效能 [10, 11]，並嘗試引入能捕捉全域關係的 Transformer 類架構 (例如 Vision Transformer 或其變體)，使模型在特徵交互關係建模上具有更高彈性 [12]。

此外，亦有研究透過自編碼器進行特徵降維並搭配序列模型進行分類，例如 Xue 等

Measured in USD millions




圖 1.2: 各產業平均的資料外洩成本（單位：百萬美元），資料來源：IBM 《Cost of a Data Breach Report》 [1]




圖 1.3: 外洩事件的平均識別與控制時間（單位：天），資料來源：IBM 《Cost of a Data Breach Report》 [1]

人提出以 Hybrid Autoencoder 與 ResNet-LSTM 結合之入侵偵測架構，在多個資料集上能提升分類上的準確率。然而其研究亦指出：即使整體準確率提升，在多類別與未知攻擊情境下仍難以維持穩定辨識能力，此現象顯示問題並非單純分類能力不足，而是過去的大多數研究方法多建立於封閉集合假設，當資料分布產生大規模偏移或出現未見攻擊型態時，模型缺乏合理偵測未見型態的機制，導致在現實中部署的可行性上受限。因此若僅依賴高表現分類模型，仍不足以解決實務 IDS 面臨的未知威脅問題 [13]。

綜合上述討論，可以發現現有 IDS 方法在實務上仍面臨以下挑戰：

- 挑戰一：未知攻擊的辨識能力不足。監督式模型通常建立在封閉集合（Closed-set）假設上，僅能對已知類別做出判斷；當輸入的資料出現訓練未見之攻擊型態時，模型容易將其誤判為正常或相近已知類別。另一方面，異常偵測方法雖可視所有偏離為異常，但在正常流量多樣性高的情境下往往帶來較高誤報。
- 挑戰二：多任務偵測的整合困難。實務 IDS 往往同時需要「已知攻擊多分類」與「未知攻擊偵測」兩種能力；然而現有研究多聚焦單一任務，較缺乏能在同一架構

中同時輸出已知攻擊類型與可靠未知告警的設計。

- 挑戰三：較少關注流量上下文特徵與評估偏差。多數研究仍將流量視為獨立樣本進行建模，忽略攻擊在時間與行為上的連續性，導致難以偵測具序列特徵的攻擊。

上述挑戰亦揭示了一個重要的研究缺口：在真實部署情境中 IDS 不僅需要在封閉集合假設下追求優異的已知準確率，更需要面對未知威脅存在的開放環境特性。若模型僅能在既有類別上做出精細分類，而缺乏對未知流量的可靠告警能力，則在零日攻擊 (Zero-day attack) 或變種攻擊出現時仍可能產生高風險誤判。此外偵測模型如果忽略流量之間的上下文關係，則其對多階段入侵行為的辨識能力將受限，尤其在更符合真實情境的時間序評估下可能出現效能落差。基於以上，本研究聚焦於同時兼顧上下文關係與未知攻擊偵測之 IDS 架構設計，期望在不犧牲已知類別的分類能力前提下，同時系統又能對未知威脅的穩健性與可部署性。

因此，雖然近年深度學習顯著提升了 IDS 在已知攻擊分類上的表現，但在開放環境下如何同時提升多分類與未知攻擊偵測能力，並在更符合真實情境的評估下依舊保持優秀的效能，已成為 IDS 領域的關鍵研究課題。

1.2 研究動機

基於上述背景，本研究的動機主要來自以下幾點：

1. 入侵偵測在實務上屬於開放環境問題：與一般監督式分類問題不同，網路攻擊的類型與行為模式會隨時間演化，攻擊者能主動調整行為以規避既有偵測規則，使得訓練資料永遠無法完整涵蓋未來威脅。
2. 未知攻擊具有高度偽裝性並造成辨識不對稱：網路攻擊常刻意模仿正常行為以降低被偵測機率，例如低速掃描、分散式探測或隱匿通訊等，使惡意流量在特徵空間中與正常流量高度重疊。此特性導致分類模型容易將未知攻擊判為正常，而異常偵測方法則可能因正常行為多樣性而產生較高誤報率。根據 Verizon 公布的 2025 年《Data Breach Investigations Report》[14]，零日漏洞相關攻擊呈現顯著成長趨勢，更凸顯未知攻擊偵測的迫切性。
3. 單筆流量建模忽略上下文，難以對應多階段攻擊：多階段入侵往往分散於多筆流量之中，因此若僅將單筆 flow 視為獨立樣本，容易忽略其上下文關係。本研究希望在建模上考量流量之間的關聯性，使偵測不僅依賴單點特徵，而能更貼近真實攻擊行為模式。
4. 影像化表徵與圖像模型提供結構建模的可行途徑：本研究將網路流量轉換為影像形式，使模型能以空間關係方式學習流量之間的關聯結構，並導入可有效關注全局的 Vision Transformer (ViT) 圖像模型以捕捉長距依存與交互特徵。
5. 實務需求同時包含已知分類與未知偵測：實務部署中，IDS 不僅需要辨識是哪一種已知攻擊，也需要對未見過的未知威脅給出可靠的告警。因此本研究設計一個兩階段、多任務偵測架構：第一階段針對已知攻擊進行分類，第二階段針對被判為正常的樣本進一步進行未知攻擊偵測，以提升整體部署可用性。

研究目標與評估觀點

基於上述動機，本研究以「可部署的開放環境入侵偵測系統」為目標，強調模型在真實情境下的穩健性與可用性。具體而言，本研究希望同時滿足三項需求：首先，在已知攻擊集合上維持穩定且具辨識力的多分類能力；其次，當未知攻擊出現時能提供可靠告警，避免將未知威脅誤判為正常流量；最後，在固定誤報率（False Positive Rate, FPR）條件下提升未知攻擊的偵測率，

問題定義

綜合以上動機與挑戰，本研究所探討的核心問題可形式化描述如下：

給定加拿大網路安全研究中心（CIC）公開之 CICIDS2017 與 CICIDS2018 網路流量資料，令每筆樣本 $x \in \mathcal{X}$ ，其標籤集合可分為已知類別 $\mathcal{Y}_K$ 與未知類別 $\mathcal{Y}_U$ 。在訓練階段僅能觀測 $\mathcal{Y}_K$ 的標註資料，而在測試或部署階段可能出現 $\mathcal{Y}_U$ 中之未知攻擊。本研究之目標為設計一個偵測架構，使其在準確分類已知攻擊類型的同時，亦能在固定誤報率（FPR）條件下有效識別未知攻擊，並相較現有方法達到更佳之偵測表現。此問題可視為開放集識別（Open-set recognition）與異常偵測在入侵偵測情境下的結合。

1.3 本文貢獻

綜合上述研究動機與問題分析，本研究之主要貢獻如下：

1. 提出結合流量圖像化與 **Vision Transformer** 之多分類與未知入侵偵測架構：不同於傳統以數值特徵為主的 IDS，本研究將網路流量轉換為影像形式，並導入 ViT 以捕捉圖像化後之全域關係與上下文特徵，使模型能有效學習流量之間的潛在交互表示，並支援後續未知偵測需求。
2. 設計針對未知攻擊的偵測機制：為因應開放環境下的零日威脅，本研究結合主成分分析 (Principal Component Analysis, PCA) 殘差並設計基於相似度分群取樣策略，從被判為正常的樣本中進一步篩選潛在未知攻擊，以提升對未知威脅的靈敏度與泛化能力。
3. 在統一評估下進行客觀比較並展現有效性：實驗結果顯示所提出架構在未知攻擊偵測任務上呈現一定程度的效能提升，並能同時兼顧已知攻擊分類與未知威脅偵測的實務需求。

1.4 論文架構

本論文其餘章節安排如下：

1. 第二章回顧入侵偵測系統相關研究，包含簽章式與異常式偵測、深度學習式 IDS、開放集識別與未知攻擊偵測方法，以及上下文／時序建模之相關文獻。
2. 第三章說明本研究提出之兩階段偵測架構，包含網路流量影像化表示、第一階段已知攻擊分類模型、第二階段未知攻擊偵測機制與其設計細節。
3. 第四章介紹實驗設定與評估指標，並在 CICIDS2017 與 CICIDS2018 上進行方法比較與消融分析，探討各模組對效能之影響。
4. 第五章總結本研究之貢獻與限制，並提出未來研究方向。

二、文獻探討

隨著網路安全威脅日益嚴重，入侵偵測系統是資訊系統安全的重要防線之一，大量的相關研究致力於提升入侵偵測系統的偵測準確率和泛化性以應對日益複雜的攻擊行為。依照偵測方法的不同大致可以分為基於已知類型（Signature-based Detection）和基於異常的方法，而分類模型也從過去傳統的機器學習模型如支持向量機 (SVM) 到新興起的深度學習模型如 DNN、CNN、RNN 甚至是 transformer 等。

本章節會系統性回顧目前入侵偵測系統的研究成果，從傳統方法的理論與實務應用到探討近期深度學習方法的進展，並針對網路流量做圖像化以及未知類別偵測的相關方法進行分析。透過對現有研究的比較和分析，為本研究所提出的方法和架構提供理論基礎與技術上的支持。

2.1 研究背景

入侵偵測系統的起源可以追溯至 Denning 於 1987 年所提出的經典模型 [15]。更之前的電腦安全研究大多集中在存取控制、防火牆等，但這篇作者首次提出透過監控系統記錄，並統計異常檢測來發現入侵的概念。傳統方法多依賴於 signature-based detection（簽章式偵測），能有效發現已知攻擊，但對未知攻擊的辨識能力不足。為了應對新型態威脅，anomaly-based IDS（基於異常的偵測系統）成為一個新的方向，其主要可以分為基於統計方法建模或是透過機器學習方法進行偵測。相比於簽章式偵測，異常偵測更具有發現未知攻擊的潛力，然而其高誤報率也限制了現實環境的實用性 [6, 7]。因此，如何兼顧兩者的優點仍是後續研究的重要課題。

另一方面，公開的入侵偵測資料集數量相對有限。真實網路流量往往包含大量敏感資訊（例如個人隱私），若直接公開將涉及法規問題；而完整標註正常與攻擊流量則需要高度專業與高昂成本。因此，早期 IDS 研究多採用 KDD99 與其改良版本 NSL-KDD 作為基準，但這些資料集存在樣本分布不均、重複比例過高以及攻擊過時等限制 [16, 17]。

近年來，加拿大網路安全研究中心（CIC）所建構的 CICIDS2017 與 CICIDS2018 因

模擬真實企業環境、涵蓋多樣化現代攻擊並具上下流量關係以及完整標註。多篇比較研究亦指出，CICIDS2017 與 2018 已逐漸成為現代入侵偵測系統研究的標準基準資料集 [18, 19]，鑑於這些原因本研究選擇以這兩種資料集其作為主要實驗資料來源，以驗證所提方法在真實流量環境下的可行性。

2.2 傳統機器學習的入侵偵測方法

在入侵偵測領域中，傳統的機器學習方法曾經是研究主流方向，透過較經典的監督式分類器如決策樹、隨機森林、支持向量機 (SVM) 與 KNN 等，使用標註資料學習特徵與攻擊類型之間的關係對應，已經足夠能在已知攻擊的二分類或多分類任務中取得良好成效 [20]。另一項研究則在 NSL-KDD 與較新的 CICIDS2018 資料集上分析多種機器學習模型，結果顯示在 NSL-KDD 的多分類任務上，隨機森林 (Random Forest) 與作者設計的集成學習方法分別達到 98.81% 與 99.53% 的準確率以及 94.66% 和 98.78% 的召回率，而在 CICIDS2018 的二元分類上兩種方法也達到 98.91% 和 99.99% 的準確率 96.69% 和 99.89% 的召回率以及上顯示傳統 ML 方法在已知攻擊分類上仍具強大競爭力 [21]。然而儘管效果顯著，但並未對偵測未知的效果進行探討，這也是本研究希望改進之處。

另一方面，為了擴大實用性與系統偵測未知的能力，基於異常的偵測方法也廣泛應用於 IDS。Bhuyan 等人 [22] 將 anomaly-based 方法歸納為統計、距離、資訊理論與機器學習四大類，這些分類框架有助於系統性理解各種方法的理論基礎，然而該分類並未深入探討各類方法可能的混合應用，這啟發本研究思考結合不同方法進一步的可能性；Ahmed 等人 [23] 則指出雖然這些方法都具備檢測未知攻擊，但高誤報率等問題限制了其實際應用。

Sommer 等人 [8] 進一步批判指出，以往 IDS 研究多在 close-world 假設下進行，未能反映現實中的 open-world 環境。基於異常的偵測系統則面臨誤報代價高昂、訓練資料不足、異常檢測結果無法歸因、以及評估困難等挑戰，限制了傳統機器學習在真實環境中的應用。綜合而言，傳統方法在應對未知威脅與多樣化攻擊時仍顯不足，隨著深度學習模型的發展，也促使研究者開始探索透過深度學習與混合式方法，以期提升

入侵偵測系統的整體效能與穩定性。

2.3 深度學習在入侵偵測的應用

隨著深度學習技術的快速發展，相關模型在網路入侵偵測系統（IDS）中的應用日益廣泛，並展現出強大的特徵學習與異常偵測能力。初期的相關研究多聚焦於利用結構化的網路流量特徵，採用深度神經網路如卷積神經網路（CNN）、循環神經網絡（RNN）或是自動編碼器（AutoEncoder）等模型來提升入侵偵測的準確率，Chuanlong Yin 等人（2016）利用 RNN 模型捕捉網路流量中的時間序列特徵，對持續性攻擊行為展現出較好的偵測能力，並於 NSL-KDD 資料集上和傳統的分類器如隨機森林、SVM 等進行比較並且取得較為優異的結果 [10]。此研究證實了考量時間的做法在特定攻擊偵測上的好處，但 RNN 在處理長距離依賴時可能面臨梯度消失問題，因此後續研究開始探索如 Transformer 等更先進的架構。

例如最新提出的 FlowTransformer 框架針對網路流量序列資料進行專門設計，能靈活組合不同的輸入編碼方式、Transformer 變體及分類頭，並系統性地比較各種模型配置對性能的影響。作者的實驗結果表明，Transformer 模型在 NSL-KDD、CSE-CIC-IDS2018 及 UNSW-NB15 等多個資料集上，不僅準確率達到或超越過往的深層模型，且在推理速度上方面有明顯提升，顯示該架構在實務應用上具備高度潛力 [12]。

而 Shone 等人提出將非對稱深度自編碼器與隨機森林結合的混合模型，透過深度自編碼器進行非監督式特徵抽取，並在 KDD Cup99 及 NSL-KDD 等資料集上，顯著提高多分類攻擊的識別效果 [11]。該研究的優點在於結合了深度學習的特徵提取能力與傳統機器學習的分類效能，但其使用較為過時的資料集上，對於現代常見的攻擊的分類能力無法得到驗證。

綜合上述研究成果，深度學習技術透過自動挖掘網路流量中複雜的空間及時間特徵，有效提升了入侵偵測系統對攻擊的辨識能力。特別是近年來 Transformer 架構的引入，相比傳統模型在長距離依賴捕捉相關性上更有優勢，為未來高效且靈活的入侵偵測系統提供了新的技術方向。然而即使如此，多數深度學習方法的研究仍預設訓練時與真實應用的樣本或是類型相同，並不足以面對開放式環境帶來的未知或新型攻擊挑

戰，這正是近年研究轉向開放集識別異常偵測的原因。

2.4 圖像化在入侵偵測中的應用

本研究亦屬於此圖像化入侵偵測的研究方向，透過將流量特徵轉換為影像並引入新的 Vision Transformer 架構，以發揮考量上下關係與特徵時在未知攻擊識別上的潛力。近年來，隨著深度學習在影像辨別領域中取得優異的進展，將流量資訊轉換為影像的入侵偵測方法成為一個新興的研究趨勢。該方法透過將高維度的特徵透過數值縮放，映射到固定大小格式的影像並讓模型學習如何捕捉整體的攻擊模式，並且藉此捕捉傳統表格型特徵無法呈現的流量時間依賴性與上下文關係以達到更好的偵測能力。

Ho 等人提出一種結合決策樹特徵選擇與滑動視窗機制的轉換方式，將網路流量轉為固定大小的 RGB 圖像，並使用 ViT 作為二元分類器，在 CICIDS2017 與 UNSW-NB15 資料集上分別達到 96.4% 與 98.5% 的分類準確率，FPR 分別是 1.1% 和 2.3%，都顯著優於其餘比較方法 [24]。該研究的貢獻在於成功將 ViT 應用於流量分類並且透過實驗比較說明相較於 CNN 關注局部特性的設計，ViT 在全局關聯性上的優勢更加適合流量轉圖像化的作法，但其僅作為二元分類器，限制了對具體攻擊類型的識別能力以及未知偵測效果，這一點是本研究希望擴展的方向。

在提升模型泛化能力方面，Yan 等人提出 TL-CNN-IDS 系統，利用 IG 為主的方法（Information Gain, IG）進行特徵工程，並將數值型流量資料轉為彩色圖像，輸入至 VGG16、Inception 與 Xception 等 CNN 架構進行轉移學習並結合集成式的分類方法。該方法在 CICIDS2017 與 NSL-KDD 資料集上達成超過 99% 的準確率和召回率 (Recall)，勝過進行比較的 DNN 和 LSTM-RNN 等模型，此方法的優點是透過遷移學習有效利用了預訓練模型的強大能力，並且證實利用圖像轉換的優勢 [25]。

El-Ghamry 等人針對 IoT 的入侵檢測提出一套結合特徵選擇、圖像化與最佳化機制的入侵偵測系統 (IDS) [26]。該系統首先利用遞迴特徵消除 (RFE) 從 NSL-KDD 資料集中選取特徵，再將其轉換為 RGB 圖像以輸入至 VGG-16 模型進行攻擊分類。為強化模型效能，研究中引入粒子群最佳化演算法 (Particle Swarm Optimization, PSO) 進行超參數調整，顯著提升分類準確率與穩定性。此方法的優點在於系統性地進行了超參數

優化，但其在 NSL-KDD 這個較舊的資料集上達到近乎百分百的準確率，能否泛化到流量模式更複雜的現代網路環境仍有待驗證。

然而現有多數將網路流量轉換為影像之入侵偵測研究，仍主要著重於在封閉世界假設（Closed-set setting）下提升分類效能，即假設所有測試樣本皆屬於訓練階段已知的正常或攻擊類型。在此設定下影像化方法確實能有效提升已知攻擊的分類準確率，相關研究亦已在多個資料集上取得相當亮眼的成果。

然而在實際網路環境中，新型或變形攻擊往往不會事先出現在訓練資料中，單純以分類準確率作為評估指標難以反映模型在未知攻擊情境下的風險。當深度模型被迫對未知樣本進行已知類別判斷時，往往會產生過度自信的錯誤預測，因此若不做進一步處理會嚴重影響系統的實務可用性。

基於上述觀察，本研究延續圖像化入侵偵測的研究脈絡，進一步將其應用於開放世界（Open-set）入侵偵測情境。綜上所述，圖像化的流量偵測方法在入侵偵測中具備一些優勢：（1）能夠有效考慮流量潛在的前後關係；（2）可與現有的強大影像模型（如 CNN、ViT）結合。

2.5 開放集識別的相關研究

開放集異常偵測旨在識別那些在訓練階段未出現過的未知類別樣本，並與已知類別加以區分，是現代入侵偵測與安全系統中的重要挑戰。研究者提出多種方法以拓展傳統分類模型的辨識能力。

例如，PCA Residual 是一種簡單而且快速的方法，透過建立已知或正常樣本的主成分空間，並計算測試樣本的投影誤差大小來判斷是否偏離原始子空間的分布。此方法能應用於深度特徵空間的開放集識別，具有計算效率高的優點。或是常見的單類別分類器（One-Class Classifiers），如 One-Class SVM 與 Deep SVDD 為常見的異常偵測方法，但在實際應用中仍需謹慎設定模型參數，以避免影響偵測結果。

進一步的方法則包括 OpenMax[27]，其透過建模已知類別的 activation 向量分布並使用 Weibull 分布調整 softmax 輸出以排除未知樣本；而 Virtual Logit Matching (ViM)[28] 則利用分類器最後一層的特徵嵌入與虛擬 logit 進行未知程度的衡量，展現出優異的

未知樣本識別能力，而這兩種方法的好處都在於是一種後處理技術，無需重新訓練分類器，但強烈依賴於該模型輸出的 softmax 與 logit 分布，可能不適用於所有模型或是場景。另一方面，生成式模型如自動編碼器（Autoencoder, AE）與變分自動編碼器（Variational Autoencoder, VAE）也常被應用於異常偵測任務。此類方法通常透過學習正常資料的潛在行為，模型學習如何能夠重建輸入樣本，並利用重建誤差（Reconstruction error）作為異常評估指標。當測試樣本無法被模型有效重建時，其重建誤差將顯著增加，因此可被判定為潛在異常樣本 [29, 30]。

綜合來說這些方法各具優勢，但在實際 IDS 部署中仍面臨諸多挑戰，單一找出分布外方法並不能很好的平衡已知與未知類別的檢測率與誤報率。因此設計能兼顧效能與實用性的開放集入侵偵測架構，仍是後續研究的重要方向。

2.6 網路入侵偵測的未知攻擊研究

隨著網路環境日益複雜，新型態攻擊手法層出不窮，導致傳統基於封閉世界假設（Closed-World Assumption）的入侵偵測系統在面對未知攻擊（Zero-Day Attacks）時顯得有力有未逮。為此近年研究逐漸轉向開放集合識別（Open-Set Recognition, OSR）與異常偵測模型，以強化模型對未知樣本的辨識能力。

Hindy 等人所提出的 Autoencoder-based 未知攻擊偵測方法 [31]。該研究設計了一套基於重建誤差的異常偵測流程，透過自編碼器去學習良性網路流量的潛在表示，並以預設閾值評估測試樣本的重建損失，從而判斷是否為未知攻擊。作者同時使用 One-Class SVM 作為比較基準，證明深度學習模型在流量偵測中的表現具有顯著優勢，但其只以正常建構的模型並不能確切辨認已知的攻擊類型，若要實際部署上這點較為可惜。

Qiu 等人提出的 VAEMax 架構即是一種結合 OpenMax 與 Variational Autoencoder（VAE）的雙階段未知攻擊偵測模型 [32]。該方法首先透過 OpenMax 對流量進行分類並初步辨識出部分未知樣本，；其後再以 VAE 針對每個類別進行重建誤差檢測，進一步識別潛藏的未知攻擊。此一雙重機制設計能兼顧精確分類與異常感知，有效緩解 OpenMax 單一方法在邊界樣本誤判上的侷限性，但需要建構多個 VAE 模型進行偵測，

會需要訓練過多的模型加重整體的複雜程度。

Xu 等人近期的研究則採用 CICIDS2017 資料集，針對三類排除於訓練資料之外的攻擊樣本（DoS slowloris、DoS Slowhttptest 與 Bot）進行未知偵測的能力評估，全面比較了多種不同類型的模型，包括 MLP、CNN、LOF 與 OCSVM 四種模型在已知與未知攻擊場景下的表現差異 [33]。

結果顯示，監督式模型（如 MLP 與 CNN）雖能在已知攻擊上達到非常接近百分之百的準確率，但在未知攻擊上 recall 嚴重下降，顯示其對新型威脅的適應性不足；反而是像 OCSVM 與 LOF 等非監督方法展現出較高的泛化性，其中 OCSVM 在未知攻擊測試集上 F1-score 達 0.7575，其訓練於正常樣本的邊界學習策略對於偵測未見樣本相比其他類型模型更加優秀。

爲了能夠同時分類異常攻擊的類別與偵測未知，Verkerken 等人提出利用多階段的偵測方法 [3]。該架構首先利用二元分類器判斷異常，針對被判定爲異常的流量再進一步透過多分類模型辨識其具體攻擊類別。爲了避免多分類將未知攻擊強行判爲已知類別，作者在最後新增一層檢查，根據分類器輸出的信心分數或特徵空間距離進行可信度估計，當判別結果低於閾值時將樣本視爲「未知攻擊」。此種設計結合了分類器與開放式辨識的機制，在已知攻擊辨識與未知攻擊偵測之間取得折衷，然而其在論文中測試的未知類別僅有一種，泛化性較難以確定。

綜上所述，異常重建（如 VAE）、極值建模（如 OpenMax）、以及多階段分類架構等，皆爲當前因應未知攻擊挑戰的重要研究方向。本研究亦延續此脈絡，提升模型在實際網路場域中對未知攻擊的敏感度與效能。

三、 解決方法架構

本研究提出一個兩階段的入侵偵測架構，如圖 3.1 所示，結合監督式分類與非監督式異常偵測方法，以同時滿足已知攻擊分類與未知攻擊偵測兩項核心需求。本章將首先說明整體架構設計動機，接著依序介紹第一階段分類模型與第二階段未知偵測模型之建構方式。

在實際網路入侵偵測的部署情境中，系統往往同時面臨兩個本質上不同且具有張力的需求：一方面，對於訓練階段已知的攻擊類型，系統需能提供穩定且具體的多分類結果，以利資安人員進行後續分析與事件回應；另一方面，對於未曾出現在訓練資料中的未知攻擊，系統亦需具備辨識異常行為的能力，以降低潛在風險。

然而，單一監督式分類模型通常假設測試資料與訓練資料來自相同的類別分佈，當未知攻擊出現時，模型往往會以高信心將其強制歸類為某一已知類別。相對地，若僅採用異常偵測模型進行正常與異常的二元判斷，雖可提升對未知樣本的敏感度，卻難以提供具體的攻擊類型資訊，且在實務部署中常伴隨較高的誤報率。

基於上述觀察，本研究並未嘗試以單一模型或階段處理已知分類與未知偵測兩項任務，而是將其明確拆解為兩個階段，分別對應不同的決策目標，以形成一個更具穩定性與實用性的兩階段入侵偵測流程。

本研究之偵測流程設計以實際入侵偵測情境中的風險特性為出發點。由於惡意攻擊在實際環境中往往刻意模仿正常通訊行為，因此在監督式模型的特徵空間中，未知攻擊更可能與正常流量產生高度重疊，本研究將未知攻擊偵測定位為對正常判斷結果的補充檢查，而非作為分類流程中的前置決策步驟。透過此設計，系統得以在維持已知分類穩定性的同時，針對被判定為正常但具有潛在風險的樣本進行更細緻的分析，提升整體偵測流程於實務應用中的可行性與可靠性。

本研究提出的入侵偵測系統雙階段架構，可表示為：

$$f(x) = \begin{cases} f_{\text{cls}}(x), & \text{if } x \in \mathcal{D}_{\text{known}} \\ f_{\text{OOD}}(x), & \text{if } f_{\text{cls}}(x) = \text{normal} \end{cases} \quad (3.1)$$

其中，各符號定義如下：

- $\mathbf{x}$ ：輸入之網路流量樣本（經影像化轉換後的圖像）。
- $\mathcal{D}_{\text{known}}$ ：訓練時已知的異常類別。
- 若 $f_{\text{cls}}(\mathbf{x}) \neq \text{normal}$ ，則為已知攻擊，輸出其對應類別。
- 若 $f_{\text{cls}}(\mathbf{x}) = \text{normal}$ ，則進入第二階段進行異常偵測。
- $f_{\text{OOD}}(\cdot)$ ：PCA Residual-based 未知攻擊偵測器，其輸出為：

$$f_{\text{OOD}}(\mathbf{x}) \in \{\text{normal}, \text{unknown attack}\}$$



3.1 整體流程概述

本研究將整體流程依照圖 3.1 之結構切分為四個主要步驟，如下所示：

1. 步驟一：資料前處理與圖像轉換

本研究將原始網路流量特徵轉換為影像表示，其主要用意並非單純視覺化，而是為了解決原始流量特徵在高維的空間中缺乏結構性表示的問題。影像化轉換後原本獨立的數值型特徵可被重新建構為具固定的結構，使模型能夠同時學習多個特徵與區塊之間的關聯關係。

此外，該轉換方式亦能與後續所採用之 Vision Transformer 架構相互對齊，使模型得以利用其全局關聯建模能力，捕捉流量在時間與上下文層面上的潛在模式，進而提升對正常行為與異常行為差異的辨識能力。因此本研究首先針對網路流量資料進行前處理，包括欄位選擇、特徵標準化、流量整合成圖片等操作。隨後將固定數量的流量映射成 RGB 圖像，使模型能夠利用影像來學習流量模式。

2. 步驟二：ViT 多分類模型訓練

使用已知攻擊類別與正常流量所轉換之圖像，訓練 ViT 作為多分類模型。

3. 步驟三：OOD 分類器建構

針對訓練資料中的正常樣本，透過前述的 ViT 提取特徵後分群與取樣並採用 PCA Residual 的方法，作為未知攻擊判斷依據。

4. 步驟四：整合偵測機制

最終偵測流程將 ViT 多分類器與 OOD 分類器進行整合。若 ViT 將流量判定為某已知攻擊類別，則輸出已知的攻擊類型；若 ViT 預測為正常樣本，則進一步交由 OOD 分類器進行異常評估。當異常分數超過預設閾值時，樣本被視為未知攻擊，否則視為真正正常流量。




圖 3.1: 本研究之 Proposed Method

3.2 資料處理與圖像轉換

由於 CICIDS2017 與 CICIDS2018 資料集包含超過 70 種以上的特徵且包含不同型態，其中許多具有高度相關或是不具判別力的特徵，若全部使用將導致模型準確度下降。因此本研究需要先經過前處理與特徵選擇，而為了更有效捕捉網路流量在時間與上下文關係中的潛在模式，本研究將篩選後的特徵數值轉換為固定大小的影像資料。數值縮放並轉換圖像的方法主要借鑑 Ho 等人 [24] 的研究，具體流程如下：

1. 原始流量讀取：讀取資料集中每天以 CSV 格式存放的流量特徵。
2. 特徵選擇：本研究採用遞迴特徵刪除與交叉驗證 (RFECV) 搭配 XGBoost 作為代理模型的方法，來篩選出具判別能力的特徵後再統一轉換為圖像進行訓練。

本研究選擇遞迴特徵刪除與交叉驗證 (Recursive Feature Elimination with Cross-Validation, RFECV) 作為特徵選擇方法，主要考量其能在模型訓練過程中同時評估特徵組合對分類效能的實際影響。相較於僅依賴單一統計指標（如相關係數或 Information Gain）的特徵選擇方法，RFECV 能考量特徵之間的交互關係，並透過交叉驗證評估不同特徵子集的穩定性，降低過度擬合的風險，使所選特徵更具實用性。

此外與逐步式特徵選擇方法（如 Sequential Forward Selection, SFS 與 Sequential Backward Selection, SBS）相比，RFECV 能在每一輪特徵刪除過程中皆以交叉驗證評估整體分類效能，能降低逐步貪婪選擇可能導致的局部最佳化問題，進一步提升特徵選擇結果的穩定性與可重現性。

3. 數值縮放：為了將數值特徵映射至 RGB 顏色空間，本研究將每個特徵 x_i 經線性縮放轉換至 $[0, 0xFFFFFFFF]$ 範圍，其轉換公式如下：

$$\tilde{x}_i = \text{round} \left((0xFFFFFFFF) \times \frac{x_i - \min(X)}{\max(X) - \min(X)} \right) \quad (3.2)$$

4. 構成同一張圖像：流量的每個特徵依據縮放後的數值依序對應到一個 RGB 像素點，由左至右填入一個橫排，並如此多筆流量就能構成一張圖像。

5. 標記圖像標籤：若構成同一張圖的連續流量中有異常則標記為異常。




圖 3.2: 不同類別流量轉換後之 RGB 影像示例。

此轉換方式的主要目的在於提供 Vision Transformer 能直接處理的輸入格式，利用模型強大的全局關聯機制，捕捉流量間潛在的關係以提升準確率。

3.3 訓練 ViT 多分類模型

實際部署中除了能夠對異常行為即使提出警報之外，能夠確切地指出可能的攻擊或惡意行為才能夠更好的幫助資訊人員進行應對，因此第一階段會訓練一個能夠分類正常與已知異常的分類器。本研究採用 ViT 作為基礎分類模型，其利用自注意力機制捕捉圖像各區塊可能的潛在相關行為，符合將具有時間關係的資料轉為圖像的做法所合適的模型。ViT 的輸入影像首先被劃分為 $P \times P$ 的 patch，並轉換為向量嵌入，接著經過多層 Transformer Encoder 最終輸出分類結果。




圖 3.3: Vision Transformer (ViT) 架構示意圖，取自 Dosovitskiy et al. [2]

- 爲了加速模型收斂並提升對圖像特徵的學習效果，本研究採用遷移學習的方法，採用 ImageNet 預訓練的模型權重初始化，並在本研究資料集上進行整體再訓練。
- 使用交叉熵損失函數（Cross-Entropy Loss）作爲分類模型的訓練目標，其定義如下：

$$\mathcal{L}_{cls} = - \sum_{i=1}^C y_i \log(\hat{y}_i) \quad (3.3)$$

其中 C 表示分類問題中的類別數量， i 爲類別索引， y_i 表示真實標籤的指示變數（one-hot encoding）， $\hat{y}_i$ 則表示模型對第 i 類別所預測的機率。

3.4 建構 OOD 分類器

訓練時已知的攻擊通常模型都能有效偵測，而未見過的未知異常類型是對入侵偵測系統的最大威脅，本研究爲了處理可能混入正常類別的未知類別，將進一步建構一個 OOD 分類器，從第一階段被分類爲正常的樣本中篩選出可能的未知攻擊。而本研究用的方法是特徵提取後分群、取樣後搭配 PCA Residual 進行異常偵測

1. 特徵抽取：使用第一階段訓練完成的 ViT-B/16 分類器，去除分類頭後抽取影像的特徵向量。給定一張輸入影像 $x \in \mathbb{R}^{H \times W \times C}$ ，其中 H 、 W 與 C 分別表示影像的高度、寬度與通道數。本研究透過特徵提取器 $f_{\theta}(\cdot)$ 將輸入影像 x 映射爲一個 d 維的特徵向量表示。

$$\mathbf{z} = f_{\theta}(x), \quad \mathbf{z} \in \mathbb{R}^d. \quad (3.4)$$

2. 分群 (Clustering)：正常流量中可能存在多種行為模式，本研究針對正常樣本的特徵向量 $\mathbf{z}$ 採用 K-means 演算法進行分群，每一個正常樣本 x_i 會被指派至一個群集 C_j ，使得群內樣本在特徵空間中的距離最小化，形成多個相對一致的正常子分布供後續 PCA 子空間建模使用。

3. 相似度計算與取樣：即使是正常流量也具有多種不同的行為模式，如果用全部的正常流量去建構一個主子空間會導致過度壓縮，反而不利於整體效果，因此先將正常樣本先透過 K-Means 進行分群後進行取樣，並且各自建立子空間，當測試樣本被分類為正常時會投影到最接近的那個群的子空間，並根據誤差值判斷為正常或未知攻擊。

在每個正常樣本群集中，利用歐幾里得距離 (Euclidean distance) 計算樣本間的群內平均相似度，並依據相似度進行取樣。給定一個由 n 筆正常樣本所構成之群集 $C = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ ，其中每一 $\mathbf{x}_i \in \mathbb{R}^d$ 為經 ViT 萃取之特徵向量，則樣本 $\mathbf{x}_i$ 之群內平均距離定義為：

$$d_{\text{avg}}(\mathbf{x}_i) = \frac{1}{|C| - 1} \sum_{\substack{\mathbf{x}_j \in C \\ j \neq i}} \|\mathbf{x}_i - \mathbf{x}_j\|_2. \quad (3.5)$$

4. PCA 殘差計算 (Residual Score)：異常偵測：透過 ViT 提取特徵後利用 PCA 降維方法建構出正常樣本低維潛在分布，並且進一步結合分群等方法計算樣本到該群空間的距離來判斷是否不屬於正常類別。

給定一筆樣本 $\mathbf{x}$ ，其在 PCA 主子空間中的投影可表示為：

$$\hat{\mathbf{x}} = \mathbf{U}_k \mathbf{U}_k^T \mathbf{x}, \quad (3.6)$$

其中 $\mathbf{U}_k$ 表示由前 k 個主成分所組成的投影矩陣。樣本之重建殘差定義為：

$$\mathbf{r} = \mathbf{x} - \hat{\mathbf{x}}, \quad (3.7)$$

並以其 l_2 範數作為未知攻擊偵測的評分指標：

$$\text{ResidualScore}(\mathbf{x}) = \|\mathbf{r}\|_2. \quad (3.8)$$

當樣本 $\mathbf{x}$ 的殘差值超過預設閾值 τ 時，即視為未知攻擊：

$$\text{Label}(\mathbf{x}) = \begin{cases} \text{normal}, & \text{if } \text{ResidualScore}(\mathbf{x}) \leq \tau \\ \text{unknown attack}, & \text{if } \text{ResidualScore}(\mathbf{x}) > \tau \end{cases} \quad (3.9)$$

此外，選擇 PCA 子空間作為未知攻擊偵測機制，亦基於其在流量偵測應用中所具備的計算效率與部署優勢。在推論階段，未知偵測僅涉及特徵向量至低維子空間的線性投影與殘差計算，無需額外的深度模型推論過程，使其在高流量且需即時反應的網路環境中具有較低的計算負擔。相較於需額外訓練生成模型或進行高維距離計算的異常偵測方法，PCA Residual-based 方法能在維持偵測能力的同時，有效降低系統整體運算複雜度，進一步提升所提出兩階段架構於實務部署情境中的可行性。

3.5 結合已知分類與未知檢測

為了整合兩階段模型的偵測結果並提供一個清晰且全面的判斷流程，本研究設計了以下的系統輸出邏輯：

- 若樣本被分類為已知攻擊類型 → 輸出相應攻擊標籤。
- 若樣本被分類為正常 → 分配至最靠近的正常群類。
- 投影至該正常群的主子空間並且計算投影前後的誤差值。
- 根據設定的閾值判斷為正常或是未知攻擊

Algorithm 3.1 Two-Stage Image-based NIDS with Clustered PCA-Residual OOD Detection

Require: Dataset $\mathcal{D}$; window size m ; image size (H, W) ; trained ViT classifier $g(\cdot)$; feature extractor $f(\cdot)$; number of clusters K ; golden ratio α ; percentile p

Ensure: Known-class predictions and unknown attack detection

Stage 0: Flow-to-Image Preprocessing

- 1: Convert network flows into images using time-ordered windows of size m
- 2: Assign image labels as Normal or Known Attack
- 3: Split dataset into training, validation, and test sets
- 4: Reserve one attack class as Unknown for testing only

Stage 1: Known-Class Classification

- 5: Train ViT classifier $g(\cdot)$ on Normal and known attack classes
- 6: Remove classification head to obtain feature extractor $f(\cdot)$

Stage 2: OOD Model Construction (Normal Data Only)

- 7: Extract features $\mathbf{z}_i = f(\mathbf{x}_i)$ for all normal samples
- 8: Apply K-means clustering to obtain clusters $\{C_1, \dots, C_K\}$
- 9: **for** each cluster C_k **do**
- 10: **for** each feature $\mathbf{z}_i \in C_k$ **do**
- 11: Compute average intra-cluster distance $d_{\text{avg}}(\mathbf{z}_i)$
- 12: **end for**
- 13: Sort samples in descending order of $d_{\text{avg}}(\cdot)$
- 14: Select top $\lceil \alpha |C_k| \rceil$ samples as golden samples
- 15: Build PCA subspace $\mathbf{U}_k$ using golden samples
- 16: Compute residuals of normal samples and set threshold τ_k as p -th percentile
- 17: **end for**

Inference

- 18: **for** each test image $\mathbf{x}$ **do**
 - 19: Predict label $\hat{y} = g(\mathbf{x})$
 - 20: **if** $\hat{y} \neq \text{Normal}$ **then**
 - 21: Output $\hat{y}$
 - 22: **else**
 - 23: Extract feature $\mathbf{z} = f(\mathbf{x})$
 - 24: Assign $\mathbf{z}$ to nearest cluster C_k
 - 25: Project $\hat{\mathbf{z}} = \mathbf{U}_k \mathbf{U}_k^\top \mathbf{z}$
 - 26: Compute residual $r = \|\mathbf{z} - \hat{\mathbf{z}}\|_2$
 - 27: **if** $r > \tau_k$ **then**
 - 28: Output Unknown Attack
 - 29: **else**
 - 30: Output Normal
 - 31: **end if**
 - 32: **end if**
 - 33: **end for**
-

四、實驗結果

本章驗證本研究所提出之入侵偵測框架的有效性，整體實驗設計可分為兩大主軸：

1. 整體效能比較實驗此部分將本研究提出的完整框架與三種代表性方法進行比較。所有方法皆在相同的資料集下進行測試，以公平地評估本研究在未知攻擊偵測上的整體效能與相對優勢。
2. 消融實驗（Ablation Study）消融實驗分析本研究框架中各個關鍵組件的必要性與貢獻。本研究透過逐一比較特定部分，觀察其對最終偵測效能的影響。此部分包含以下三項子實驗：
 - 影像化策略分析：比較「保留時間上下的連續流量影像」與「隨機打散流量組成的影像」兩種設計，以驗證上下文資訊是否能提升模型對攻擊模式的辨識能力。
 - 正常樣本分群策略分析：比較「使用 K-means 分群建構」與「不分群僅使用單一分布」的效果，評估分群是否能有效避免模型過度擬合正常行為，並提升未知攻擊辨識能力。
 - 取樣選擇策略分析：探討在分群後選取不同代表性樣本（例如群集邊界樣本）建立 PCA 子空間對最終偵測效能的影響，分析取樣策略在 OOD 檢測中的重要性。

透過上述兩大主軸之實驗設計，本章將從整體效能與內部結構兩個面向，全面性地評估本研究的方法表現，並深入解析其運作機制與設計合理性。

4.1 資料集介紹

近年來，加拿大網路安全研究中心（Canadian Institute for Cybersecurity, CIC）所建構之 CICIDS2017 與 CICIDS2018 資料集因其以真實企業網路環境為基礎進行設計，能完

整模擬現代網路中之多樣化攻擊行為，並提供具備時間上下文關係之連續流量與完整標註，已被廣泛應用於入侵偵測系統相關研究中。

CIC 之官方研究指出，既有多數入侵偵測資料集（如 DARPA、KDD 與 NSL-KDD）普遍存在攻擊類型老舊、流量多樣性不足、標註不完整或過度匿名化等問題，難以真實反映現代企業網路所面臨之實際威脅情境。為改善上述限制，該研究依據攻擊多樣性、流量完整性、協定支援、標註品質與中繼資料等十一項評估標準，設計並建立 CICIDS2017 與後續的 CICIDS2018，使其能更貼近真實世界企業環境中的正常行為與攻防互動 [34, 35]。

後續多篇比較研究與綜述文獻亦指出 CICIDS2017 及其延伸版本 CICIDS2018 在資料真實性、攻擊多樣性與實驗可重現性等面向均優於傳統入侵偵測資料集，並已逐漸成為現代入侵偵測系統研究中常用之基準資料集 [18, 19, 36]。基於上述原因，本研究選擇 CICIDS2017 與 CICIDS2018 作為主要實驗資料來源，以驗證所提出方法於真實網路流量環境下之可行性與實用性。

相較於其他公開之網路入侵資料集，CICIDS2017 與 CICIDS2018 具備以下優勢：真實性：資料集由 CIC 所建構，透過完整之企業級網路拓樸與專業攻擊工具產生流量，能真實反映實際網路環境中之正常行為與攻擊活動。

連續性：流量資料依順序連續產生，保留前後流量間之關聯性，適合用於影像化轉換以捕捉時間與空間特徵。

多樣性：涵蓋多種現代常見攻擊類型，包括 DoS、Brute Force、Web 攻擊、Infiltration 與 Botnet 等，能有效評估系統對不同層級威脅之偵測能力。CICIDS2017 資料集涵蓋為期五天（週一至週五）之網路流量，模擬企業環境中的日常運作情境，包含 HTTP、HTTPS、FTP 與 DNS 等正常流量，並於不同日期執行特定攻擊場景，使研究者能針對各類攻擊行為進行具情境性的分析。

相較之下，CICIDS2018 延續 2017 版本之設計理念，進一步擴充為十天的網路流量資料，並採用更為複雜之企業級網路架構，包含多個子網路與物聯網設備，使整體流量行為與攻擊情境更貼近現代大型企業環境，在多樣性與真實性方面亦更為完善。

4.2 實驗環境與設置

4.2.1 硬體與軟體環境

本研究的實驗環境配置如表 4.1 所示。系統作業環境為 Linux Kernel 6.14.0-29，處理器採用 AMD Ryzen 9 9950X（16 核心 32 執行緒），並搭配 NVIDIA GeForce RTX 5090 顯示卡與 CUDA 12.8。實驗程式主要以 Python 3.12.11 撰寫，並使用 PyTorch 2.9.0 (cu128) 與 TensorFlow 2.20.0 作為深度學習框架。

表 4.1: 實驗環境系統配置

項目	規格
作業系統 (OS)	Linux Kernel 6.14.0-29 (x86_64, glibc 2.39)
CPU	AMD Ryzen 9 9950X (16 Cores / 32 Threads)
GPU	NVIDIA GeForce RTX 5090 (CUDA 12.8)
Python	3.12.11 (Anaconda, GCC 11.2.0)
PyTorch	2.9.0 (cu128)
TensorFlow	2.20.0

4.2.2 資料集與前處理

本研究使用 CICIDS2017 與 CICIDS2018 作為主要實驗資料集，其涵蓋多種常見的網路攻擊類型（如 DDoS、DoS、Brute Force、Infiltration 等）及正常流量，以模擬真實企業網路環境。經過資料前處理與影像化轉換後，各類別所對應之樣本數統計如表 4.2 與表 4.3 所示，樣本過低的如 CICIDS2017 的 Infiltration、CICIDS2018 的 Web Attack 不記錄準確率，其餘樣本不足則可透過過採樣的方法緩解樣本不足。

- 特徵選擇：使用遞迴特徵刪除 (Recursive Feature Elimination, RFE) 搭配 XGBoost 作為代理模型，從官方文檔的原始特徵中篩選出具判別能力的特徵集合。
- 數值轉換：篩選後的數值特徵進行線性縮放至 $[0, 0xffffffff]$ 範圍，對應至一個像素點的 RGB 值。
- 影像化：將固定時間窗口內的多筆流量依序映射為 $H \times W \times 3$ 的影像，保留封包的時序性與上下文資訊。

- 標籤規則：若同一張圖像內出現任一筆攻擊流量，則該圖像標記為「攻擊」，都沒有則此圖標記為「正常」，最後產生對應的圖片集。

表 4.2: CICIDS2017 轉圖像後樣本數

類別 (Label)	樣本數 (Flows)
Normal	82250
Brute-force	4954
DoS	16491
Web Attack	1089
Infiltration	36
Botnet	839
DDoS	5867
Portscan	6968

表 4.3: CICIDS2018 轉圖像後樣本數

類別 (Label)	樣本數 (Flows)
Normal	499138
Brute-force	15322
DoS	42969
Web Attack	73
Infiltration	11121
Botnet	11839
DDoS	65021

4.2.3 第一階段:ViT 模型訓練設置

在模型訓練設置方面，本研究採用 Vision Transformer (ViT-B/16) 作為基礎分類器，輸入影像大小縮放為 $224 \times 224 \times 3$ 。圖像化資料集，每次選一種作為未知攻擊樣本，僅於測試階段使用以模擬開放集場景。在 CICIDS2018 的資料集中由於正常流量 (label 0) 數據量遠大於其他類別，特別進行 70% 下採樣，僅保留 30% 用於模型訓練，以避免樣本嚴重不平衡。

影像資料在載入時經過標準的 ImageNet 預處理流程：縮放至 224×224 ，並正規化為 $\text{mean}=[0.485, 0.456, 0.406]$ 、 $\text{std}=[0.229, 0.224, 0.225]$ 。

在訓練模型方面，損失函數採用交叉熵損失 (Cross-Entropy Loss)，最佳化方法為 Adam Optimizer，學習率設為 5×10^{-5} 。模型訓練總共進行 5 個 epoch，batch size 設為

64。訓練過程中將模型於每個 epoch 儲存檢查點，並在中斷時自動載入最新權重以繼續訓練，訓練參數如表4.4。

在驗證階段除計算整體準確率與平均損失外，本研究亦報告各類別的分類準確率，以觀察模型在不平衡數據下的表現。同時，針對未知類別樣本，則統計其在已知類別下的分類分布，以分析模型對未知攻擊的誤分類傾向。

表 4.4: 模型訓練設置參數

項目	設定值
基礎模型	Vision Transformer (ViT-B/16)
輸入大小	$224 \times 224 \times 3$
未知類別	不同攻擊輪流測試，其餘做為已知類別
攻擊數據切分	70% 訓練，20% 驗證 10% 測試，未知類別不加入
預處理	ImageNet 標準化 (mean, std)
損失函數	Cross-Entropy Loss
最佳化器	Adam (learning rate = 5×10^{-5})
訓練週期	5 epoch
Batch size	64
檢查點機制	每 epoch 儲存模型

4.2.4 第二階段：未知攻擊檢測實驗設置

在第二階段的未知攻擊檢測實驗中，本研究採用了 PCA residual analysis，並設計了分群和取樣的選擇策略以提升對未知攻擊的辨識能力。包含以下步驟：

1. 特徵抽取：使用第一階段訓練完成的 ViT-B/16 分類器，去除分類頭後抽取影像的特徵向量。
2. 分群（**Clustering**）：對正常樣本進行 K-means 分群（本實驗設定群數 $k = 9$ ），以模擬不同正常流量模式，並確保後續 PCA 建模能對應相似的子分布。
3. 相似度計算與取樣：在每個正常樣本群集中，利用歐幾里得距離（Euclidean distance）計算樣本間的群內平均相似度，並依據相似度進行取樣。給定一個由 n 筆正常樣本所構成之群集

4. **PCA 殘差計算 (Residual Score)**：爲了捕捉正常樣本在特徵空間中的主要變化模式，本研究以前面提到的方法選取之樣本建立 PCA 主子空間。

由於未知攻擊在特徵分佈上通常無法被正常樣本所形成的主子空間有效表示，其投影後將產生較大的重建殘差。因此本研究以正常樣本殘差分佈的 95th 百分位數作爲判斷閾值，當樣本的 Residual Score 大於該閾值時，即判定其爲未知攻擊。此設計能在控制正常樣本誤判率的同時，提升對未知攻擊的敏感度，實驗設置如表4.5。

表 4.5: 第二階段未知攻擊檢測實驗設置

項目	設定值
特徵抽取模型	第一階段訓練後的 ViT-B/16
分群方法	K-means
分群數 (k)	9
sample 策略	Low-to-High (分佈邊界樣本)
sample 比例	50%
判斷閾值	正常樣本 residual 的 95 th 百分位數
判斷標準	$\text{ResidualScore}(\mathbf{x}) > \tau$ 判爲異常

4.2.5 評估指標

爲了評估本研究方法在未知攻擊偵測上的效能，本研究採用以下指標：

- **Recall (True Positive Rate, TPR)**：衡量模型在架構中，未知攻擊能夠準確被辨識爲未知類別的比例：

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **TPR@5%FPR**：特別針對異常偵測模組中未知攻擊偵測的性能指標，定義爲在假陽率 (FPR) 控制於 5% 時，模型對未知攻擊的召回率 (TPR)。公式如下：

$$\text{TPR@5\%FPR} = \max\{\text{TPR} \mid \text{FPR} \leq 0.05\}$$

4.3 實驗與其他方法比較

4.3.1 模型結果

本節展示了模型在 CICIDS2017 資料集下的初步分類結果，如表4.6與表4.7所示。

表 4.6: CICIDS2017 七種攻擊類別輪流作為 Unknown 時的分類結果：主對角線為 Unknown Recall(異常偵測模組 @5%FPR (%) 設定下)，非對角線為各已知類別的分類準確率 (%)，Normal 固定為已知類別。

Held-out \ Class	Normal	DoS	DDoS	PortScan	WebAtk	BruteForce	Botnet	unknown attack
DoS	0.99	—	1.00	1.00	0.98	1.00	0.90	0.94
DDoS	1.00	1.00	—	1.00	0.99	1.00	0.91	1.00
PortScan	0.99	1.00	1.00	—	0.99	1.00	0.92	1.00
WebAtk	0.99	1.00	1.00	1.00	—	0.99	0.91	0.70
BruteForce	0.99	1.00	1.00	1.00	0.98	—	0.91	0.67
Infiltration	1.00	1.00	1.00	1.00	0.98	1.00	0.92	0.24
Botnet	0.99	1.00	1.00	1.00	0.99	1.00	—	0.28

註：主對角線為 Unknown Recall，非對角線為該設定下的 per-class Accuracy 而 Infiltration 因樣本過少而不加入已知類別只做未知測試。

表 4.7: CICIDS2018：攻擊類別輪流作為 Unknown 的分類結果。主對角線為 Unknown Recall(異常偵測模組 @5%FPR (%) 設定下) 其餘為各已知類別的分類準確率 (%)。Normal 永遠作為已知類別。

Held-out \ Class	Normal	DoS	DDoS	BruteForce	Infiltration	Botnet	unknown recall@5FPR
DoS	0.98	—	1.00	1.00	0.92	0.99	0.82
DDoS	0.98	1.00	—	1.00	0.95	0.99	0.70
WebAtk	0.97	0.99	1.00	1.00	0.95	0.99	0.61
BruteForce	0.97	1.00	1.00	—	0.92	0.99	0.98
Infiltration	1.00	1.00	1.00	1.00	—	0.99	0.17
Botnet	0.98	1.00	1.00	1.00	0.95	—	0.62

註：主對角線為 Unknown Recall，非對角線為該設定下的 per-class Accuracy 而 web attack 因樣本過少而不加入已知類別只做未知測試。

4.3.2 方法比較

得益於目前成熟的模型以及辨識方法，在已知異常的情況下觀察到只要有足夠多的樣本訓練通常都能達到較好的結果，而未知偵測則不然，因此本研究將重點放在驗證研究方法在未知攻擊偵測上的有效性。本文將結果與三篇具代表性的未知攻擊研究進行比較，分別為 Hindy 等人 [31]、Verkerken 等人 [3] 以及 Chen 等人 [4]。這些近幾年的

文獻各自使用不同的模型和架構提出一套偵測未知攻擊的方法，並且都有在網路上公開他們的程式碼。

因此爲了公平比較，本研究下載上述文獻的公開程式碼，並在固定實驗環境下進行實驗。然而由於實驗條件（如特徵前處理、資料集與切割不同、隨機種子設定、程式碼實作框架等）與原作者報告的環境不完全一致，所得到的結果可能會與其原本在論文中的數據略有差異。

- **Hindy et al. (2020) [31]**：採用自編碼器 (Autoencoder) 進行異常檢測，主要以重建誤差判斷未知攻擊，在幾年前就提出具備未知偵測能力的簡單架構，訓練容易且只需要正常流量即可，但表現相對受限且面對已知攻擊時效果也等同於未知。
- **Verkerken et al. (2023) [3]**：提出一個結合 OCSVM 與 Random Forest 之回流式三階段入侵偵測架構，首先用正常的流量去訓練 One-Class SVM 並將異常送入第二階段，接下來使用已知的攻擊類型訓練隨機森林模型完成已知異常多分類任務並且透過設定閾值的方法將低信心的樣本重新根據第一階段的結果，確認最後應該要分類到良性或是未知攻擊。




圖 4.1: 本圖爲根據 Verkerken et al. (2023) [3] 所提出之三階段入侵偵測流程重新繪製。

- **Chen et al. [4]**：提出一個基於預設閾值分流篩選和非已知攻擊類別流量離群點監

測的未知攻擊檢測策略，同樣先透過轉圖像的方法之後使用 Swim Transformer 進行已知攻擊的多分類，並且透過設定閾值的方法將低信心的歸類為 others(其他)類別，接著透過 Efficientnet 當作特徵提取器提取正常樣本的特徵並搭配分群與 LOF 方法偵測未知攻擊




圖 4.2: 本圖為根據 Chen et al. 提出的兩階段偵測重新繪製的流程圖 [4]

從四張表 4.8 4.9 4.10 4.11 可以觀察到，本研究所提出的基於 ViT 圖像的流量分類與良性流量特徵分群 topn-PCA 殘差計算的未知攻擊檢測策略在多數攻擊類別下的未知攻擊 Recall 均優於或接近現有方法，特別是在 DoS 與 PortScan 類別上表現顯著提升，在 CICIDS2017 的測試上分別達到 0.94 與 1.00 的檢測率。

相比之下，Hindy et al. (2020) 的自編碼器方法在某些異常類別下偵測效果明顯不夠敏銳（如 Botnet, Infiltration）。而 Chen et al. 的方法原先是在 Virus-MNIST 上做測

表 4.8: 不同比較對象在異常偵測模組設定 5% FPR 下，各攻擊類別之未知攻擊整體 Recall 比較 (CICIDS2017)

攻擊類別 (Unknown)	[31]	[3]	本研究
Brute Force	0.47	0.95	<u>0.67</u>
DoS	0.88	<u>0.89</u>	0.94
Web Attack	0.06	<u>0.11</u>	0.70
Infiltration	<u>0.24</u>	0.87	0.24
Botnet	<u>0.10</u>	0.01	0.28
DDoS	<u>0.99</u>	0.95	1.00
Portscan	0.24	<u>0.52</u>	1.00
平均 (Mean)	0.42	<u>0.61</u>	0.69

註：表中數值為在異常偵測模組設定 5% FPR 下，整體兩階段系統之未知攻擊 Recall (%)。

表 4.9: Chen et al. 方法於各未知攻擊類別的未知攻擊準確率與 FPR 比較 (CICIDS2017)

攻擊類別 (Unknown)	Unknown Accuracy	FPR
Brute Force	0.53	0.52
DoS	0.72	0.72
Web Attack	0.14	0.74
Infiltration	0.10	0.74
Botnet	0.21	0.62
DDoS	0.49	0.74
Portscan	0.97	0.70

註：Chen et al. 方法中 FPR 無法固定控制於 5%，故本表分別列出各未知攻擊類別的 Unknown Accuracy 與實際 FPR。

表 4.10: 不同比較對象在異常偵測模組設定 5% FPR 下，各攻擊類別之未知攻擊整體 Recall 比較 (CICIDS2018)

攻擊類別 (Unknown)	[31]	[3]	本研究
Brute Force	0.47	0.98	0.98
DoS	<u>0.11</u>	0.21	0.82
Web Attack	<u>0.48</u>	0.42	0.61
Infiltration	<u>0.15</u>	0.06	0.17
Botnet	0.01	<u>0.03</u>	0.62
DDoS	0.31	0.80	<u>0.70</u>
平均 (Mean)	0.26	<u>0.42</u>	0.65

註：表中數值為在異常偵測模組設定 5% FPR 下，整體兩階段系統之未知攻擊 Recall (%)。

表 4.11: Chen et al. 方法於各未知攻擊類別的未知攻擊準確率與 FPR 比較 (CICIDS2018)

攻擊類別 (Unknown)	Unknown Accuracy	FPR
Brute Force	0.92	0.71
DoS	0.98	0.76
Web Attack	0.79	0.80
Infiltration	0.57	0.43
Botnet	0.93	0.79
DDoS	0.90	0.89

註：Chen et al. 方法中 FPR 無法固定控制於 5%，故本表分別列出各未知攻擊類別的 Unknown Accuracy 與實際 FPR。

試可能對於 CICIDS 的資料集並不適用，正常的圖片並沒有辦法很好的透過 threshold 的設定從已知的攻擊裡面提取出來因而造成非常高的 FPR，而 Verkerken et al. (2023) 的多階段方法與本研究的設計架構都能夠同時滿足多分類已知攻擊並偵測未知攻擊的效果，綜合數據顯示他們的方法與架構在部分攻擊類別表現較佳，但在某些樣本攻擊上依然有不足之處。

在相同實驗環境下測試資料集提供的所有攻擊類別都測試後，本研究能夠達到整體較優秀的未知攻擊偵測率，顯示所提出的二階段架構搭配圖像化結合分群與 PCA 殘差檢測策略具備良好的泛化能力，而在架構上最大的差異則是由於在資料分布上觀察到第一階段分類器中，多數未知類別中的特徵空間上較接近正常類別，這個結果其實符合實務攻擊可能會盡量模仿正常流量的特性，也代表真正的風險主要來自『被誤判為正常的未知樣本』，因此設計架構時將正常類別在已知類別時便加入訓練，而後從正常類別中進一步偵測未知是更為有效的方法

值得注意的是，雖然整體本方法取得較好的實驗結果，但在少數類別或情況下如 Infiltration 類別，不論是在 CICIDS2017 或是 CICIDS2018 時的未知偵測的效果仍不夠完美。

為了更完整呈現模型在不同誤報預算下的部署可用性，本研究進一步比較在不同固定誤報率 (FPR) 門檻下的未知攻擊偵測表現。由於實務場域常需依告警量與人力負荷調整誤報容忍度，因此除了 5%FPR 外，亦額外報告 3% 與 1%FPR 下之 Unknown Recall (TPR@FPR)，以觀察偵測率在更嚴格誤報限制下的變化趨勢。

由表 4.12 與表 4.13 可觀察到，當 FPR 門檻由 5% 逐步收緊至 3% 與 1% 時，整體偵

表 4.12: 本研究在不同 FPR 門檻（於異常偵測模組設定）下之未知攻擊整體偵測表現（CICIDS2017）。

攻擊類別 (Unknown)	TPR@5%FPR	TPR@3%FPR	TPR@1%FPR
Brute Force	0.67	0.58	0.45
DoS	0.94	0.90	0.82
Web Attack	0.70	0.61	0.48
Infiltration	0.24	0.18	0.09
Botnet	0.28	0.20	0.13
DDoS	1.00	1.00	0.99
Portscan	1.00	0.98	0.98
平均 (Mean)	0.69	0.64	0.56

註：表中數值為整體兩階段系統之未知攻擊 Recall（%），其中 FPR 門檻設定於異常偵測模組。

表 4.13: 本研究在不同 FPR 門檻（於異常偵測模組設定）下之未知攻擊整體偵測表現（CICIDS2018）。

攻擊類別 (Unknown)	TPR@5%FPR	TPR@3%FPR	TPR@1%FPR
Brute Force	0.98	0.93	0.85
DoS	0.82	0.73	0.52
Web Attack	0.61	0.49	0.27
Infiltration	0.17	0.10	0.05
Botnet	0.62	0.44	0.25
DDoS	0.70	0.64	0.53
平均 (Mean)	0.65	0.56	0.41

註：表中數值為整體兩階段系統之未知攻擊 Recall（%），其中 FPR 門檻設定於異常偵測模組。

測率呈現合理下降，反映在更嚴格的誤報限制下，系統需採取較保守的未知告警策略。然而在中多數攻擊類別中，本研究方法仍能維持具實務意義的偵測能力，顯示所提出之策略具有一定的穩定性。

另一方面 Infiltration 類別無論是在已知或是未知設定下，在兩資料集下皆維持相對較低的偵測成功率，推測可能與其行為模式與正常流量高度重疊、以及類別內部變異較大等因素相關。此結果指出：對於高度偽裝且樣本稀少之攻擊型態，僅依賴單一特徵子空間與固定閾值的方法仍可能不足，後續可考慮結合更細緻的時間上下文建模或對比學習方法，以進一步改善對於此類攻擊的偵測能力。



4.4 消融實驗 (Ablation Study)

爲了深入分析所提出方法各個部分所帶來的影響，因此消融實驗 (Ablation Study) 會逐步移除本研究各項實驗組件，並比較在相同實驗條件下對檢測效能的影響。主要探討的面向如下：

4.4.1 影像化策略

本研究將原始網路流量轉換爲影像資料，意在捕捉流量潛在的上下關係，爲了要觀察這種上下關係是否有助於偵測異常因此並特別設計了兩種構成圖片的方式：

- 連續流量圖片：保留流量的順序關係構成圖。
- 隨機流量圖片：將流量隨機排列後轉換爲影像，抹取上下關係。



圖 4.3: CICIDS2017 上連續流量構成的 DDoS 攻擊圖片




圖 4.4: CICIDS2017 上隨機流量構成的 DDoS 攻擊圖片

表 4.14: 影像化策略對已知攻擊分類準確率 (%) 之影響 (CICIDS2017, ViT-B/16)

類別 (Known)	連續流量圖片	隨機流量圖片
Normal	1.00	1.00
DoS	1.00	1.00
DDoS	1.00	1.00
PortScan	1.00	1.00
Web Attack	0.99	0.91
Brute Force	1.00	1.00
Botnet	0.91	0.43

這兩種方法分別在 CICIDS2017 資料集上進行已知攻擊的多分類模型訓練，在實驗環境一樣的情形下查看是否影響準確率。表格中能看到對於某些類別而言會有很明顯的準確率落差，如 **Web Attack** 和 **Botnet** 兩種攻擊，而這兩種攻擊恰好是樣本比較不足的類別，顯示出流量的前後關係能夠幫助模型偵測異常行為，而樣本數不夠多的情況下可能在模型的學習上差距會更加的明顯。

4.4.2 正常樣本分群策略

在正常流量中也可能存在多種不同行爲，如果全部當作同一種正常行爲來看可能會過度擬合，因此本研究在消融實驗章節比較了分群前後對於偵測未知的效果差異

表 4.15: 正常樣本分群與取樣策略對未知攻擊整體偵測表現之影響（於異常偵測模組設定 5% FPR）。

Unknown 類別	不分群	K-means 分群
BruteForce	0.44	0.61
DoS	0.82	0.93
WebAtk	0.52	0.68
Infiltration	0.11	0.16
Botnet	0.28	0.18
DDoS	1.00	1.00
Portscan	0.99	1.00
平均 (Mean)	0.59	0.65

註：數值為整體兩階段系統之未知攻擊 Recall (%)，其中 FPR 門檻設定於異常偵測模組。

值得注意的是，分群策略整體帶來有效提升的同時卻並非對所有類型皆帶來一致提升。如表 4.15 所示，Botnet 類別在分群後的偵測表現反而略有下降。認為此現象可能與 Botnet 流量本身的行爲特性有關。相較於其他攻擊類型，Botnet 通常具有低頻率、長時間且近似正常流量的特徵使其在特徵空間中更容易接近部分正常流量分佈，因此也是未知偵測難度較高的異常類型。

在引入分群後，正常流量被劃分為多個子群並分別建立 PCA 子空間，部分 Botnet 樣本由於本身在特徵空間中就極度接近某一類正常類型，因此可能反而使得在局部子空間中的重建誤差降低，進而影響其異常分數。此結果顯示分群策略雖能有效提升整體未知攻擊的偵測穩定性，但對於行爲模式高度接近正常流量的攻擊類型，仍可能存在辨識上的挑戰。

4.4.3 取樣選擇策略

在分群後建立該群樣本的主子空間，而建立主子空間前若能夠透過良好的取樣方法則能夠更好的辨識異常，因此本研究將群內進行取樣，基於 n-to-n 的方法計算相似度排名，並且測試了不同的取樣選擇方式：

- **High-to-Low** 相似度：選取最具代表性的樣本（相似度從高到低取樣）。
- **Low-to-High** 相似度：選取分布邊界樣本（相似度從低到高取樣）。

表 4.16: CICIDS2017 不同取樣比例下（High-to-Low 相似度策略）未知攻擊偵測效果（TPR@5%FPR, %）。列為攻擊類別，欄為 golden sample 取樣比例。

Unknown 類別	1%	10%	20%	50%	80%	100%
BruteForce	0.37	0.40	0.42	0.45	0.49	0.61
DoS	0.56	0.54	0.53	0.67	0.77	0.93
WebAtk	0.29	0.26	0.26	0.28	0.39	0.68
Infiltration	0.09	0.07	0.07	0.07	0.07	0.16
Botnet	0.03	0.04	0.05	0.03	0.04	0.18
DDoS	0.12	0.19	0.14	0.19	0.63	1.00
Portscan	0.61	0.49	0.50	0.53	0.93	1.00

註：表中數值為各 Unknown 類別於 **Low-to-High** 相似度策略下，不同 golden sample 取樣比例（相對於該群樣本數）所得到的 **TPR@5%FPR**（%）。當比例為 100% 時，即等同於未取樣（使用全部樣本建立 PCA 子空間）。




圖 4.5: CICIDS2017 高到低取樣時在各比例下的偵測率折線圖

表 4.17: CICIDS2018 不同取樣比例下 (High-to-Low 相似度策略) 未知攻擊偵測效果 (TPR@5%FPR, %)。列為攻擊類別，欄為 golden sample 取樣比例。

Unknown 類別	1%	10%	20%	50%	80%	100%
BruteForce	0.95	0.97	0.97	0.97	0.97	0.96
DoS	0.25	0.26	0.26	0.29	0.54	0.79
WebAtk	0.08	0.10	0.11	0.25	0.47	0.51
Infiltration	0.14	0.15	0.16	0.16	0.19	0.17
Botnet	0.49	0.49	0.49	0.50	0.53	0.59
DDoS	0.11	0.09	0.10	0.14	0.31	0.63

註：表中數值為各 Unknown 類別於 **Low-to-High** 相似度策略下，不同 golden sample 取樣比例（相對於該群樣本數）所得到的 TPR@5%FPR (%)。當比例為 100% 時，即等同於未取樣（使用全部樣本建立 PCA 子空間）。




圖 4.6: CICIDS2018 高到低取樣時在各比例下的偵測率折線圖

如表 4.16 與表 4.17 所示，從最經典的樣本開始選取並建立主子空間的策略，在大多數攻擊類別上顯示對偵測的效果不佳，而從另一個觀點來審視準確率是隨著取樣數量一路上升，可以發現加入越多的非經典樣本後反而更能幫助區分未知攻擊，因此這邊

用了另一個方法則是先從非經典的樣本做取樣。

表 4.18: CICIDS2017 不同取樣比例下 (Low-to-High 相似度策略) 未知攻擊整體偵測表現之影響 (於異常偵測模組設定 5% FPR)。列為攻擊類別，欄為取樣比例。

Unknown 類別	1%	10%	20%	50%	80%	100%
BruteForce	0.42	0.66	0.69	0.64	0.61	0.61
DoS	0.41	0.90	0.94	0.94	0.93	0.93
WebAtk	0.25	0.35	0.53	0.70	0.71	0.68
Infiltration	0.01	0.01	0.10	0.23	0.21	0.16
Botnet	0.00	0.07	0.18	0.27	0.21	0.18
DDoS	1.00	1.00	1.00	1.00	1.00	1.00
Portscan	0.52	0.96	0.99	1.00	1.00	1.00

註：表中數值為各 Unknown 類別於 **Low-to-High** 相似度策略下，不同取樣比例 (相對於該群樣本數) 所得到的結果。當比例為 100% 時，即等同於未取樣。




圖 4.7: CICIDS2017 低到高取樣時在各比例下的偵測率折線圖




圖 4.8: CICIDS2018 低到高取樣時在各比例下的偵測率折線圖

表 4.19: CICIDS2018 不同取樣比例下（Low-to-High 相似度策略）未知攻擊整體偵測表現之影響（於異常偵測模組設定 5% FPR）。列為攻擊類別，欄為取樣比例。

Unknown 類別	1%	10%	20%	50%	80%	100%
BruteForce	0.95	0.97	0.97	0.97	0.97	0.96
DoS	0.27	0.65	0.81	0.82	0.82	0.79
WebAtk	0.34	0.59	0.59	0.61	0.55	0.51
Infiltration	0.09	0.13	0.15	0.17	0.17	0.17
Botnet	0.00	0.01	0.44	0.62	0.61	0.59
DDoS	0.21	0.52	0.65	0.67	0.64	0.63

註：表中數值為各 Unknown 類別於 **Low-to-High** 相似度策略下，不同取樣比例（相對於該群樣本數）所得到的結果。當比例為 100% 時，即等同於未取樣。

如表 4.18 與表 4.19 所示，Low-to-High 的策略明顯奏效，顯示更加關注邊界樣本的變化更有助於區分出未知攻擊，根據挑選的比例不同，可以看出挑選約前 50% 的樣本時能夠在整體的未知偵測上取得更加優秀的結果。

4.5 本章小結

本章首先介紹了本研究的實驗環境與資料集設定，並透過兩階段架構驗證了所提出方法的有效性。在第一階段中，使用 Vision Transformer (ViT-B/16) 完成已知攻擊的分類，於 CICIDS2017 與 CICIDS2018 皆能達到不錯的準確率。在第二階段中會檢查第一階段分類為正常的樣本以避免漏網之魚，利用 PCA 殘差結合分群取樣的策略以進行未知攻擊偵測，整體的實驗結果結果顯示：

- 低相似度 (Low-to-High) 的取樣策略能夠提升對未知類別的敏感度；
- 分群策略 (K-means) 能進一步改善模型對多樣正常流量的建模效果並進一步區分未知；
- 圖像化方法對於捕捉流量的上下文關係具明顯幫助。

綜合比較結果，本研究提出的「影像化 + ViT 分類 + 提取特徵 + 分群後取樣 + PCA 殘差偵測」架構，在未知攻擊偵測上的整體表現優於現有方法，證實了所設計流程與方法的有效性與泛化能力。下一章將進一步總結研究成果，並討論未來可延伸的研究方向。

五、 結論與未來工作

5.1 研究挑戰與對應解決策略

本研究於第一章中指出，現有入侵偵測系統在實際應用情境下，主要面臨三項關鍵挑戰：未知攻擊的辨識能力不足、多任務偵測架構難以整合，以及流量上下文特徵未被充分利用。針對上述挑戰，本研究透過整體架構與方法設計加以回應，整體如表5.1所示。

表 5.1: 研究挑戰與本研究之對應解決策略

研究挑戰	本研究之對應解決方式
未知攻擊的辨識能力不足：監督式模型僅能學習已知攻擊類別，而僅依賴異常偵測的方法則通常面臨偵測率不足或誤報率過高的問題。	採用兩階段入侵偵測架構，並在第二階段透過設計的分群與取樣方法搭配基於 PCA 投影誤差的方式進行未知攻擊偵測，使系統具備辨識新型攻擊的能力。
多任務偵測的整合：現有研究多僅聚焦於多分類或異常偵測其中之一，較缺乏能同時輸出已知攻擊類型與未知攻擊判斷的統一架構。	透過雙階段設計，將已知攻擊分類與未知攻擊偵測分離但整合於同一流程中，兼顧分類準確度與未知攻擊偵測能力。
較少關注流量上下文特徵：多數研究將網路流量視為獨立樣本，忽略時間上的關聯性，可能使具連續性行為特徵的攻擊難以有效偵測。	將連續流量轉換彩色影像，使模型能從具時間與上下文結構的表示中學習潛在模式，並利用 Vision Transformer 的全局關聯能力學習潛在流量模式。

5.2 研究貢獻

綜合上述成果，本研究的主要貢獻可歸納如下：

1. 透過 ViT 以捕捉流量圖像化後之全域關係與上下文特徵，使模型能有效學習流量之間的潛在表示，並且引入 K-means 分群建立多個正常子空間，有效提升 PCA 殘差法對不同流量模式的建模能力。
2. 設計基於 Low-to-High 的相似度取樣策略，強化模型對分布邊界樣本的辨識能力，顯著提升未知攻擊的 Recall rate。
3. 於 CICIDS2017 與 CICIDS2018 兩份資料集上進行完整實驗驗證，並與多篇具代表性研究進行比較，證明所提方法在穩定性與泛化性上具競爭力。

5.3 研究限制

雖然本研究提出的影像化雙架構偵測系統，在已知與未知攻擊偵測上皆展現出良好的性能與泛化能力，但在實際應用與設計上仍存在一些限制，需於後續研究中加以改進與注意：

1. 影像化過程：將網路流量特徵轉換為影像雖能保留部分上下文關係，但在特徵選擇與轉換成像素和圖片中若處理不當可能造成部分資訊遺失，可能影響偵測靈敏度。
2. 特徵選取方法的限制：本研究於前處理階段採用 RFECV 搭配代理模型進行特徵選取，其目標在於取得一組具穩定性且具判別能力的特徵組合。然而該方法仍屬於特定模型導向的特徵選擇策略，未必能保證在轉圖像之後對於 Vision Transformer 或不同模型架構下皆為最優特徵組合。此外，特徵選取結果亦可能受到資料分布與代理模型選擇的影響。
3. 分群與取樣策略的敏感性：第二階段中分群數量（ k 值）與取樣比例對最終偵測結果影響顯著，若設定不當可能導致 PCA 子空間偏離正常樣本分布或出現過度擬合。此外，不同資料集的正常流量行為差異也可能使最佳參數不具可遷移性。
4. 已知類別的準確率：由於本研究的設計重點在於引入未知攻擊偵測能力，並未針對已知攻擊分類準確率進行專門的最佳化。此外在實驗過程中觀察到，若模型過

度以提升已知分類效能為主要最佳化目標，可能使特徵空間中的決策邊界趨於緊密，進而影響未知樣本在特徵空間中的結構穩定性。因此，本研究之已知分類表現可能未達現有研究所報告之最高水準。

5. 新類型加入時需要重新訓練：若有發現新型的攻擊要更新架構，則需要重新訓練第一階段的分類器才能夠加入為已知攻擊，若能進一步結合持續學習方法則有望解決這點。

綜上所述，本研究方法雖展現出良好的偵測性能，但在模型資源需求、穩定性與實際部署可行性方面仍需進一步優化，後續研究可針對這些限制設計更具延展性與即時性的改良方案。

5.4 未來研究方向

雖然本研究的實驗結果顯示出所提出方法的可行性，但仍有若干可進一步改進之處。後續研究可從以下幾個方向延伸：

- 模型層面：未來可嘗試結合多層次特徵融合、注意力機制強化或對比學習（contrastive learning）等技術，以進一步提升特徵表示的區辨能力與穩定性，減少高相似度樣本間的混淆。
- 應用層面：未來可將本研究方法與線上監測系統整合，或是設計持續學習機制，讓模型能動態更新對未知樣本的判斷，朝向實際入侵防禦系統的落地應用發展。

綜合而言，本研究提出的影像化與 PCA 殘差結合架構，提供了一種兼具可解釋性與彈性的未知攻擊偵測方式。透過後續在模型泛化與即時性上的持續改進，預期能為智慧型網路防禦提供更穩健的技術支撐。

參考文獻

- [1] IBM Security, “Cost of a data breach report 2025,” IBM Corporation, Armonk, NY, USA, Tech. Rep., 2025. [Online]. Available: <https://www.ibm.com/reports/data-breach>
- [2] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, Vienna, Austria, 2021.
- [3] M. Verkerken, L. D’hooge, D. Sudyana, Y.-D. Lin, T. Wauters, B. Volckaert, and F. D. Turck, “A novel multi-stage approach for hierarchical intrusion detection,” *IEEE Transactions on Network and Service Management*, vol. 20, no. 3, pp. 3915–3928, September 2023.
- [4] Y.-S. Chen, H.-Y. Lien, J.-Y. Li, and C.-Y. Lin, “Detecting unknown attacks: Transformer-based image classifiers with an out-of-distribution detector,” in *Technologies and Applications of Artificial Intelligence (TAAI 2024)*, ser. Communications in Computer and Information Science, W.-T. Chu, C.-Y. Shen, and H.-H. Shuai, Eds. Singapore: Springer, 2025, vol. 2415, pp. 319–329.
- [5] Z. Yang, X. Liu, T. Li, D. Wu, J. Wang, Y. Zhao, and H. Han, “A systematic literature review of methods and datasets for anomaly-based network intrusion detection,” *Comput. Secur.*, vol. 116, p. 102675, 2022.
- [6] P. García-Teodoro, J. Díaz-Verdejo, G. Maciá-Fernández, and E. Vázquez, “Anomaly-based network intrusion detection: Techniques, systems and challenges,” *Computers & Security*, vol. 28, no. 1-2, pp. 18–28, 2009.

- [7] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin, and K.-Y. Tung, "Intrusion detection system: A comprehensive review," *Journal of Network and Computer Applications*, vol. 36, no. 1, pp. 16–24, 2013.
- [8] R. Sommer and V. Paxson, "Outside the closed world: On using machine learning for network intrusion detection," in *Proceedings of the IEEE Symposium on Security and Privacy*, Oakland, CA, USA, 2010, pp. 305–316.
- [9] A. El Mahdaouy *et al.*, "Deep learning for contextualized netflow-based network intrusion detection: Methods, data, evaluation and deployment," *arXiv*, 2026.
- [10] C. Yin, Y. Zhu, J. Fei, and X. He, "A deep learning approach for intrusion detection using recurrent neural networks," *IEEE Access*, vol. 5, pp. 21 954–21 961, 2017.
- [11] N. Shone, T. N. Ngoc, V. D. Phai, and Q. Shi, "A deep learning approach to network intrusion detection," *IEEE Transactions on Emerging Topics in Computational Intelligence*, vol. 2, no. 1, pp. 41–50, 2018.
- [12] L. D. Manocchio, S. Layeghy, W. W. Lo, G. K. Kulatilleke, M. Sarhan, and M. Portmann, "Flowtransformer: A transformer framework for flow-based network intrusion detection systems," *Expert Systems with Applications*, vol. 241, p. 122564, 2024.
- [13] Y. Xue, C. Kang, and H. Yu, "Hae-hrl: A network intrusion detection system utilizing a novel autoencoder and a hybrid enhanced lstm-cnn-based residual network," *Computers & Security*, vol. 151, p. 104328, 2025.
- [14] Verizon, "2025 data breach investigations report (dbir)," Verizon Communications, New York, NY, USA, Tech. Rep., 2025. [Online]. Available: <https://www.verizon.com/business/resources/reports/dbir/>
- [15] D. E. Denning, "An intrusion-detection model," *IEEE Transactions on Software Engineering*, vol. SE-13, no. 2, pp. 222–232, 1987.

- [16] M. Tavallaei, E. Bagheri, W. Lu, and A. A. Ghorbani, "A detailed analysis of the KDD CUP 99 data set," in *2009 IEEE Symposium on Computational Intelligence in Security and Defense Applications (CISDA)*. IEEE, 2009, pp. 1–6.
- [17] M. Ring, S. Wunderlich, D. Scheuring, D. Landes, and A. Hotho, "A survey of network-based intrusion detection data sets," *Computers & Security*, vol. 86, pp. 147–167, 2019.
- [18] I. Sharafaldin, A. H. Lashkari, S. Hakak, and A. A. Ghorbani, "Developing realistic distributed denial of service (ddos) attack dataset and taxonomy," in *2019 International Carnahan Conference on Security Technology (ICCST)*. IEEE, 2019, pp. 1–8.
- [19] M. A. Ferrag, L. Maglaras, S. Moschogiannis, and H. Janicke, "Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study," *Journal of Information Security and Applications*, vol. 50, p. 102419, 2020.
- [20] A. L. Buczak and E. Guven, "A survey of data mining and machine learning methods for cyber security intrusion detection," *IEEE Communications Surveys & Tutorials*, vol. 18, no. 2, pp. 1153–1176, 2016.
- [21] Q. Abbas, S. Hina, H. Sajjad, K. S. Zaidi, and R. Akbar, "Optimization of predictive performance of intrusion detection system using hybrid ensemble model for secure systems," *PeerJ Computer Science*, vol. 9, p. e1552, 2023.
- [22] M. H. Bhuyan, D. K. Bhattacharyya, and J. K. Kalita, "Network anomaly detection: Methods, systems and tools," *IEEE Communications Surveys & Tutorials*, vol. 16, no. 1, pp. 303–336, 2014.
- [23] M. Ahmed, A. N. Mahmood, and J. Hu, "A survey of network anomaly detection techniques," *Journal of Network and Computer Applications*, vol. 60, pp. 19–31, 2016.
- [24] C. M. K. Ho, K.-C. Yow, Z. Zhu, and S. Aravamuthan, "Network intrusion detection via flow-to-image conversion and vision transformer classification," *IEEE Access*, vol. 10, pp. 97 780–97 795, 2022.

- [25] F. Yan, G. Zhang, D. Zhang, X. Sun, B. Hou, and N. Yu, "Tl-cnn-ids: transfer learning-based intrusion detection system using convolutional neural network," *The Journal of Supercomputing*, vol. 79, pp. 17 562–17 584, 2023.
- [26] A. El-Ghamry, A. Darwish, and A. E. Hassanien, "An optimized cnn-based intrusion detection system for reducing risks in smart farming," *Internet of Things*, vol. 22, p. 100709, 2023.
- [27] A. Bendale and T. E. Boulton, "Towards open set deep networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 1563–1572.
- [28] H. Wang, Z. Li, L. Feng, and W. Zhang, "Vim: Out-of-distribution with virtual-logit matching," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 4911–4920.
- [29] G. E. Hinton and R. R. Salakhutdinov, "Reducing the dimensionality of data with neural networks," *Science*, vol. 313, no. 5786, pp. 504–507, 2006.
- [30] D. P. Kingma and M. Welling, "Auto-encoding variational bayes," *International Conference on Learning Representations (ICLR)*, 2014.
- [31] H. Hindy, R. Atkinson, C. Tachtatzis, J.-N. Colin, E. Bayne, and X. Bellekens, "Utilising deep learning techniques for effective zero-day attack detection," *Electronics*, vol. 9, no. 10, p. 1684, Oct. 2020.
- [32] Z. Qiu, D. Zhou, Y. Zhai, B. Liu, L. He, and J. Cao, "VAEMax: Open-set intrusion detection based on openmax and variational autoencoder," in *2024 5th Information Communication Technologies Conference (ICTC)*. IEEE, 2024, pp. 98–105.
- [33] Z. Xu and Y. Liu, "Robust anomaly detection in network traffic: Evaluating machine learning models on cicids2017," *arXiv preprint arXiv:2506.19877*, 2025.
- [34] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward generating a new intrusion detection dataset and intrusion traffic characterization," in *Proceedings of the 4th Interna-*

tional Conference on Information Systems Security and Privacy (ICISSP). SCITEPRESS
– Science and Technology Publications, 2018, pp. 108–116.

- [35] Canadian Institute for Cybersecurity, “Cse-cic-ids2018 dataset,” <https://www.unb.ca/cic/datasets/ids-2018.html>, 2018.
- [36] A. Thakkar and R. Lohiya, “A review of the advancement in intrusion detection datasets,” *Procedia Computer Science*, vol. 167, pp. 636–645, 2020.

