

國立中央大學

資訊工程學系
碩士論文

FINE：基於多模態對比式嵌入學習的細粒度影像
理解方法

FINE: Fine-Grained Image Understanding through
Multimodal Contrastive Embedding Learning

研究生：林澤華

指導教授：林家瑜 博士

中華民國一百一十四年六月

國立中央大學圖書館學位論文授權書

填單日期：114/08/15

2019.9 版

授權人姓名	林澤華	學 號	112525001
系所名稱	資訊工程學系	學位類別	☒ 碩士 ☐ 博士
論文名稱	FINE：基於多模態對比式嵌入學習的細粒度影像理解方法	指導教授	林家瑜教授

學位論文網路公開授權

授權本人撰寫之學位論文全文電子檔：

- 在「國立中央大學圖書館博碩士論文系統」。

() 同意立即網路公開

(☒) 同意 於西元 2030 年 7 月 1 日網路公開

() 不同意網路公開，原因是：_____

- 在國家圖書館「臺灣博碩士論文知識加值系統」

() 同意立即網路公開

(☒) 同意 於西元 2030 年 7 月 1 日網路公開

() 不同意網路公開，原因是：_____

依著作權法規定，非專屬、無償授權國立中央大學、台灣聯合大學系統與國家圖書館，不限地域、時間與次數，以文件、錄影帶、錄音帶、光碟、微縮、數位化或其他方式將上列授權標的基於非營利目的進行重製。

學位論文紙本延後公開申請 (紙本學位論文立即公開者此欄免填)

本人撰寫之學位論文紙本因以下原因將延後公開

- 延後原因

() 已申請專利並檢附證明，專利申請案號：

(☒) 準備以上列論文投稿期刊


() 涉國家機密

() 依法不得提供，請說明：_____

• 公開日期：西元 2030 年 7 月 1 日

※繳交教務處註冊組之紙本論文(送繳國家圖書館)若不立即公開，請加填「國家圖書館學位論文延後公開申請書」

研究生簽名： 

指導教授簽名： 

*本授權書請完整填寫並親筆簽名後，裝訂於論文封面之次頁。

FINE：基於多模態對比式嵌入學習的細粒度影像理解方法

摘要

近年來深度學習技術的快速發展，使得電腦視覺在分類、檢測與分割等任務上取得良好的效果。然而，大多數方法仍高度依賴大量標註資料，尤其對於像是醫療影像分析或工業產品檢測等標註成本高昂的應用場景時，會受到限制。為了降低對人工標註的依賴，非監督式學習 (Unsupervised Learning) 逐漸受到重視，其中對比式學習 (Contrastive Learning) 作為非監督式學習的一種，已被證實能夠有效學習出具判別性的特徵表示。

然而，傳統的對比式學習在面對「微小且細粒度 (tiny and fine-grained)」的資料時仍面對巨大的困難。這種資料通常嵌入在複雜背景中的小型目標，且類別間差異細微，使得模型難以擷取有效特徵，進而影響整體表現。本研究針對此挑戰，提出 FINE: 基於多模態對比式嵌入學習的細粒度影像理解方法，專為「微小且細粒度」資料所設計。我們的方法採用編碼器-解碼器架構來生成輔助影像，強調微小目標區域，從而促使更有效的特徵提取。此外，我們設計了一個多模態對比式特徵提取模組 (Multi-modal Contrastive Learning Feature Extract Block, MCLFE)，整合分支特徵提取模組、注意力模組與特徵融合模組。該模組與對比學習策略共同運作，分別利用 Instance Loss (IL) 與 Center Loss (CL) 來訓練特徵提取器與聚類中心。

在實驗中，我們分別使用一種非公開的產線面板資料集以及四種公開資料集進行比較，其中包含非公開的產線面板資料集 A19、Retina 視網膜資料集 [1]、NEU 鋼鐵表面瑕疵資料集 [2]、MVTec AD 工業異常資料集 [3] 和 CIFAR-10 資料集 [4]。其中，在視網膜資料集上，當提供準確的輔助影像時，我們的方法能顯著提升超過 25% 的分群準確率，突顯其在醫學影像上，處理微小且細粒度方面的有效性。在一般分類資料集上，我們的方法即使僅提升約 4% 的 ARI，仍優於多數主流方法，顯示本方法在無需額外先驗的情況下，亦具備穩定且一致的分群能力。在鋼鐵表面瑕疵資料集中，我們的方法也可以在三個指標下取得最好的效果，證實本方法對於顯著異常亦具備良好的辨識能力。

我們也於工業異常資料集中針對兩種不同型態的瑕疵類別（結構性與紋理性）進行測試。結果顯示，我們的方法在結構性瑕疵上優於所有對照方法，展現其於結構性缺陷分群上的穩定性與辨識力；雖然在紋理性瑕疵中受到紋理型異常與輔助模態限制影響，表現略遜於最佳方法，但整體仍具備一致且具有潛力的分群效果，進一步說明了本方法於多樣化工業瑕疵情境中的應用可能。

最後，在非公開的產線面板資料集上，我們的方法搭配輔助影像後於 NMI、ARI 與 ACC 三項指標上均優於現有方法，雖然各指標提升幅度有限，但整體表現更為穩定，展現出本研究方法於真實工業場景中的實用性與潛力。

關鍵字：無監督學習, 對比式學習, 細粒度分群, 多模態特徵融合

FINE: Fine-Grained Image Understanding through Multimodal Contrastive Embedding Learning

Abstract

In recent years, the rapid development of deep learning techniques has led to significant progress in computer vision tasks such as classification, detection, and segmentation. However, most existing approaches still heavily rely on large amounts of annotated data. This dependency becomes a major limitation in application scenarios where annotation is costly, such as medical image analysis or industrial product inspection. To alleviate the reliance on manual labeling, unsupervised learning has gained increasing attention. Among these methods, contrastive learning—an effective unsupervised approach—has been shown to learn discriminative feature representations successfully.

Nevertheless, conventional contrastive learning methods face significant challenges when applied to "tiny and fine-grained" data. Such data typically consist of small targets embedded in complex backgrounds with subtle inter-class differences, making it difficult for models to extract meaningful features and thereby affecting overall performance. To address this challenge, we propose FINE: Fine-Grained Image Understanding through Multimodal Contrastive Embedding Learning, specifically designed for "tiny and fine-grained" data. Our method adopts an encoder-decoder architecture to generate auxiliary images that emphasize small target regions, thereby facilitating more effective feature extraction.

Additionally, we design a Multi-modal Contrastive Learning Feature Extract Block (MCLFE), which integrates a multi-branch feature extraction module, an attention module, and a feature fusion module. This module, together with a contrastive learning strategy, jointly optimizes the feature extractor and clustering centers using Instance Loss (IL) and Center Loss (CL), respectively.

In our experiments, we evaluate the proposed method on a private industrial panel dataset and four public datasets: the private panel dataset A19, the Retina fundus dataset [1], the NEU

surface defect dataset [2], the MVTec AD industrial anomaly dataset [3], and the CIFAR-10 dataset [4]. On the Retina dataset, our method achieves over a 25% improvement in clustering accuracy when provided with high-quality auxiliary images, demonstrating its effectiveness in handling tiny and fine-grained features in medical imaging. On general classification datasets, our method still outperforms most mainstream approaches by achieving an approximate 4% improvement in ARI, indicating its stable and consistent clustering capability even without additional priors. For the NEU dataset, our method achieves the best performance across all three evaluation metrics, further validating its ability to identify prominent anomalies effectively.

Moreover, we evaluate our method on two distinct defect types—structural and textural—within the MVTec AD dataset. The results show that our method outperforms all baseline approaches on structural defects, showcasing its robustness and discriminative power in clustering structural anomalies. Although its performance on textural defects is slightly inferior to the best-performing method due to the challenges posed by texture anomalies and auxiliary modality limitations, the overall results remain consistent and promising, underscoring the method’s potential in diverse industrial inspection scenarios.

Finally, on the private industrial panel dataset, our method, when combined with auxiliary images, surpasses existing methods in terms of NMI, ARI, and ACC. While the improvement margins are modest, the performance is notably more stable, highlighting the practical applicability and potential of our approach in real-world industrial environments.

Keywords: Unsupervised Learning, Contrastive Learning, Fine-Grained Clustering, Multi-modal Feature Fusion

誌謝

Acknowledgements

在本論文撰寫與研究過程中，承蒙諸多師長與親友的指導與協助，謹此致上本人最誠摯的謝意。

首先，誠摯感謝指導教授林家瑜教授在整個研究期間所給予的悉心指導與支持。無論是在課業學習上提供豐富的知識與建議，或是在論文研究的主題選定、內容架構、實驗設計與常見錯誤的修正等方面，教授皆不吝提供寶貴的意見與啟發，使我得以逐步釐清研究方向並穩健推進。教授的嚴謹教學與耐心指導，對於本論文之順利完成，實具關鍵性的貢獻，謹此表達我最深的感謝與敬意。

此外，感謝合作廠商提供寶貴的數據，使本研究得以運用真實資料進行驗證，進而提升實驗結果之可信度與研究之完整性，對於本論文整體品質的提升亦具實質助益。

也感謝我的同學子瑜，在研究計畫執行期間與我並肩合作，無論在資料處理、實驗設計或成果彙整等各個環節，皆投入大量心力，最終順利完成計畫交付。其積極參與與貢獻，對於本研究之實驗流程與成果品質的提升，皆具有莫大助益。

最後，衷心感謝我的父母與長姐們，在碩士期間給予我無微不至的支持與協助，讓我能無後顧之憂地專注於研究與學習，順利完成本論文。無論在生活上或精神上，家人始終是我最堅強的後盾。每當遇到困難與挫折時，他們總是耐心鼓勵、默默支持，使我能夠重新振作。能夠在他們的陪伴與關愛下完成學業，我深感幸運與感激。

目錄

	頁次
摘要	i
Abstract	iii
誌謝	
Acknowledgements	v
目錄	vi
圖目錄	viii
表目錄	x
一、 緒論	1
1.1 研究背景	1
1.2 研究動機	1
1.3 問題定義	2
1.4 研究貢獻	2
二、 相關研究	4
2.1 Contrastive Learning	4
2.2 Attention-Based Multimodal Fusion	5
2.3 GAN-based and Adversarial Self-supervised Learning	5
三、 解決方法	7
3.1 方法參數定義	8
3.2 ROI 擷取階段	10
3.2.1 VQ-VAE	10
3.2.2 DRAEM	10

3.3	多模態對比式學習特徵擷取	11
3.3.1	Multi-branch Feature Extraction (MFE)	11
3.3.2	Attention Block 與 Feature Fusion Block.....	12
3.4	權重更新與對比學習流程	14
四、	實驗與結果討論	16
4.1	資料集介紹	18
4.1.1	A19 產線面板資料集	18
4.1.2	Retina 視網膜資料集	18
4.1.3	NEU-DET 鋼鐵表面瑕疵資料集	19
4.1.4	MVTec AD 工業異常資料集	20
4.1.5	CIFAR-10 資料集	20
4.2	參數設置	21
4.3	實驗結果	23
4.4	評估指標	23
4.4.1	實驗一：產線面板非公開資料集圖像分群.....	25
4.4.2	實驗二：RETINA 醫學影像資料集圖像分群.....	25
4.4.3	實驗三：NEU-DET 資料集圖像分群.....	26
4.4.4	實驗四：MVTec AD - Bottle 類別分群	27
4.4.5	實驗五：MVTec AD - Leather 類別分群.....	28
4.4.6	實驗六：CIFAR-10 公開資料集圖像分群	29
4.5	Ablation Study	30
4.5.1	Clustering Analysis	30
4.5.2	Heatmap Analysis	32
4.5.3	Convergence analysis	33
五、	結論與未來展望	34
5.1	結論	34
5.1.1	未來展望	34
六、	參考文獻	36

圖目錄

	頁次
3.1 整體架構。其中包含三個階段。	8
3.2 利用 autoencoder-based 的模型抓取潛在的微小異常區域，並選出正樣本 圖像以及輔助圖像	10
3.3 多模態對比學習特徵擷取模組 (Multi-modal Contrastive Learning Feature Extract Block, MCLFE)，其中包含三個元件	11
4.1 說明方法中所使用的輔助圖的影像類型。	17
4.2 A19 產線面板資料集。裡面分別有五種瑕疵類別，可以看出不僅僅瑕疵 類別極為相似，背景顏色也十分雷同，且特徵微小。	18
4.3 Retina 視網膜資料集 [1]。裡面分別有四種類別，類別間差異不易區分， 顯示該資料集具高挑戰性。	18
4.4 NEU-DET 鋼鐵表面瑕疵資料集 [2]。裡面分別有六種類別，相較於 A19 資料集，瑕疵大小較為明顯。	19
4.5 MVTec AD 資料集 [3] 中 Bottle 類別之異常樣本，包含三種不同類型的缺 陷。	20
4.6 MVTec AD 資料集 [3] 中 Leather 類別之異常樣本，包含五種不同類型的 瑕疵。	20
4.7 CIFAR-10 資料集 [4]，裡面分別有十種類別。	21
4.8 分別在 RETINA 視網膜資料集 [1]、CIFAR-10 資料集 [4] 和 A19 資料集 進行 K-Means 分群並視覺化。	31
4.9 分別在 MVTec 資料集 [3] 的 Bottle 及 Leather 的類別和 NEU 資料集 [2] 進 行 K-Means 分群並視覺化。	32
4.10 針對 Retina 資料集 [1] 在各模型模型中 Heatmap 的表現。	33

4.11 在 Retina 資料集 [1] 上的訓練過程收斂曲線。可觀察到損失逐漸下降， 聚類指標穩定上升，顯示模型訓練穩定性良好。	33
---	----

表目錄

	頁次
2.1 Work Comparison. 比較代表性方法在無監督學習能力與細粒度特徵處理能力的差異	6
3.1 方法中使用的參數與符號定義	9
4.1 各個資料集所使用的訓練集張數及測試集張數	21
4.2 FINE 訓練階段之 (超) 參數設定	22
4.3 FINE 推論階段之 (超) 參數設定	22
4.4 實驗一: 模型在面板瑕疵資料集中的實驗結果	25
4.5 VQ-VAE [5] 與 DRAEM [6] 在 Retina 資料集 [1] 中 Dice 系數上的比較 . .	26
4.6 實驗二: 模型在 RETINA 資料集 [1] 中的實驗結果	26
4.7 實驗三: 模型在 NEU-DET 資料集 [2] 中的實驗結果	27
4.8 VQ-VAE [5] 與 DRAEM [6] 在 MVTec 資料集 [1] 中 Bottle 類別上 Dice 系數的比較	27
4.9 實驗四: 模型在 MVTec AD 資料集 bottle 中的實驗結果	27
4.10 VQ-VAE [5] 與 DRAEM [6] 在 MVTec 資料集 [1] 中 Leather 類別上 Dice 系數的比較	28
4.11 實驗五: 模型在 MVTec AD 資料集 leather 中的實驗結果	28
4.12 實驗六: 模型在 CIFAR-10 資料集中的實驗結果	29
4.13 針對不同資料集與輔助影像類型所進行之消融實驗結果-1	30
4.14 針對不同資料集與輔助影像類型所進行之消融實驗結果-2	30

一、緒論

1.1 研究背景

近年來，隨著深度學習的快速發展，電腦視覺相關的模型訓練已在分類、檢測與分割等任務中取得顯著的成果。然而，目前主流的方法仍以監督式學習（Supervised Learning）為主，不僅仰賴大量人工標註的資料來訓練模型，且在實務應用中，例如醫學影像診斷或工業瑕疵檢測等專業領域，資料會有標註困難的問題。為了減少模型對於標註資料的依賴，近年來逐漸轉向非監督式學習（Unsupervised Learning），希望能在無需人工標註的情況下，學習出具有語義的特徵表示。

其中，對比式學習（Contrastive Learning）作為一種有效的非監督式學習方法，其核心思想是透過在特徵空間中拉近相似樣本（正樣本）之間的距離，並推遠不相似樣本（負樣本），使得模型學習出具備良好判別能力的嵌入表示。所提取出來的特徵可進一步結合聚類演算法，完成無需人工標註資料的分群任務。

1.2 研究動機

傳統的對比式學習在例如 CIFAR-10 [4] 與 ImageNet [7] 等公開標準資料集上，展現出優異的表徵學習能力。然而，這類資料集普遍具有以下特性：

1. 粗粒度特徵：類別間差異明顯，有助於模型快速區分特徵；
2. 圖像中主要目標通常佔據大部分畫面，使模型能輕易聚焦於關鍵資訊。

然而，當應用於工業瑕疵檢測或醫學影像等真實場域時，資料集具有下列性質：

1. 細粒度特徵：不同類型的瑕疵或病灶在外觀上差異細微，導致傳統方法難以有效區分；
2. 異常區域微小且分散：異常區域常僅佔整張影像的一小部分，甚至呈現多處分散分布，對模型的感知能力與特徵擷取能力需要更高要求。

1.3 問題定義

在工業瑕疵檢測與醫學影像分析等應用場景中，資料普遍具有細粒度特徵以及異常區域僅佔影像極小部分甚至呈現分散等特性，使得異常特徵的學習與分類變得極具挑戰性。有鑑於此，本研究旨在於完全無需人工標註的情境下，訓練一個具備**判別能力的特徵擷取器 (feature extractor)**，使其能有效聚焦於細粒度、區域微小且分散的異常特徵，並提升對異常類別的判別能力，並進一步結合分群演算法，以實現異常樣本的自動分群。本研究假設可取得大量未標註的影像資料，來源涵蓋工業製造或醫學檢測等領域，並為每張影像搭配一張輔助影像，此輔助影像可以來自無需人工標註的 autoencoder-based 的模型自動產生，也可以是資料集所提供的語意標註，抑或是缺乏異常標註時以灰階圖像作為替代，藉以提供空間引導訊息。模型輸入為影像與其對應的輔助影像組成之多模態資料，輸出則為經訓練後具判別性的特徵表示。最終，這些特徵可作為無監督任務（如 K-means 分群）的基礎，進行圖像的初步分類，若分群結果具備良好的類內一致性與類間分離性，則可進一步應用於標註流程的自動化，降低人工標註成本，並提升微小異常的辨識能力。

1.4 研究貢獻

本研究針對細粒度特徵及難以辨識細微且特徵分散等挑戰，提出一套名為 **FINE: Fine-Grained Image Understanding through Multimodal Contrastive Embedding Learning** 的方法，具體貢獻如下：

- 我們的方法結合輔助影像與我們所提出的多模態對比式特徵提取器，能專注於目標區域並降低背景雜訊。在 Retina 資料集 [1] 且有語意標註的情況下，NMI 提升 29%，ARI 提升 36%，ACC 提升 11%。
- 我們的方法在非公開的資料集上，使用 VQ-VAE [5] 作為輔助影像，比其他無監督方法在三個指標下平均提升了 1~2%；在 CIFAR-10 資料集 [4] 上，搭配灰階的輔助影像也與其他最好的方法有相似表現。這顯示我們的方法不僅僅在處理「微小且細粒度」資料集的無監督分群任務中具備潛力，對於通用的資料集也可以有不錯的效果。
- 我們的方法在鋼鐵表面瑕疵資料集 [2] 在使用語意標註的情況下，可以提升 NMI 到 98%，ARI 到 0.99%，ACC 到 83%。在 MVTec 資料集 [3] 中 Bottle 類別使用

DRAEM [6] 作為輔助影像，也能提升 20 % NMI。

- 我們將學習到的多模態特徵提取器的參數凍結，並在其上訓練一個監督式的線性分類層。在這樣的設定下，在大部分的資料集的 AUC 可達 0.8~0.9，顯示我們的方法能夠有效提取適用於分群任務的細粒度特徵。

二、 相關研究

2.1 Contrastive Learning

對比式學習的概念可以追溯至 1990 年代，隨著自然語言處理（NLP）以及電腦視覺（CV）領域中大型預訓練模型的興起，此項技術在近年來迅速獲得大量的關注與發展。代表性方法如 SimCLR [8] 利用資料增強產生正對樣本，結合 InfoNCE 損失學習具有語意區分能力的嵌入向量；MoCo [9] 則透過動量編碼器與動態記憶機制，改善小批次訓練中負樣本不足的問題。Un-Mix [10] 更進一步反思傳統混合式資料增強策略如 MixUp 與 CutMix 所造成的語意破壞問題，提出以語意區塊為基礎的拆解與重組方法，有效保留視覺語意的一致性，進而提升無監督表徵學習品質。這些方法皆透過縮小相似樣本間的距離、拉遠不相似樣本間的距離，以優化特徵空間表示，並在多項下游分類任務中展現出色表現。為突破傳統對比式學習在實際應用中的限制，Qian 等人提出了 SeCu [11]（Stable Cluster Discrimination for Deep Clustering）方法。與 SimCLR [8]、MoCo [9]、Un-Mix [10] 等僅學習特徵表徵、需另行進行分群的策略不同，SeCu [11] 在架構中整合了全連接層作為分類器，使模型能以端到端（end-to-end）方式，同步完成特徵學習與樣本聚類。此舉不僅提升了聚類的一致性，也降低了後續處理的複雜度。此外，SeCu [11] 引入了 pseudo-label smoothing 技術，減緩訓練初期 pseudo-label 的噪聲對於模型訓練所造成的不穩定，進一步提升模型的魯棒性；同時提出 Global Size Constraint，以強化各群體樣本分布的均衡性，有效避免模型崩潰的現象。實驗結果顯示，SeCu [11] 在多個無監督聚類任務中展現穩定且優異的表現。

然而，上述方法大多在開放型資料集上驗證，這些資料集中的主要物體通常佔據影像中大部分的區域且特徵明顯，有利於模型學習。相較之下，在包含「微小且細粒度」目標的資料集中，常伴隨大量背景與稀疏的目標區域，使得傳統無監督對比學習模型難以擷取具語意的有效特徵。為了解決此問題，研究者開始嘗試將多模態訊息（如語言、深度圖像、紅外影像等）引入到對比式學習的架構中，以提供額外的資訊來源，提升模型的表徵能力。

2.2 Attention-Based Multimodal Fusion

為了解決細粒度與局部細微特徵提取困難的問題，部分研究採用多模態架構，結合語言、結構化資料或不同型態影像，以強化特徵表徵能力。例如，Huang 等人 [12] 證實多模態對比學習在特徵學習與下游任務中表現優於單模態方法，其關鍵在於不同模態間具備互補性，可透過協同學習強化模型理解。Hazirbas 等人則提出 FuseNet [13]，透過融合可見光與深度影像資訊，實現室內場景的語意標註，其特徵於中間層進行融合。然而，這些早期方法多著重於網路架構整體設計，較少針對微小特徵進行注意力強化。為此，Choi 等人提出一個多模態特徵融合模組（Multimodal Feature Fusion Module）[14]，使用可見光與紅外影像作為輸入，於特徵融合後加入通道注意力機制（Channel Attention），以加強模型對關鍵特徵的聚焦。其在實際電力線資料集上的實驗結果證明，此方法顯著優於僅使用單一影像輸入的模型。Tang 等人則提出 DATFuse [15]，一種創新的多模態網路架構，旨在透過雙分支結構有效融合可見光與紅外線影像。其核心模組為 Dual Attention Residual Module（DARM），該模組結合殘差學習以擷取細緻的紋理特徵，並透過通道注意力（Channel Attention Block, CAB）與空間注意力（Spatial Attention Block, SAB），使模型能夠自適應地關注最具判別性的通道與空間區域；除了局部特徵提取外，DATFuse 亦整合 Transformer 模組（TRM），用以捕捉全域上下文資訊，進一步提升特徵的語義表達能力。透過上述結構設計，DATFuse [15] 在多模態資訊的對齊與融合上展現出高度的表現力，能有效強化模型對關鍵區域的特徵擷取能力。實驗結果顯示，結合注意力機制與異質影像輸入，能顯著提升影像融合任務中的整體效能。

2.3 GAN-based and Adversarial Self-supervised Learning

除了基於對比式學習與多模態融合的研究外，也有方法引入生成對抗網路（Generative Adversarial Network, GAN）與對抗式學習策略，藉此提升模型在無監督與細粒度特徵提取上的能力。

C3GAN [16] 旨在解決無監督環境下的細粒度分類與分群問題。該方法在 GAN 框架中引入對比式學習，並利用生成器產生多樣化的細粒度影像樣本，以補充特徵空間的多樣性。同時，透過對比損失優化生成樣本與真實樣本的特徵對齊，強化類間可分性與類內一致性。

另一方面，DiRA [17] 則提出一種結合判別式學習（Discriminative）、重建式學

習 (Restorative) 與對抗式學習 (Adversarial) 的自監督框架。該方法同時在實例級別 (Instance-level) 與全域結構上進行特徵學習，其中重建分支能恢復輸入影像的語意細節，判別分支負責優化表徵判別能力，並透過對抗分支提升生成與真實影像的域對齊效果。DiRA [17] 在醫學影像分析的無監督與遷移學習任務中，特別是在結構複雜與細粒度的資料集上，展現出優異的特徵表徵與聚類穩定性。

本研究受上述工作啟發，提出 **FINE** 架構，採用兩種輔助影像生成策略來引導對比學習模型聚焦於目標區域。其中，VQ-VAE [5] 為一種結合離散編碼與重建能力的自編碼器，能夠有效學習影像的語意結構，DRAEM [6] 則同時學習異常影像與其正常重建版本的表示，並學習判別邊界以進行異常偵測。本研究將由 VQ-VAE [5] 與 DRAEM [6] 所產生的輔助影像作為多模態輸入，導入多分支特徵提取模組與注意力模組中，進一步提升模型對「微小且細粒度」的注意力集中與表徵能力。為了進一步突顯本研究與現有工作的差異與優勢，表 2.1 彙整了各項代表性方法在「無監督能力」與「微小且細粒度能力」兩個面向的比較情形。從表中可見，雖然 SimCLR [8]、MoCo [9] 與 SeCu [11] 等方法在無監督特徵學習方面表現良好，然而在處理微小目標與細粒度特徵時仍顯不足。相較之下，DATFuse [15] 與本研究則針對此挑戰進行設計，皆具備同時處理細微特徵與融合異質模態的能力，特別是本研究結合輔助影像生成與多模態特徵提取模組，更進一步強化模型對關鍵區域的聚焦能力，展現於後續實驗中優異的分群表現。

表 2.1: Work Comparison. 比較代表性方法在無監督學習能力與細粒度特徵處理能力的差異

	Unsupervised Ability	Tiny and fine-grained Ability
SimCLR [8]	✓	×
MoCo [9]	✓	×
SeCu [11]	✓	×
DATFuse [15]	✓	✓
FINE (Ours)	✓	✓

三、 解決方法

本研究基於 SeCu [11] 進行改良，結合多模態學習與對比式學習的架構，稱為 **FINE**。透過多模態輸入的特性，我們利用輔助影像來引導模型專注於輸入圖像中「微小且細粒度」的特徵，並訓練出可以關注「微小且細粒度」的特徵提取器 (feature extractor)。

此模型共分為三個階段（如圖 3.1 所示）：

- **第一階段 (Stage 1)**：使用 Zavrtanik 等人提出的 **DRAEM** [6] 或是 Van Den Oord 等人提出的 **VQ-VAE** [5] 技術，從輸入中選出感興趣區域 (ROI)，強調潛在的目標位置作為輔助影像（記作 $a \in A$ ），並擷取可能存在微小物體的位置作為正樣本（ $p \in P$ ）。假設資料集是沒有異常的一般資料集，則使用灰階圖像作為輔助影像。
- **第二階段 (Stage 2)**：進行基於多模態的對比式學習。我們設計了一個融合正樣本影像與輔助影像的多模態對比學習特徵提取模組 (Multi-modal Contrastive Learning Feature Extract Block, **MCLFE**)，並將其嵌入於 Res2Net [18] 的架構中，即為多模態特徵提取器（ F_q 和 F_k ），以提升模型對細粒度及微小異常特徵的辨識能力。其中在 MCLFE 中包含：**多分支特徵提取模組 (Multi-branch Feature Extraction Block, MFE)**、**注意力模組 (Attention Block)** 和 **特徵融合模組 (Feature Fusion Block)**，以萃取「微小且細粒度」目標的關鍵特徵。
- **第三階段 (Stage 3)**：進行分群。透過可學習的群聚中心來進行分類，群聚中心則以 **全連接層 (FC)** 表示。來自 F_q 與 F_k 的輸出經過投影後，與群聚中心計算相似度，以優化以下兩項損失：第一，計算 Instance Loss (IL)，以訓練我們提出的多模態特徵提取器 F_q 與 F_k ；第二，計算 Center Loss (CL)，用以優化全連接層 (FC) 的權重。

後續章節將詳細介紹每個階段的設計內容。




圖 3.1: 整體架構。其中包含三個階段。

3.1 方法參數定義

本節說明模型中各階段所用的變數與參數，其定義如表 3.1 所示。

在第一階段，輸入圖像以 j 表示，經 VQ-VAE [5] 或 DRAEM [6] 產生中間表示 $En(j)$ ，並解碼為重建圖像 $De(j)$ 。VQ-VAE [5] 的輔助影像 A 取為 $|De(j) - j|$ ；DRAEM [6] 則透過辨識子網路輸出 anomaly map a ，經閾值處理後得到 A 。若資料無異常標註，則改以灰階圖作為輔助輸入。

第二階段中，正樣本及其增強版本記為 p 與 p_t ，搭配其輔助影像 m 、 m_t ，一同輸入至多模態特徵提取器 F_q 與 F_k ，再經由 G_q 、 G_k 進行轉換後，取得最終對比式學習嵌入 f_{f_q} 與 f_{f_k} 。特徵提取中，我們設計了多尺度卷積模組與注意力機制，原圖與輔助圖經卷積後分別生成 X_f^s 、 I_f^s ，融合為 M 。其經壓縮與注意力加權後得到融合特徵 $F(x) = H(x) + x$ ，強調細粒度異常區域。

在第三階段，特徵輸出會與當前迭代的聚類中心 (FC) 進行投影，計算 C_q 、 C_k ，並與前一迭代的 FC 比較得到 l_q 、 l_k ，進一步用於 Cluster Loss (CL) 與 Instance Loss (IL)，以提升訓練穩定性與聚類準確度。

表 3.1: 方法中使用的參數與符號定義

Parameters	Representation	Parameters	Representation
j	輸入 VQ-VAE [5] 或 DRAEM [6] 的異常影像	$En(j)$	VQ-VAE [5] 或 DRAEM [6] 的編碼器輸出
$De(j)$	解碼器生成的圖像	a	anomaly map，經轉換後為 A
A	遮罩影像（差異圖或二值化異常圖）	m, m_t	正樣本對應的輔助影像
p, p_t	正樣本圖像與其對應的增強版本		
F_q, F_k	多模態特徵提取器（共享參數）	G_q, G_k	維度轉換模組（共享參數）
f_{fq}, f_{fk}	特徵提取與轉換後的最終特徵向量	$H(x)$	特徵經 MCLFE 提取後的結果
$F(x)$	最終殘差結構輸出（ $H(x) + x$ ）	F_e	MFE 輸出特徵經 1×1 卷積壓縮後的結果
X_f, I_f	原圖與輔助圖的卷積特徵圖	X_f^s, I_f^s	不同尺度下的卷積特徵圖
M	多尺度特徵圖融合結果	z_c	通道注意力權重向量
X_{re}^c, I_{re}^c	經過通道注意力加權後的原圖與輔助圖的特徵圖	z_s	空間注意力權重向量
X_{re}^s	正樣本特徵圖與空間注意力向量相乘的特徵圖		
$FC^{(t)}$	當前疊代的聚類中心	$FC^{(t-1)}$	上一疊代的聚類中心
FC	聚類中心總稱	α	混合係數
C_q, C_k	特徵與當前 $FC^{(t)}$ 的投影結果（cluster logits）	y_q, y_k	基於 cluster size 指派的 pseudo label（hard label）
l_q, l_k	特徵與前一疊代 $FC^{(t-1)}$ 的投影結果（Instance Loss 用）	$\tilde{y}_q, \tilde{y}_k$	交叉視角目標分布（soft label 混合 one-hot）
$\mathcal{L}_{IL}$	Instance Loss（更新特徵提取器）	$\mathcal{L}_{CL}$	Cluster Loss（優化聚類中心）

3.2 ROI 擷取階段

在第一階段 (Stage 1) 中，我們使用異常影像當作輸入圖像，如圖 3.2 所示，輸入圖像 j 會透過 Autoencoder-based 的方法轉換為遮罩影像 A ，用以捕捉潛在的微小異常區域，並選出正樣本圖 $p \in P$ 及輔助圖像 m ，再利用資料增強的方式，產生 p^t 及 m^t 。此階段的目的是從原始圖像中定位可能存在的微小物體位置，作為後續對比學習的輸入影像。




圖 3.2: 利用 autoencoder-based 的模型抓取潛在的微小異常區域，並選出正樣本圖像以及輔助圖像

3.2.1 VQ-VAE

VQ-VAE [5] 採用編碼器-解碼器架構。輸入圖像 j 經由編碼器轉換為低維表示 $En(j)$ ，再由解碼器還原為生成圖像 $De(j)$ 。輔助圖像 A 定義為生成圖與原圖 j 的差異，即 $A = |De(j) - j|$ 。

3.2.2 DRAEM

DRAEM [6] 架構由兩個編碼器-解碼器對所組成，其中包含重建子網路與辨識子網路。重建子網路以結構相似度指數 (SSIM) 與重建損失進行訓練，用以學習圖像 j 的結構特徵並產生重建影像 $En(j)$ 。接著，將 $En(j)$ 與 j 拼接後送入辨識子網路以進行異常區域的判別。辨識子網路透過 Focal Loss 進行訓練，並輸出異常區域的定位圖 (anomaly map) a ，最後透過預設閾值對 a 進行二值化，取得最終遮罩影像 A ，作為後

續對比式學習的訓練輸入。

3.3 多模態對比式學習特徵擷取

在第二階段 (Stage 2) 中，我們基於 Res2Net [18] 提出一個基於對比式學習的多模態架構，模型會同時從正樣本 p 、與其增強版本 p_t ，以及對應的輔助影像 m 與 m_t 中提取關鍵特徵，以聚焦於「微小且細粒度」的區域。其中多模態特徵提取器 F_q 與 F_k 採用相同的網路架構，參數共享，分別由 3、4、6 與 3 個單元層組成，如圖 3.1 所示。

其中，我們設計了多模態對比學習特徵擷取模組 MCLFE，如圖 3.3 所示。輸入特徵 x 為正樣本圖像 p 與輔助影像 m 的拼接。該輸入會通過我們設計的模型產生特徵 $H(x)$ ，並透過殘差的方式連接與原始輸入相加形成 $H(x) + x$ ，以減緩深層網路中的梯度消失問題。




圖 3.3: 多模態對比學習特徵擷取模組 (Multi-modal Contrastive Learning Feature Extract Block, MCLFE)，其中包含三個元件

該模組主要由三個元件組成：

- 多分支特徵提取模組 (Multi-branch Feature Extraction Block, MFE)
- 注意力模組 (Attention Block)
- 特徵融合模組 (Feature Fusion Block)

透過這些設計，模型能夠從原圖與輔助影像中提取關鍵特徵，並強調異常區域與細粒度特徵。

3.3.1 Multi-branch Feature Extraction (MFE)

MFE 模組設計的目的是提升模型對於不同尺度特徵的擷取能力。我們使用不同尺寸的卷積核 (1×1 、 3×3 、 5×5) 來擷取圖像特徵，並將所有特徵圖串接。將正樣本圖與輔助影像分別通過這些卷積操作後，會產生共六個特徵圖。其數學表示如下：

設正樣本圖經由 Res2Net [18] 卷積層後的特徵圖表示為 $X_f = [x_f^1, x_f^2, \dots, x_f^c] \in R^{H \times W \times C}$ ，經由卷積核大小為 $s \times s$ 的卷積操作後，得到的特徵圖為

$$X_f^s = [x_f^{(s,1)}, x_f^{(s,2)}, \dots, x_f^{(s,d_h)}] \in R^{H \times W \times d_h},$$

其計算如下：

$$x_f^{(s,\text{idx})} = v_{(s,\text{idx})} * x = \sum_{k=1}^C v_{(s,\text{idx})}^{[k]} * x_f^k \quad (3.1)$$

同理，輔助圖經由 Res2Net [18] 卷積層後的特徵圖表示為 $I_f = [i_f^1, i_f^2, \dots, i_f^c] \in R^{H \times W \times C}$ ，經卷積後的結果為 $I_f^s = [i_f^{(s,1)}, i_f^{(s,2)}, \dots, i_f^{(s,d_h)}] \in R^{H \times W \times d_h}$ ，其計算如下：

$$i_f^{(s,\text{idx})} = u_{(s,\text{idx})} * i = \sum_{k=1}^C u_{(s,\text{idx})}^{[k]} * i_f^k \quad (3.2)$$

接著，將上述所提到的正樣本圖與輔助圖的特徵圖進行串接並加入偏差 b ，再通過 ReLU 激活函數 $\delta(\cdot)$ ，得到融合特徵圖 M ，如下式所示 ($s = 1, 3, 5$)：

$$M = \delta(\text{concat}[X_f^s, I_f^s] + b) \quad (3.3)$$

3.3.2 Attention Block 與 Feature Fusion Block

為了進一步強調 MFE 所擷取的關鍵特徵，我們設計了 Attention Block，並整合通道注意力 (Channel-wise Attention Block, CAB) 與空間注意力 (Spatial-wise Attention Block, SAB)，調整不同通道與空間特徵的權重。

MFE 輸出的特徵圖 M 經由 1×1 卷積層進行通道數調整（將六組 d_h 壓縮為 $2C$ ），生成的特徵圖記作 $F_e \in R^{H \times W \times 2C}$ ，計算如下：

$$f_e^i = w_i * M = \sum_{k=1}^{6d_h} w_i^{[k]} * m_k \quad (3.4)$$

接著，每一通道的特徵圖 f_e^i 會通過 Global Average Pooling 得到 scalar 值 scc_i ，再通過 Sigmoid 函數轉為通道注意力向量 $z_c = [z_X, z_I] \in R^{2C}$ ：

$$z_c = \sigma([scc_X, scc_I]) \quad (3.5)$$

再者，將該通道注意力向量分別與正樣本特徵圖 X_f 與輔助圖特徵圖 I_f 相乘，得

到通道加權後的輸出：

$$[X_{re}^c, I_{re}^c] = z_c \cdot [X_f, I_f] \quad (3.6)$$

為了進一步引導正樣本圖聚焦於在輔助圖所表示的潛在異常區域，我們引入空間注意力。該模組利用輔助圖的空間特徵產生空間注意力圖，進而調整正樣本圖的特徵表徵。

具體而言，將輔助圖的通道加權後特徵圖 I_{re}^c 分別進行最大池化與平均池化操作，取得兩個空間注意力表示，並將其串接後通過一個卷積層與 Sigmoid 函數，生成空間注意力圖 $z_s \in R^{H \times W \times 1}$ ，如下所示：

$$z_s = \sigma(\text{Conv}_{7 \times 7}([\text{AvgPool}(I_{re}^c), \text{MaxPool}(I_{re}^c)])) \quad (3.7)$$

接著，將該空間注意力乘上正樣本圖的通道加權特徵 X_{re}^c ，得到空間加權後的輸出：

$$X_{re}^s = z_s \cdot X_{re}^c \quad (3.8)$$

最後，將經過空間加權後的正樣本圖特徵 X_{re}^s 與輔助圖特徵 I_{re}^c 進行通道串接，形成特徵圖 $H(x)$ ，並採用殘差結構與輸入 x 相加以獲得最終輸出：

$$F(x) = H(x) + x, \quad \text{where } H(x) = \text{Concat}(X_{re}^s, I_{re}^c) \quad (3.9)$$

最後，如圖 3.1 第二階段所示，正樣本圖像 p 與輔助圖 m 通過多模態特徵提取器 F_q ，通過反向傳播進行優化，生成特徵表示 $F_q(x)$ ；同時，轉換後的正樣本影像 p_t 與輔助圖 m_t 經由多模態動量特徵提取器 F_k ，生成 $F_k(x)$ 。接著，這兩個特徵 $F_q(x)$ 和 $F_k(x)$ 分別通過維度轉換模組 G_q 與 G_k ，將特徵壓縮至 128 維，最終得到輸出特徵 f_{f_q} 和 f_{f_k} 表示為：

$$f_{f_q} = G_q(F_q(x)), \quad f_{f_k} = G_k(F_k(x)) \quad (3.10)$$

3.4 權重更新與對比學習流程

為了強化無監督模型的訓練效果，在圖 3.1 的 **第三階段 (Stage 3)** 中，不僅優化了聚類中心 (FC)，也同時訓練多模態特徵提取器 (F_q 和 F_k)。在 **Stage 2** 所產生的最終特徵 f_{f_q} 與 f_{f_k} 會分別與當前疊代 t 的聚類中心 (即 $FC(t)$) 進行內積投影，用以衡量特徵與各個群聚中心的相似度，產生 cluster logits C_q 與 C_k ，如式 (3.11) 所示：

$$C_q = f_{f_q} \cdot FC(t), \quad C_k = f_{f_k} \cdot FC(t) \quad (3.11)$$

在計算 Cluster Loss 之前，需先為每個樣本分配 pseudo-label (y_q 與 y_k)，本方法採用「基於 cluster size 限制」的分配策略，計算每個樣本與各群聚中心之間的負相似度 (即 $-C_q$ 、 $-C_k$)，並加上對應的雙重變數 (dual term) 進行最小化指派：

$$y_q = \arg \min_i (-C_q^{(i)} + \text{dual}_i), \quad y_k = \arg \min_i (-C_k^{(i)} + \text{dual}_i) \quad (3.12)$$

接著，使用 pseudo-label y_q 與 y_k 作為目標，與 cluster logits C_q 和 C_k 計算交叉熵損失 (採用 hard label)，作為 $\mathcal{L}_{CL}$ ：

$$\mathcal{L}_{CL} = \text{CE}(C_q, y_q) + \text{CE}(C_k, y_k) \quad (3.13)$$

此外， f_{f_q} 與 f_{f_k} 亦會與前一疊代 $FC^{(t-1)}$ 進行內積，獲得 logits l_q 與 l_k ，作為對另一視角監督的輸出基礎：

$$l_q = f_{f_q} \cdot FC^{(t-1)}, \quad l_k = f_{f_k} \cdot FC^{(t-1)} \quad (3.14)$$

為提升跨視角特徵一致性，將 l_k 經 softmax 得到的機率分布視為 l_q 的目標分布 (反之亦然)，並加上 α 權重的 one-hot pseudo label 進行微量補強，形成 soft-hard 混合目標 $\tilde{y}_q$ 、 $\tilde{y}_k$ ：

$$\tilde{y}_q = (1 - \alpha) \cdot \text{softmax}(l_k) + \alpha \cdot \text{one_hot}(y_q)$$

$$\tilde{y}_k = (1 - \alpha) \cdot \text{softmax}(l_q) + \alpha \cdot \text{one_hot}(y_k)$$

最終 Instance Loss 採用對稱式監督結構，計算每一視角輸出與另一視角目標分布之間的加權交叉熵：

$$\mathcal{L}_{IL} = \sum_i \left(\tilde{y}_q^{(i)} \cdot \log \text{softmax}(l_q)_i \right) + \sum_i \left(\tilde{y}_k^{(i)} \cdot \log \text{softmax}(l_k)_i \right) \quad (3.15)$$

最後，總損失為 Cluster Loss 與 Instance Loss 的加總：

$$\mathcal{L}_{total} = \mathcal{L}_{CL} + \mathcal{L}_{IL} \quad (3.16)$$

透過此更新策略，我們能同時提升分群穩定性與特徵提取能力。本方法實現了聚類中心與特徵學習的端到端聯合訓練，具備相較傳統 k-means 更高的整合性與表現潛力。

四、實驗與結果討論

在本章節中，我們總共進行了六組主要實驗與消融實驗，藉此驗證我們的方法在不同資料特性下的分群效果。每組實驗皆選用具代表性的資料集，模擬現實中異常檢測場景可能遇到的挑戰，如細微異常特徵等問題，並與多種現有主流的無監督學習方法（如 SimCLR [8]、MoCoV2 [9]、SeCu [11]、DATFuse [15]）進行性能比較。第一組實驗採用非公開的面板瑕疵資料集 A19，該資料來源自實際產線環境，影像中不僅瑕疵類別相近且背景複雜，實驗目的在於驗證我們的方法能否有效應用於工業瑕疵影像中進行異常分類。第二組實驗使用公開醫學影像資料集 Retina [1]，該資料集中包含多種難以區分的微小視網膜病變，實驗重點在於觀察我們的方法在處理醫學影像上的分群效果。第三組實驗採用 NEU-DET 鋼鐵表面瑕疵資料集 [2]，其瑕疵特徵相對明顯，目的是評估我們的方法在瑕疵明顯但輔助遮罩品質不佳（bounding box 粗略標註）條件下的適應能力。第四和第五組實驗使用 MVTec AD 工業異常資料集 [3]，該資料集廣泛應用於異常偵測任務，涵蓋 15 種物體與紋理類別，具備豐富的異常樣態與像素級標註資訊。本實驗中，我們選擇其中的 Bottle 與 Leather 類別進行測試，分別代表結構規則的物體與表面紋理為主的材料，並對訓練資料進行資料增強處理，目的是評估我們的方法在結構規則和表面紋理上的表現，每組實驗均使用相同的評估指標，以確保一致性。第六組實驗則為 CIFAR-10 資料集 [4]，雖非異常資料集，但藉由引入灰階圖像作為輔助圖像，模擬多模態資訊設計，進一步檢驗我們的方法在一般圖像分類任務下的泛化能力。上述實驗所使用的輔助圖會展示在數據的表格中，如圖 4.1 為例，(Gray scale) 代表灰階圖像作為輸入的輔助圖，(DRAEM) 代表使用 DRAEM [6] 所產生的輔助圖，(VQ-VAE) 代表使用 VQ-VAE [5] 所產生的輔助圖，(GT) 是使用資料集本身提供的語意標註 (semantic ground truth) 當作輔助圖，(Supervised) 則是凍結住 backbone 的參數，在模型的最後新增一層線性分類層，利用監督式學習驗證模型有學到表徵的能力。若沒有提及則是單純使用正樣本當作模型的輸入。

Evaluation Metrics
SimCLR
MoCoV2
SeCu
DATFuse (Gray scale)
FINE (DRAEM)
FINE (VQ-VAE)
FINE (GT)
FINE (Supervised)

圖 4.1: 說明方法中所使用的輔助圖的影像類型。

最後，針對我們的方法中的各模組（如輔助圖生成方式、k-means 聚類等）進行測試，以評估其對整體性能的貢獻。透過在不同資料集上進行比較與分析，驗證了所提出之模組在處理不同類型影像資料時的穩定性與有效性，並透過 t-SNE 視覺化結果佐證模型在特徵空間中的可分性提升。綜合以上實驗設計與分析結果，顯示我們的方法在無需人工標註的條件下，能透過輔助圖像與多模態特徵融合，有效提升聚類準確性的能力，特別適用於細粒度異常與缺乏標註的異常檢測任務。

4.1 資料集介紹

在此先介紹各實驗中所使用的資料集。

4.1.1 A19 產線面板資料集

第一個實驗所使用的資料集是 A19 產線面板資料集，A19 是來自產線面板計畫中的非公開資料集，A19 資料集主要收錄自實際產線環境中擷取之面板影像，圖像均為彩色 RGB 格式，每個類別根據黑點、刮痕、水波、渲染等瑕疵進行分類。如圖 4.2 所展示的五種不同的瑕疵類別。




圖 4.2: A19 產線面板資料集。裡面分別有五種瑕疵類別，可以看出不僅僅瑕疵類別極為相似，背景顏色也十分雷同，且特徵微小。

4.1.2 Retina 視網膜資料集

第二個實驗所使用的資料集為 Retina 資料集 [1]，由 Pachade 等人提出，該資料集主要用於視網膜病變檢測，具有高解析度與細微病灶的特性，適合評估模型在處理細粒度與微小異常目標上的表現，其中包含一種正常及三種異常病變: Disc (正常)、Hemorrhage (出血)、Hard Exudates (硬性滲出物) 和 Red Small Dots (紅色小點)。如圖 4.3 所展示的正常圖及三種不同的病變。




圖 4.3: Retina 視網膜資料集 [1]。裡面分別有四種類別，類別間差異不易區分，顯示該資料集具有高挑戰性。

4.1.3 NEU-DET 鋼鐵表面瑕疵資料集

第三個實驗使用的資料集為 NEU Surface Defect Dataset (NEU-DET) [2]，此資料集由 Northeastern University 提出，廣泛應用於鋼鐵表面瑕疵的分類研究，包含六種常見的鋼材表面瑕疵類型：Crazing (裂紋)、Inclusion (夾雜物)、Patches (斑點)、Pitted Surface (凹坑)、Rolled-in Scale (壓入氧化皮) 以及 Scratches (刮痕)。如圖 4.4 所展示的六種不同的鋼鐵表面瑕疵類型。




圖 4.4: NEU-DET 鋼鐵表面瑕疵資料集 [2]。裡面分別有六種類別，相較於 A19 資料集，瑕疵大小較為明顯。

4.1.4 MVTec AD 工業異常資料集

第四和第五個實驗使用的資料集為 MVTec AD 工業異常資料集 (MVTec) [3]，由 MVTec 公司於 CVPR 2019 發表，用於無監督異常偵測，是工業機器視覺中最著名的基準資料集之一。其中包含 15 個物體與紋理類別。本實驗選用其中的 **Bottle** 與 **Leather** 兩類進行測試，分別代表結構性物件與紋理性材料，藉以驗證模型於不同型態工業瑕疵中的特徵提取能力。其中 Bottle 類別包含 3 種異常類型，Leather 類別則包含 5 種異常類型，並透過資料增強以提升樣本數量。如圖 4.5 和圖 4.6 分別展示了 MVTec AD 中 bottle 與 leather 類別的異常範例，說明不同瑕疵間的視覺差異與分群挑戰。




圖 4.5: MVTec AD 資料集 [3] 中 Bottle 類別之異常樣本，包含三種不同類型的缺陷。




圖 4.6: MVTec AD 資料集 [3] 中 Leather 類別之異常樣本，包含五種不同類型的瑕疵。

4.1.5 CIFAR-10 資料集

第六個實驗使用的資料集為 CIFAR-10 [4]，此資料集為經典的通用分類資料集，包含 10 類不同類別（如汽車、貓、狗、飛機等）的自然場景彩色圖像，每張圖像解析度為 32×32 。雖然並非是瑕疵或異常類別資料集，但 CIFAR-10 [4] 資料集可以提供一個強基準可評估模型在一般影像分類任務下的通用性與擴展能力。如圖 4.7 所示，這些類別包含多種動物與交通工具，有助於評估模型在通用圖像分類下的泛化能力。

表 4.1 中顯示上述各類資料集在訓練以及測試時所使用的張數。




圖 4.7: CIFAR-10 資料集 [4]，裡面分別有十種類別。

表 4.1: 各個資料集所使用的訓練集張數及測試集張數

Datasets	Train	Validation
A19	3000	500
Retina [1]	4000	1000
NEU-DET [2]	1440	360
MVTec bottle [3]	630	144
MVTec leather [3]	1230	240
CIFAR-10 [4]	50000	10000

4.2 參數設置

我們使用兩張 NVIDIA RTX 3090Ti 顯示卡的設備上執行，開發環境為 Python 3.9.21 搭配 PyTorch 深度學習框架。訓練流程僅執行一次，無需額外進行預訓練階段，而是直接於來源資料集上進行端對端訓練。訓練總共進行 1200 個 epochs，批次大小（batch size）設定為 128，學習率（learning rate）設為 0.2，權重衰減（weight decay）設為 1×10^{-4} ，並使用具備 momentum 的 SGD 最佳化器，其中 momentum 值為 0.9。學習率調整策略採用 cosine decay with warm-up，以提升模型的穩定性與收斂效率，此學習率與批次大小經實驗驗證可穩定收斂，並在多數資料集取得良好效果。考量資料特性，輸入影像尺寸依資料集調整：考量 CIFAR-10 原始圖像解析度僅為 32×32 ，故升採至 224×224 ，其餘資料集則統一採用 256×256 。

為說明本研究於訓練與推論階段的設定細節，表 4.2 與表 4.3 分別列出所採用的主要超參數與執行配置。

表 4.2: FINE 訓練階段之（超）參數設定

Parameter	Default	Description
workers	4	Number of data loading workers
epochs	1201	Number of total training epochs
start_epoch	0	Manual epoch number (useful for restarts)
batch_size	128	Mini-batch size (total across all GPUs)
lr	0.2	Initial learning rate
momentum	0.9	Momentum of SGD solver
weight_decay	1e-4	Weight decay for optimizer
print_freq	100	Print frequency during training
world_size	-1	Number of nodes for distributed training
rank	-1	Node rank for distributed training
seed	None	Seed for initializing training
gpu	None	GPU id to use
multiprocessing_distributed	False	Use multiprocessing distributed training
secu_dim	128	Feature dimension in FINE
secu_num_ins	1439	Number of instances (e.g., training samples)
secu_num_head	4	Number of k-means heads
secu_k	[4, 8, 12, 16]	Multi-clustering head settings
secu_tx	0.05	Temperature for representation
secu_tw	0.05	Temperature for cluster center
secu_tau	0.2	Weight of one-hot label
secu_dual_lr	0.1	Learning rate for dual variable lower bound
secu_lratio	0.9	Lower-bound ratio constraint
secu_alpha	6000	Entropy weight
secu_cst	size	Constraint type
clr	1.2	Learning rate for cluster center
min_crop	0.3	Minimal scale for random crop
data_name	retina	Dataset name used for training

表 4.3: FINE 推論階段之（超）參數設定

Parameter	Default	Description
batch_size	32	Mini-batch size for inference
workers	2	Number of data loading workers
gpu	0	GPU id to use
model_path	(required)	Path to trained model checkpoint
test_file	(required)	Path to test dataset list (TXT file with: path1 path2 label)
output_file	results.csv	Path to save inference results

4.3 實驗結果

在本研究的六項實驗中，我們將所提出的方法與四種現有的非監督式學習方法進行比較，分別為 SimCLR [8]、MoCoV2 [9]、SeCu [11] 與 DATFuse [15]。這些方法涵蓋自 2020 年至 2023 年間發表的代表性非監督學習架構，包含早期的對比式學習方法（如 SimCLR [8] 與 MoCoV2 [9]），以及近期針對聚類抑或是多模態融合所提出的進階方法（如 SeCu [11] 與 DATFuse [15]）。透過跨年份與架構類型的比較，能更全面評估本研究方法於不同場景下的表現優勢與穩定性。

4.4 評估指標

為了全面評估本研究所提出方法在分群任務中的效能，本文採用三項常見且互補的分群指標：**Normalized Mutual Information (NMI)**、**Adjusted Rand Index (ARI)** 與 **Clustering Accuracy (ACC)**。這三項指標分別從資訊理論、群集一致性與分類正確率三個層面，衡量模型輸出與真實標籤之間的一致性，能提供更完整的分群品質評估。

- **Normalized Mutual Information (NMI)**：衡量模型預測分群與真實標籤之間的互資訊（Mutual Information），並經標準化處理，使其結果範圍介於 0 與 1 之間。數值越高代表分群與真實標籤越一致。

舉例：若分群結果完全與標籤對應， $NMI = 1$ ；若兩者完全無關，則 NMI 趨近於 0。

- **Adjusted Rand Index (ARI)**：透過比較所有樣本對（pair-wise）是否被歸為同一群集，評估預測分群與真實標籤間的一致性。ARI 排除了隨機聚類產生的期望結果，使得結果更可靠。指標範圍為 $[-1, 1]$ ，其中 1 表示完全一致，0 表示隨機分群水準。

舉例：若將所有樣本錯誤地分為同一群， ARI 會趨近於 0，反映無意義的分群。

- **分群準確率（Clustering Accuracy, ACC）**：透過最佳標籤對應（permutation mapping）計算模型預測分群與真實標籤間的準確性。雖然無監督任務不使用真實標籤進行訓練，但 ACC 提供一個直觀的性能參考，特別適合用於已知類別數的評估情境。

舉例：若模型正確分群，但群集標號與標籤對應錯置，透過最佳對應後仍可正確反映實際準確性。

本研究所使用之三項評估指標的數學定義如下（式 4.1）至（式 4.3）所示：

$$\text{NMI}(Y, \hat{Y}) = \frac{2 \cdot I(Y, \hat{Y})}{H(Y) + H(\hat{Y})} \quad (4.1)$$

其中 $I(Y, \hat{Y})$ 表示真實標籤與預測分群之間的互資訊， $H(Y)$ 和 $H(\hat{Y})$ 分別表示真實標籤與預測分群的資訊熵。

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}} \quad (4.2)$$

其中 n_{ij} 表示真實標籤 i 與預測分群 j 的交集樣本數， $a_i = \sum_j n_{ij}$ ， $b_j = \sum_i n_{ij}$ ， n 為總樣本數。

$$\text{ACC} = \max_{m \in \mathcal{P}} \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{y_i = m(\hat{y}_i)\} \quad (4.3)$$

其中 $\mathcal{P}$ 為所有可能的標籤對應排列組合， $m(\cdot)$ 表示重新映射預測標籤， $\mathbf{1}\{\cdot\}$ 為指示函數，當括號內條件為真時取值為 1，否則為 0。

4.4.1 實驗一：產線面板非公開資料集圖像分群

在實驗一中，A19 資料集為採用的非公開工業面板瑕疵資料，其影像來源自實際產線環境，特徵在於類別之間差異極為細微，且背景高度相似，對分群任務具有高度挑戰性。由表 4.4 可觀察到，傳統對比式學習方法如 SimCLR [8] 與 MoCoV2 [9] 雖能達到約 0.33 和 0.36 的 ACC，但其 NMI 與 ARI 指標偏低，顯示其在細粒度特徵學習上能力有限。SeCu [11] 針對聚類學習設計，但在此資料集表現不佳，NMI 僅 0.05，顯示其難以處理類別邊界模糊的資料。

在所有評估指標中，我們的方法在 VQ-VAE [5] 的引導下展現出最優異的無監督方法效果，獲得了最高的分數。這項結果突顯了輔助遮罩品質的重要性——儘管使用 DRAEM [6] 遮罩的表現較差，但當採用來自 VQ-VAE [5] 的遮罩時，能顯著提升特徵提取的效果，進而實現更準確的分群結果。

表 4.4: 實驗一：模型在面板瑕疵資料集中的實驗結果

Evaluation Metrics	NMI	ARI	ACC
SimCLR [8]	0.12	0.07	0.33
MoCoV2 [9]	0.12	0.08	0.36
SeCu [11]	0.05	0.01	0.27
DATFuse [15]	0.06	0.09	0.29
FINE (DRAEM [6])	0.07	0.05	0.31
FINE (VQ-VAE [5])	0.13	0.10	0.37
FINE (Supervised)			0.41

4.4.2 實驗二：RETINA 醫學影像資料集圖像分群

在實驗二中，我們額外收集了 4,000 張正常的視網膜 CT 影像（來源參見文獻 [19]），並以此訓練 VQ-VAE [5] 與 DRAEM [6] 模型。由於 Pachade 等人提供之公開 Retina 資料集 [1] 包含語意標註資訊，先以額外的正常影像訓練 VQ-VAE [5] 與 DRAEM [6] 模型，並比較其重建效果。根據 Dice 系數（表 4.5），DRAEM [6] 明顯優於 VQ-VAE [5]，因此作為本實驗的輔助輸入。

然而，由於上述兩種模型在語意分割任務中皆未達到理想的準確度，因此我們在聚類評估中加入語意標註（semantic ground truth），以利進行更全面的比較，如表 4.6 所示。

表 4.5: VQ-VAE [5] 與 DRAEM [6] 在 Retina 資料集 [1] 中 Dice 系數上的比較

Reconstruction	Dice
VQ-VAE [5]	0.1122
DRAEM [6]	0.334

在使用 DRAEM [6] 輔助的 Retina 資料集 [1] 中，雖然 FINE 模型的準確率 (ACC) 相對低於其他無監督方法，但其在 ARI 指標上取得最高分數，顯示出 FINE 具備優異的聚類能力。若使用語意標註當作輔助影像輸入的話，則在三種指標下都可取得最好的效果，也證明說輔助影像對於我們的方法有深遠的影響。在使用監督式的線性分類層訓練後，也可達 80% 的準確度。

表 4.6: 實驗二: 模型在 RETINA 資料集 [1] 中的實驗結果

Evaluation Metrics	NMI	ARI	ACC
SimCLR [8]	0.03	0.02	0.34
MoCoV2 [9]	0.15	0.06	0.36
SeCu [11]	0.09	0.01	0.31
DATFuse [15] (Gray scale)	0.41	0.25	0.46
FINE (DRAEM [6])	0.39	0.26	0.22
FINE (Ground Truth)	0.70	0.62	0.57
FINE (Supervised)			0.80

4.4.3 實驗三: NEU-DET 資料集圖像分群

在實驗三中，NEU-DET 資料集 [2] 每張圖像均附有對應的語意標註，可用於輔助異常區域的辨識。值得注意的是，這些標註非像素級語意分割，而是以矩形框 (bounding box) 形式粗略標示異常所在範圍。

儘管如此，我們的方法在使用 Ground Truth 遮罩輔助時，依然在 NMI、ARI 與 ACC 三項指標上表現最佳 (表 4.7)，ACC 達 0.83，高於 SeCu [11] 與 DATFuse [15] 等方法。在實驗中亦觀察到我們的方法在特徵提取方面具高穩定性，即使輔助資訊品質不佳，也能維持聚類品質。

表 4.7: 實驗三: 模型在 NEU-DET 資料集 [2] 中的實驗結果

Evaluation Metrics	NMI	ARI	ACC
SimCLR [8]	0.12	0.01	0.26
MoCoV2 [9]	0.10	0.01	0.19
SeCu [11]	0.93	0.92	0.82
DATFuse [15] (Gray scale)	0.45	0.32	0.58
FINE (Ground Truth)	0.98	0.99	0.83
FINE (Supervised)			0.97

4.4.4 實驗四: MVTec AD - Bottle 類別分群

在實驗四和實驗五中，我們分別針對 MVTec 資料集 [3] 中的 Bottle 與 Leather 類別進行細粒度異常分群實驗。

表 4.8: VQ-VAE [5] 與 DRAEM [6] 在 MVTec 資料集 [1] 中 Bottle 類別上 Dice 系數的比較

Reconstruction	Dice
VQ-VAE [5]	0.204
DRAEM [6]	0.593

在 bottle 類別中 (實驗四)，我們根據 Dice 係數 4.8 決定採用 DRAEM [6] 所產生的重建差異圖作為輔助圖，並與其他方法進行比較。如表 4.9 所示，我們的方法在 NMI、ARI 與 ACC 指標上皆優於對照方法，顯示其在結構性瑕疵場景下具備良好的特徵表示與聚類能力。

表 4.9: 實驗四: 模型在 MVTec AD 資料集 bottle 中的實驗結果

Evaluation Metrics	NMI	ARI	ACC
SimCLR [8]	0.15	0.07	0.47
MoCoV2 [9]	0.07	0.04	0.44
SeCu [11]	0.02	0.02	0.40
DATFuse [15] (Gray scale)	0.50	0.48	0.60
FINE (DRAEM)	0.70	0.47	0.64
FINE (Supervised)			0.97

4.4.5 實驗五: MVTec AD - Leather 類別分群

實驗五中，我們也是根據 Dice 係數 4.10 決定採用 DRAEM [6] 所產生的重建差異圖作為輔助圖，並與其他方法進行比較。

表 4.10: VQ-VAE [5] 與 DRAEM [6] 在 MVTec 資料集 [1] 中 Leather 類別上 Dice 系數的比較

Reconstruction	Dice
VQ-VAE [5]	0.162
DRAEM [6]	0.584

然而，Leather 屬於以紋理為主的類別，其異常型態（如 cut、poke、color 等）通常呈現為微小且分布稀疏的材質擾動，對於模型的區辨能力提出了更高的挑戰。在這類場景中，異常訊號不易與背景形成明顯對比，導致重建差異圖的表現較不穩定，進而影響融合模組的判別效果。由於我們的設計仰賴多模態特徵互補，此類模糊或細微的異常特徵，可能使得特徵分佈在聚類時產生較大的重疊，導致類內混淆現象，進一步反映在 NMI 與 ACC 指標上的下降（分別為 0.35 與 0.42，如表 4.11）。

表 4.11: 實驗五: 模型在 MVTec AD 資料集 leather 中的實驗結果

Evaluation Metrics	NMI	ARI	ACC
SimCLR [8]	0.41	0.27	0.48
MoCoV2 [9]	0.44	0.35	0.47
SeCu [11]	0.35	0.25	0.47
DATFuse [15] (Gray scale)	0.66	0.50	0.66
FINE (DRAEM)	0.35	0.22	0.42
FINE (Supervised)			0.23

整體而言，我們的方法在結構性異常類別上（如 Bottle）展現出良好的聚類能力，但在需要精細紋理辨識的任務上仍具挑戰。此結果也指出：在面對不同型態的異常情境時，單一融合策略未必能廣泛適用，未來可考慮導入自適應融合機制，或設計更具區辨性與穩定性的輔助訊號生成方式，以提升模型在多樣異常型態下的泛化能力與穩定性。

4.4.6 實驗六: CIFAR-10 公開資料集圖像分群

與上述資料集有所不同，CIFAR-10 [4] 沒有輔助圖。然而，由於 CIFAR-10 [4] 的圖像通常具有位於中央、顏色明亮的主體物件，相較於背景更容易辨識，我們將原始圖像轉換為灰階版本，作為模型訓練時的輔助輸入。

如表 4.12 所示，我們的方法在無監督學習設定下達到與其他方法相當的表現，並在線性分類層訓練後，也可以達到 0.89 的準確度。實驗六的結果顯示，即使僅使用簡單的灰階遮罩作為輔助，我們的方法仍能有效捕捉特徵，進一步提升其特徵表現能力。

表 4.12: 實驗六: 模型在 CIFAR-10 資料集中的實驗結果

Evaluation Metrics	NMI	ARI	ACC
SimCLR [8]	0.47	0.33	0.53
MoCoV2 [9]	0.26	0.16	0.39
SeCu [11]	0.70	0.62	0.78
DATFuse [15] (Gray scale)	0.04	0.02	0.17
FINE (Gray scale)	0.70	0.66	0.73
FINE (Supervised)			0.89

4.5 Ablation Study

在此實驗中，分析了我們的方法與基礎架構 SeCu [11] 以聚類中心以及 K-means 聚類後的表現進行比較。根據表 4.13 及 4.14 所示，我們的方法在大部分的資料集中皆穩定地取得最高的 NMI 與 ARI 分數。儘管其 ACC 相對較低，這可能是由於預測的群集與真實標籤之間存在對應誤差，但整體優異的 NMI 與 ARI 指標仍突顯出優異的聚類能力，即便面對標籤不一致的情況，仍能展現良好表現。

表 4.13: 針對不同資料集與輔助影像類型所進行之消融實驗結果-1

Method	panel (VQ-VAE)			Retina (DRAEM)			CIFAR-10		
	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI	ACC
SeCu [11] + k-means	0.06	0.03	0.29	0.07	0.004	0.28	0.60	0.28	0.60
SeCu [11]	0.05	0.02	0.27	0.09	0.01	0.31	0.70	0.62	0.78
FINE + k-means	0.07	0.03	0.30	0.29	0.22	0.51	0.52	0.36	0.54
FINE	0.13	0.10	0.37	0.39	0.26	0.22	0.70	0.66	0.73

表 4.14: 針對不同資料集與輔助影像類型所進行之消融實驗結果-2

Method	Bottle (DRAEM)			Leather (DRAEM)			NEU-DET		
	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI	ACC
SeCu [11] + k-means	0.14	0.13	0.53	0.55	0.39	0.57	0.93	0.90	0.95
SeCu [11]	0.02	0.02	0.40	0.35	0.25	0.47	0.93	0.92	0.82
FINE + k-means	0.47	0.42	0.74	0.12	0.06	0.31	0.96	0.96	0.98
FINE	0.7	0.67	0.64	0.35	0.22	0.42	0.98	0.99	0.83

4.5.1 Clustering Analysis

我們針對我們的方法和 SeCu [11] 分別提取其特徵後，進行 k-means 分群結果的評估，如圖 4.8 所示。在 Retina 資料集 [1] 中，H 表示出血 (Hemorrhage)、HE 表示硬性滲出物 (Hard Exudates)，RSD 則代表紅色小點 (Red Small Dots)。由於這些類別在視覺上高度相似，SeCu [11] 通常會將它們合併為同一個群集；相比之下，我們的方法雖然對 HE 仍有部分誤分類，但整體上展現出較佳的區分能力。

這些結果顯示，我們的方法透過輔助影像的引導，能學習到更具辨別性的特徵，從而提升分群準確度。在 CIFAR-10 資料集 [4] 上，我們的方法與 SeCu [11] 均達到相當的分群表現，說明這兩個模型在類別明確的開放領域資料上均表現良好。而在私有的面板資料集中，我們的方法成功將資料有效分為五個主要群集。儘管仍有部分誤分




圖 4.8: 分別在 RETINA 視網膜資料集 [1]、CIFAR-10 資料集 [4] 和 A19 資料集進行 K-Means 分群並視覺化。

類情形，但整體表現仍優於 SeCu [11]，顯示引入輔助影像有助於模型學習更準確且具意義的特徵以進行分群。

在 NEU 資料集 [2] 中，我們的方法與 SeCu [11] 也均達到相當的分群表現，說明這兩個模型在瑕疵明顯的情況下表現良好。最後在 MVTec 資料集 [3] 上，我們的方法在 Bottle 類別中可以明顯看出群聚的效果。




圖 4.9: 分別在 MVtec 資料集 [3] 的 Bottle 及 Leather 的類別和 NEU 資料集 [2] 進行 K-Means 分群並視覺化。

4.5.2 Heatmap Analysis

為進一步探討各方法對目標區域的感知能力，我們在 Retina 資料集 [1] 上，比較 SimCLR [8]、MoCoV2 [9]、SeCu [11] 與我們的方法所產生的熱區圖（Heatmap），如圖 4.10 所示。

在 Retina 資料集 [1] 中，我們的方法在熱區圖中顯示出對病灶位置的明確聚焦，相較於其他模型更能準確關注於異常區域。此實驗結果證實，我們的方法在引入輔助影像後，能有效提升模型對微小病灶的辨識能力，並強化其感知異常特徵的能力，進而學習到更具語意與判別性的特徵表徵。




圖 4.10: 針對 Retina 資料集 [1] 在各模型模型中 Heatmap 的表現。

4.5.3 Convergence analysis

為評估我們的方法在 Retina 資料集 [1] 上的訓練穩定性與收斂情形，我們進行了損失函數與聚類指標（如 NMI）隨訓練輪次變化的觀察，結果如圖 4.11 所示。




圖 4.11: 在 Retina 資料集 [1] 上的訓練過程收斂曲線。可觀察到損失逐漸下降，聚類指標穩定上升，顯示模型訓練穩定性良好。

從圖中可以發現，我們的方法在初期數個 epoch 內即快速降低其損失值，並穩定提升聚類指標的分數，顯示出良好的收斂速度與學習效果。隨著訓練進行，模型表現逐步穩定，無明顯震盪或過擬合現象，顯示其具備良好的訓練穩定性與泛化能力。

五、 結論與未來展望

5.1 結論

本研究針對「微小且細粒度 (tiny and fine-grained)」的影像難以辨識的問題，提出一套名為 **FINE: Fine-Grained Image Understanding through Multimodal Contrastive Embedding Learning**。該架構以 SeCu [11] 為基礎，引入輔助影像（如 VQ-VAE [5] 與 DRAME [6] 所產生的輔助圖像）作為多模態輸入，加入我們設計的多模態對比學習特徵提取模組 (Multi-modal Contrastive Learning Feature Extract Block, MCLFE)，其中使用不同尺寸的卷積層對正樣本圖及輔助圖提取特徵，再利用通道注意力及空間注意力強化模型學習，並提升模型對異常區域的關注能力，進而強化多模態特徵提取器學習「微小且細粒度 (tiny and fine-grained)」的能力。

本研究分別於 A19 產線面板資料集、Retina 視網膜資料集 [1]、NEU-DET 鋼鐵表面瑕疵資料集 [2]、MVTec 資料集 [3] 以及 CIFAR-10 [4] 上進行實驗，並與現有多種無監督方法（SimCLR [8]、MOCOv2 [9]、SeCu [11]、DATFuse [15]）進行比較。在聚類評估方面，我們的方法在 NMI 與 ARI 指標上表現穩定且優異，特別是在高雜訊與結構複雜的資料集（如 Retina [1]）中仍具強健性；即使在準確率（ACC）上因群集標籤與真實標籤對應錯位而略顯劣勢，整體聚類品質仍具有明顯優勢。此外，在線性探測實驗中，我們的方法亦展現出可判別特徵的能力，顯示所學特徵具良好遷移與分類潛力。

5.1.1 未來展望

儘管本研究已驗證我們的方法在聚類與細粒度異常分群上的可行性與效能，未來仍有數個發展方向值得深入探討：

1. **輔助影像生成之強化**：由於我們的方法對於輔助影像的要求十分的高，但目前所採用的 VQ-VAE [5] 與 DRAME [6] 所產生的輔助圖像仍受限於生成品質，後續可探索基於注意力機制的生成方法，以更有效引導模型聚焦於異常區域。

2. **跨模態與提示式學習融合**：未來可嘗試引入語言模態，搭配圖文對齊的提示學習機制，提升模型對異常語意的理解與類別泛化能力，進一步拓展至弱監督或零樣本場景。

綜上所述，我們的方法展現了於細粒度異常辨識與無監督聚類場景中的潛力，未來在多模態融合、跨領域應用與實務部署等面向，仍具備極高的研究價值與發展空間。

六、參考文獻

- [1] S. Pachade, P. Porwal, D. Thulkar, M. Kokare, G. Deshmukh, V. Sahasrabuddhe, L. Giancardo, G. Quellec, and F. Mériaudeau, “Retinal fundus multi-disease image dataset (rfmid): a dataset for multi-disease detection research,” *Data*, vol. 6, no. 2, p. 14, 2021.
- [2] N. University, “Neu surface defect database.” https://faculty.neu.edu.cn/yunhyan/NEU_surface_defect_database.html, 2013. Accessed: 2025-06-22.
- [3] P. Bergmann, M. Fauser, D. Sattlegger, and C. Steger, “Mvtec ad – a comprehensive real-world dataset for unsupervised anomaly detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9592–9600, IEEE, 2019.
- [4] A. Krizhevsky, V. Nair, and G. Hinton, “Learning multiple layers of features from tiny images,” tech. rep., Technical Report, University of Toronto, 2009.
- [5] A. van den Oord, O. Vinyals, and K. Kavukcuoglu, “Neural discrete representation learning,” in *Advances in Neural Information Processing Systems*, vol. 30, pp. 6306–6315, 2017.
- [6] V. Zavrtanik, M. Kristan, and D. Skočaj, “Draem: A discriminatively trained reconstruction embedding for surface anomaly detection,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 8330–8339, 2021.
- [7] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet: A large-scale hierarchical image database,” in *2009 IEEE conference on computer vision and pattern recognition*, pp. 248–255, Ieee, 2009.
- [8] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A simple framework for contrastive learning of visual representations,” in *International Conference on Machine Learning (ICML)*, vol. 119, pp. 1597–1607, PMLR, 2020.
- [9] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, “Momentum contrast for unsupervised visual representation learning,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9729–9738, 2020.
- [10] S. Kim, J. Park, H. Kim, and J. Choi, “Un-mix: Rethinking image mixtures for unsupervised visual representation learning,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 36, pp. 2345–2353, AAAI Press, 2022.
- [11] Q. Qian, “Stable cluster discrimination for deep clustering,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 16645–16654, October 2023.

- [12] W. Huang, A. Han, Y. Chen, Y. Cao, Z. Xu, and T. Suzuki, “On the comparison between multi-modal and single-modal contrastive learning,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 81549–81605, 2024.
- [13] C. Hazirbas, L. Ma, C. Domokos, and D. Cremers, “Fusenet: Incorporating depth into semantic segmentation via fusion-based cnn architecture,” in *Asian Conference on Computer Vision (ACCV)*, pp. 213–228, Springer, 2016.
- [14] Y. Choi, J. P. Yun, B. J. Kim, H. Jang, and S. W. Kim, “Attention-based multimodal image feature fusion module for transmission line detection,” in *IEEE Transactions on Industrial Informatics*, vol. 18, pp. 7686–7695, IEEE, 2022.
- [15] Y. Tang and Others, “Datfuse: Dual attention transformer network for multimodal semantic segmentation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [16] Y. Kim and J.-W. Ha, “Contrastive fine-grained class clustering via generative adversarial networks,” 2022.
- [17] F. Haghighi, M. R. H. Taher, M. B. Gotway, and J. Liang, “Dira: Discriminative, restorative, and adversarial learning for self-supervised medical image analysis,” 2022.
- [18] S.-H. Gao, M.-M. Cheng, K. Zhao, X.-Y. Zhang, M.-H. Yang, and P. H. S. Torr, “Res2net: A new multi-scale backbone architecture,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 802–811, 2019.
- [19] M. Herrero, “DDR dataset.” <https://www.kaggle.com/datasets/mariaherrerot/ddrdataset>, 2022. Accessed: 2025-06-22.